



# **Desarrollo de un procedimiento de calibración de sonómetros y calibradores acústicos de conformidad con las normas IEC 61672-3 e IEC 60942**

**Juan Felipe Maldonado Pedraza**

Universidad Nacional de Colombia  
Facultad de Ingeniería, Departamento de Ingeniería Eléctrica y Electrónica  
Bogotá, Colombia  
2021



# **Desarrollo de un procedimiento de calibración de sonómetros y calibradores acústicos de conformidad con las normas IEC 61672-3 e IEC 60942**

**Juan Felipe Maldonado Pedraza**

Trabajo de grado presentado como requisito parcial para optar al título de:  
**Magister en Automatización Industrial**

Director:  
Ph.D. Leonardo Enrique Bermeo Clavijo

Línea de investigación:  
Automatización en procesos de metrología  
Universidad Nacional de Colombia  
Facultad de Ingeniería  
Bogotá, Colombia  
2022



Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Lorem ipsum dolor sit amet, consectetur adipiscing elit.



## Agradecimientos

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.





---

## Resumen

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

**Palabras clave:** Calibración, metrología, sonómetros, calibradores acústicos, automatización, visión de máquina, cadena de Markov

## Abstract

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

**Keywords:** Calibration, metrology, sound level meters, acoustic calibrators, automation, computer vision, Markov chain



# Índice general

<b>Agradecimientos</b>	<b>VII</b>
<b>Resumen</b>	<b>IX</b>
<b>Lista de figuras</b>	<b>XIII</b>
<b>Lista de tablas</b>	<b>1</b>
<b>1. Introducción</b>	<b>2</b>
1.1. Planteamiento del problema	2
1.2. Objetivos	3
1.2.1. General	3
1.2.2. Específicos	3
1.2.3. Alcance de los objetivos	3
1.2.4. Antecedentes	4
<b>2. Metodología e instrumentación</b>	<b>5</b>
2.1. Instrumentos bajo calibración	5
2.1.1. Calibradores acústicos	5
2.1.2. Sonómetros integradores	6
2.2. Métodos normalizados	10
2.2.1. Descripción general de la calibración periódica de calibradores acústicos de acuerdo con la IEC 60942:2017	10
2.2.2. Descripción general de las pruebas periódicas seleccionadas de acuerdo con la IEC 61672-3:2013	12
2.3. Instrumentación	14
2.3.1. Patrones e instrumentos para la calibración periódica de calibradores acústicos	14
2.3.2. Patrones e instrumentos para la calibración periódica de sonómetros	14
2.3.3. Comandos SCPI	14
<b>3. Sistema de reconocimiento de imágenes para el valor de medición</b>	<b>15</b>
3.1. Discusión	32

<b>4. Implementación de los procedimientos de calibración</b>	<b>35</b>
4.1. Automatización de la calibración periódica de calibradores acústicos . . . . .	35
4.1.1. GRAFCET descriptivo del proceso . . . . .	35
4.1.2. Implementación en Python . . . . .	35
4.2. Automatización de la calibración periódica de sonómetros . . . . .	35
4.2.1. Implementación en Python . . . . .	35
<b>5. Modelamiento de incertidumbre de medición en la calibración periódica de sonómetros</b>	<b>36</b>
5.1. Cadenas de Markov de tiempo discreto . . . . .	37
5.1.1. Matriz de probabilidades de transición . . . . .	37
5.1.2. Valor esperado . . . . .	37
5.1.3. Probabilidad estacionaria . . . . .	37
5.2. Incertidumbre de medición . . . . .	37
5.2.1. Incertidumbre tipo A . . . . .	37
5.2.2. Incertidumbre tipo B . . . . .	37
5.2.3. Incertidumbre típica combinada . . . . .	37
5.2.4. Grados efectivos de libertad, factor de cobertura e incertidumbre expandida . . . . .	37
5.3. Algoritmo para creación de estados y tasas de transición de la cadena de Markov	37
5.3.1. Implementación de la cadena de Markov en Python . . . . .	37
<b>6. Conclusiones y recomendaciones</b>	<b>38</b>
6.1. Conclusiones . . . . .	38
6.2. Recomendaciones . . . . .	38
<b>A. Anexo: Certificado de calibración de calibrador acústico</b>	<b>39</b>
<b>B. Anexo: Certificado de calibración de sonómetro</b>	<b>40</b>
<b>Bibliografía</b>	<b>41</b>

# Índice de figuras

2-1. Calibrador acústico multifunción Brüel & Kjær 4226. . . . .	5
2-2. Calibrador acústico Brüel & Kjær 4231 acoplado al micrófono de un sonómetro Brüel & Kjær 2250. . . . .	6
2-3. Configuraciones de <i>hardware</i> del sonómetro Brüel & Kjær 2250. . . . .	7
2-4. Gráfico de las ponderaciones frecuenciales <i>A</i> , <i>C</i> y <i>Z</i> . . . . .	8
2-5. Gráfico de las respuestas en el tiempo de las ponderaciones temporales <i>fast</i> , <i>slow</i> e <i>impulse</i> . . . . .	9
2-6. Diagrama de flujo general de la calibración periódica de calibradores acústicos. . . . .	12
2-7. Diagrama de bloques del proceso de medición en la calibración periódica de sonómetros de acuerdo con la IEC 61672-3:2013. . . . .	13
3-1. Comparación de los modos de <i>padding</i> : <i>zero</i> y <i>mirror</i> . . . . .	17
3-2. Ejemplo de una fotografía de la pantalla de un sonómetro 01dB CUBE. . . . .	28
3-3. Puntos clave para el cálculo del descriptor SIFT de una imagen de un dígito. . . . .	29
3-4. Resultados de procesamiento para tres muestras del conjunto de entrenamiento. . . . .	31
3-5. Vectores de características de las tres muestras de entrenamiento procesadas. . . . .	32
3-6. Matriz de confusión del clasificador bayesiano propuesto. . . . .	33



## Índice de cuadros

# 1. Introducción

## 1.1. Planteamiento del problema

En la actualidad, la creciente contaminación acústica amerita la implementación de redes de monitoreo continuo de ruido o mediciones puntuales empleando instrumentos adecuados como son los sonómetros con el propósito de cuantizar los niveles de ruido ambiental, de emisión de ruido de fuentes sonoras específicas y de exposición sonora, para luego comparar con los niveles máximos permitidos por la normativa relacionada nacional e internacional y tomar decisiones al respecto. Para garantizar la confiabilidad de tales mediciones o asegurar la validez de sus resultados, en Colombia, entidades como el Instituto de Hidrología, Meteorología y Estudios Ambientales (IDEAM) exigen que las organizaciones que prestan estos servicios cuenten con sonómetros calibrados periódicamente bajo el estándar internacional IEC 61672-3:2013. por parte de un organismo de evaluación de la conformidad (OEC), en este caso un laboratorio de calibración acreditado por el Organismo Nacional de Acreditación de Colombia (ONAC) bajo el estándar ISO 17025, con el fin de verificar que estos instrumentos continúan cumpliendo las especificaciones normalizadas según su clase. La norma IEC 61672-3 describe una serie de pruebas acústicas y eléctricas que se realizan a sonómetros integradores clase 1 y 2, cuyo propósito es comprobar el funcionamiento del sonómetro en: 1) La sensibilidad de su micrófono (para lo cual se usa un calibrador acústico calibrado previamente y que esté en conformidad con las especificaciones de la IEC 60942). 2) Las redes de ponderación frecuencial A, C y Z. 3) En las ponderaciones temporales F (*fast*) y S (*slow*). 4) En el rango lineal. 5) En la medición de niveles promediados en el tiempo, niveles de exposición sonora y niveles pico. 6) En la indicación de sobrecarga. 7) En la exposición a largos periodos de medición y a niveles de sonido elevados. Dicha comprobación se hace comparando con las especificaciones definidas en la norma IEC 61672-1:2013.



## 1.2. Objetivos

### 1.2.1. General

Desarrollar un sistema de calibración periódica de sonómetros y calibradores acústicos de conformidad con las normas IEC 61672-3:2013 e IEC 60942:2017.

### 1.2.2. Específicos

1. Formular un modelo en GRAFCET como base para el desarrollo de un sistema de calibración periódica de calibradores acústicos.
2. Implementar las secuencias de comando (a través de bus GPIB) para configurar parámetros de señal y, a su vez, recibir resultados de los instrumentos de medición.
3. Desarrollar un método de reconocimiento de imágenes para detectar los niveles instantáneos ponderados en tiempo y en frecuencia desde la pantalla del sonómetro.
4. Desarrollar un método que permita tener en cuenta la variabilidad de los niveles en pantalla instantáneos ponderados en tiempo y en frecuencia del objetivo 3, (mediante mediciones de larga duración), para la estimación del mesurando y de la incertidumbre de medición.

### 1.2.3. Alcance de los objetivos

El sistema de calibración se implementará para ejecutar las pruebas de calibración de los numerales 9.3 (apoyado en la IEC 60942), 13, 14 y 16 de la IEC 61672-3. Los indicadores de interés serán los niveles instantáneos con ponderación temporal (*slow* o *fast*) y ponderación frecuencial (*A*, *C*, o *Z*), i.e.  $L_{AF}, L_{AS}, L_{CF}, L_{CS}, L_{ZF}$  o  $L_{ZS}$ , dependiendo de la prueba y según estén disponibles en el sonómetro sujetos al periodo de actualización de la pantalla del sonómetro. El sistema tendrá en cuenta el modelo del proceso estocástico para la estimación de incertidumbre expandida de medición.

#### **1.2.4. Antecedentes**

**Sistemas de calibración comerciales desarrollados por fabricantes**

**Sistemas de calibración desarrollados por otras organizaciones**

## 2. Metodología e instrumentación

### 2.1. Instrumentos bajo calibración

#### 2.1.1. Calibradores acústicos

De acuerdo con la normativa internacional, un calibrador acústico es un dispositivo diseñado para producir uno o más niveles de presión sonora conocidos (en dB referenciados a  $20 \mu\text{Pa}$ ) a una o más frecuencias especificadas (en Hz) cuando se acopla a modelos específicos de micrófono en configuraciones específicas (IEC-TC29, 2017). Normalmente, la señal senoidal generada por algún transductor, como un altavoz o, en el caso de los pistófonos, un pistón mecánico cuyo movimiento genera en la cavidad una velocidad de volumen conocida. Como ejemplo, en la figura 2-1 se muestra un calibrador acústico multifunción usado como referencia en muchos laboratorios: el Brüel & Kjær 4226, que es capaz de generar 94 dB, 104 dB y 114 dB en las frecuencias de octava desde 31,5 Hz hasta 16 kHz, más la frecuencia de 12,5 Hz.

Figura 2-1.: Calibrador acústico multifunción Brüel & Kjær 4226.



Tomado de <https://www.transcat.com/bruel-kjaer-4226-acoustic-calibrator-94-104-and-114db-used>

Generalmente los calibradores acústicos son empleados para determinar la sensibilidad en campo de presión (típicamente en  $\text{mV}/\text{Pa}$  o en dB referenciados a 1 V) de modelos especificados de micrófonos en configuraciones dadas, pero también es utilizado para verificar o ajustar la sensi-

bilidad de algún dispositivo o sistema de medición acústica. Un ejemplo de calibrador acoplado para comprobar la indicación de un sonómetro se muestra en la figura 2-2.

Figura 2-2.: Calibrador acústico Brüel & Kjær 4231 acoplado al micrófono de un sonómetro Brüel & Kjær 2250.



Tomado de <https://www.bksv.com/en/knowledge/blog/sound/getting-started-sound-level-meter>


La norma IEC 60942:2017 establece una clasificación de los calibradores según sus especificaciones (límites de aceptación), de la más a la menos restrictiva: Clase LS (*laboratory standard*), clase 1 o clase 2. La comprobación de que cierto modelo de calibrador cumple con todas las especificaciones normalizadas según su clase la realiza una organización independiente acreditada para hacer pruebas de aprobación de modelo de acuerdo con los lineamientos del Anexo A de la IEC 60942:2017. Pero además, un usuario de un calibrador acústico debería calibrar periódicamente su instrumento para garantizar la trazabilidad a los estándares nacionales y la confiabilidad de sus resultados. Esta calibración periódica es llevada a cabo por organismos evaluadores de la conformidad acreditados en ISO 17025 para realizar los ensayos periódicos de acuerdo con el Anexo B de la IEC 60942:2017. Los ensayos periódicos son el objeto de automatización en este proyecto y se describen en la sección 2.2.1.

### 2.1.2. Sonómetros integradores

Brüel & Kjær, uno de los fabricantes más prominentes de sonómetros define consistentemente los conceptos básicos sobre dichos instrumentos en uno de sus artículos (B&K, 2021). Básicamente, un sonómetro es un instrumento diseñado para medir niveles de sonido de una forma estandarizada; su respuesta al sonido se asemeja a la del oído humano y proporciona medidas de niveles de presión sonora objetivas y reproducibles. Generalmente, los sonómetros son empleados en el monitoreo de ruido proveniente de diversas fuentes sonoras, como plantas industriales, tráfico rodado, aeronáutico o ferroviario, conciertos, etc. Como se puede ver en la figura 2-3, un sonómetro típico consta de un micrófono, un preamplificador, una unidad de procesamiento de señal (interna) y una pantalla. Regularmente el preamplificador hace parte del cuerpo del sonómetro, pero no siempre es el caso; un sonómetro podría estar provisto de

cables de extensión que separen el preamplificador de la unidad de procesamiento.

Figura 2-3.: Configuraciones de *hardware* del sonómetro Brüel & Kjær 2250.




Tomado del Manual de Instrucciones (B&K, 2016)

En cuanto al flujo de señal, el micrófono es un transductor electroacústico que transforma la señal acústica en una señal eléctrica. La mayoría de los micrófonos empleados en mediciones acústicas son de condensador, y gracias a su construcción es el mejor tipo para garantizar precisión, estabilidad y confiabilidad en los resultados. No obstante, la señal eléctrica proporcionada por un micrófono es de baja amplitud (aún con micrófonos de alta gama cuya sensibilidad se

encuentra típicamente en el orden de los  $50 \text{ mV/Pa}$ , por lo que se requiere una amplificación para que la unidad de procesamiento manipule la señal en un nivel adecuado, este es el objetivo del preamplificador. Luego, en la unidad de procesamiento se ejecutan diferentes cálculos a partir de la señal, los mínimos requeridos por la norma internacional IEC 61672-1:2013 y utilizados en este proyecto son:

- **Ponderación frecuencial:** Diferencia, como una función especificada de la frecuencia, entre el nivel de la señal ponderada en frecuencia indicado en el dispositivo de presentación de resultados y el nivel correspondiente de una señal de entrada sinusoidal de amplitud constante (IEC-TC29, 2013). Las ponderaciones frecuenciales estandarizadas  $A$ ,  $C$ , o  $Z$ , para las bandas de tercio de octavas están definidas en la Tabla 3 de la IEC 61672-1:2013. En concreto, cada una de estas ponderaciones modifican la respuesta del sonómetro frente a diferentes frecuencias de sonido. Por ejemplo, la ponderación  $A$  asemeja la respuesta en frecuencia al comportamiento del oído humano en un rango medio de niveles, tomando como referencia la curva de igual sonoridad de 40 dB (Fletcher and Munson, 1933), por tal motivo es el más empleado en ruido ambiental y ocupacional. Pero el oído humano no tiene un comportamiento lineal, y la percepción del sonido varía con el nivel, la ponderación  $C$  está basada en la curva de igual sonoridad de 100 dB, por eso esta es empleada en la evaluación de niveles pico de sonidos altos. Finalmente, la ponderación zero ( $Z$ ) es completamente plana en todo el rango de frecuencias (sin tener en cuenta la respuesta del micrófono). En la figura 2-4 se puede ver gráficamente cada una de las ponderaciones frecuenciales.

Figura 2-4.: Gráfico de las ponderaciones frecuenciales  $A$ ,  $C$  y  $Z$ .



Tomado de (B&K, 2021).


- **Ponderación temporal:** Es una función exponencial temporal que modifica la respuesta temporal del sonómetro frente a las variaciones en el nivel de presión sonora. Esta función obedece a una constante de tiempo especificada que depende de la ponderación temporal elegida, bien sea F (fast,  $\tau_F = 125 \text{ ms}$ ), S (slow,  $\tau_S = 1 \text{ s}$ ) o I (impulse,  $\tau_I = 35 \text{ ms}$ ). Por lo

tanto, tal como lo define la norma, para una señal con ponderación  $X$ , el nivel de sonido con ponderación temporal  $Y$  será:

$$L_{XY}(t) = 10 \log \left( \frac{\frac{1}{\tau_Y} \int_{-\infty}^t p_X^2(\xi) e^{-(t-\xi)/\tau_Y} d\xi}{p_0^2} \right) \text{ dB} \quad (2-1)$$

Donde  $\tau_Y$  es la constante de tiempo en segundos de la ponderación temporal,  $\xi$  es una variable ficticia del tiempo de integración desde un instante de tiempo en el pasado  $(-\infty)$  hasta el instante de observación  $t$ ,  $p_X(\xi)$  es la señal de presión acústica instantánea con ponderación frecuencial  $X$ , y  $p_0$  es el valor de referencia de  $20 \mu\text{Pa}$ . Una comparación entre las respuestas en el tiempo de cada ponderación temporal se muestra en la figura 2-5.

Figura 2-5.: Gráfico de las respuestas en el tiempo de las ponderaciones temporales *fast*, *slow* e *impulse*.



Tomado de (B&K, 2021).

Consecuentemente, un nivel de sonido, objeto de evaluación en las pruebas aquí implementadas puede ser  $L_{AF}$ ,  $L_{AS}$ ,  $L_{CF}$ ,  $L_{CS}$ ,  $L_{ZF}$  o  $L_{ZS}$ . para las ponderaciones frecuenciales  $A$ ,  $C$ , o  $Z$  y para las ponderaciones temporales *fast* o *slow*. El resultado de la medición de nivel de sonido es mostrado directamente en la pantalla del sonómetro o alguna otra herramienta de visualización como una interfaz web; en algunos sonómetros según su tecnología y disposiciones del fabricante, el resultado de medición es enviado vía serial o en forma de una señal DC o AC de amplitud proporcional al nivel de sonido.

La norma IEC 61672-1:2013 establece una clasificación de los sonómetros según sus especificaciones: clase 1 o clase 2. La comprobación de que cierto modelo de sonómetro cumple con todas las especificaciones normalizadas según su clase la realiza una organización independiente acreditada para hacer pruebas de aprobación de modelo de acuerdo con los lineamientos de la IEC 61672-2:2013. Pero además, un usuario de un sonómetro debería calibrar periódicamente

te su instrumento para garantizar la trazabilidad a los estándares nacionales y la confiabilidad de sus resultados. Esta calibración periódica es llevada a cabo por organismos evaluadores de la conformidad acreditados en ISO 17025 para realizar los ensayos periódicos de acuerdo con la IEC 61672-3:2013. Los ensayos periódicos son el objeto de automatización en este proyecto y se describen en la sección 2.2.2. Todavía más, la sensibilidad del transductor (micrófono) y la respuesta de los circuitos electrónicos puede variar con el paso del tiempo presentando una pequeñas derivas o también pueden verse afectadas por las condiciones ambientales como la temperatura y la humedad; por esto, es una buena práctica verificar regularmente la sensibilidad del sonómetro, preferiblemente antes y después de cada campaña de medición, de este modo el sonómetro será ajustado a un nivel de referencia conocido emitido por un calibrador acústico cuyo nivel tenga trazabilidad metrológica.

## 2.2. Métodos normalizados

Las especificaciones y metodología de calibración de instrumentación acústica y de vibraciones son normalizadas por el comité técnico 29 de la Comisión Electrotécnica Internacional (IEC) en colaboración con la Organización Internacional de Metrología Legal (OIML). A continuación se hace una descripción que resume el proceso de calibración periódica de calibradores acústicos y sonómetros, dando especial enfoque a los pasos operativos más que a las disposiciones preliminares o generales de las normas.

### 2.2.1. Descripción general de la calibración periódica de calibradores acústicos de acuerdo con la IEC 60942:2017

Tal como se describe en el Anexo B de la IEC 60942:2017, el calibrador acústico o pistófono con todos sus accesorios necesarios (como adoptadores o barómetro) debe ser entregado junto con el manual de instrucciones, si este es requerido por el laboratorio de calibración. Luego, se hace una inspección visual del calibrador acústico verificando que todos los controles están funcionando y que la fuente de alimentación está operando dentro de los límites especificados en el manual de instrucciones. En seguida se toman en cuenta o se realizan las siguientes secciones.

**Orientación para los ensayos**, si en el manual de instrucciones se especifica alguna orientación del calibrador acústico, esta debe ser la utilizada en la calibración periódica.

**Ruido ambiental**, para evitar que el ruido ambiental afecte las mediciones, las pruebas sólo se realizan el nivel de presión sonora con el calibrador acoplado al micrófono, pero con el calibrador apagado, es por lo menos 30 dB por debajo del nivel especificado que se está midiendo.



**Influencia de las condiciones ambientales**, cuando es apropiado, la información suministrada en el manual de instrucciones sobre la influencia de la presión estática debe ser aplicada para corregir el nivel de presión medido a la presión estática de referencia.

**Nivel de presión sonora**, después de acoplar el calibrador acústico al micrófono, se debe dejar el tiempo de estabilización indicado en el manual de instrucciones, luego, el nivel de presión sonora generado por el calibrador debe ser medido como un promedio durante un periodo de entre 20 s y 25 s de operación.

Para medir el nivel de presión sonora hay propuestos dos métodos en la norma internacional, usando un micrófono de referencia o usando un calibrador acústico de referencia para comparación. En este proyecto se utiliza el segundo, en el que el nivel del calibrador bajo prueba es determinado por comparación contra el nivel generado por un calibrador acústico calibrado cuya trazabilidad metrológica esté establecida.

El nivel de presión sonora debe ser medido al menos tres veces, cada vez acoplando el micrófono y el calibrador acústico antes de la medición y desacoplándolo después. En cada nuevo acoplamiento se debe rotar el micrófono sobre su eje. La diferencia absoluta entre el nivel medido medio y el nivel especificado no debe exceder los límites establecidos en la Tabla 2 de la IEC 60942:2017 según la clase del calibrador y la frecuencia medida. La medición de nivel de presión sonora debe ser repetida para cada combinación de nivel y frecuencia que indique el manual de instrucciones que cumple con las especificaciones de la norma.

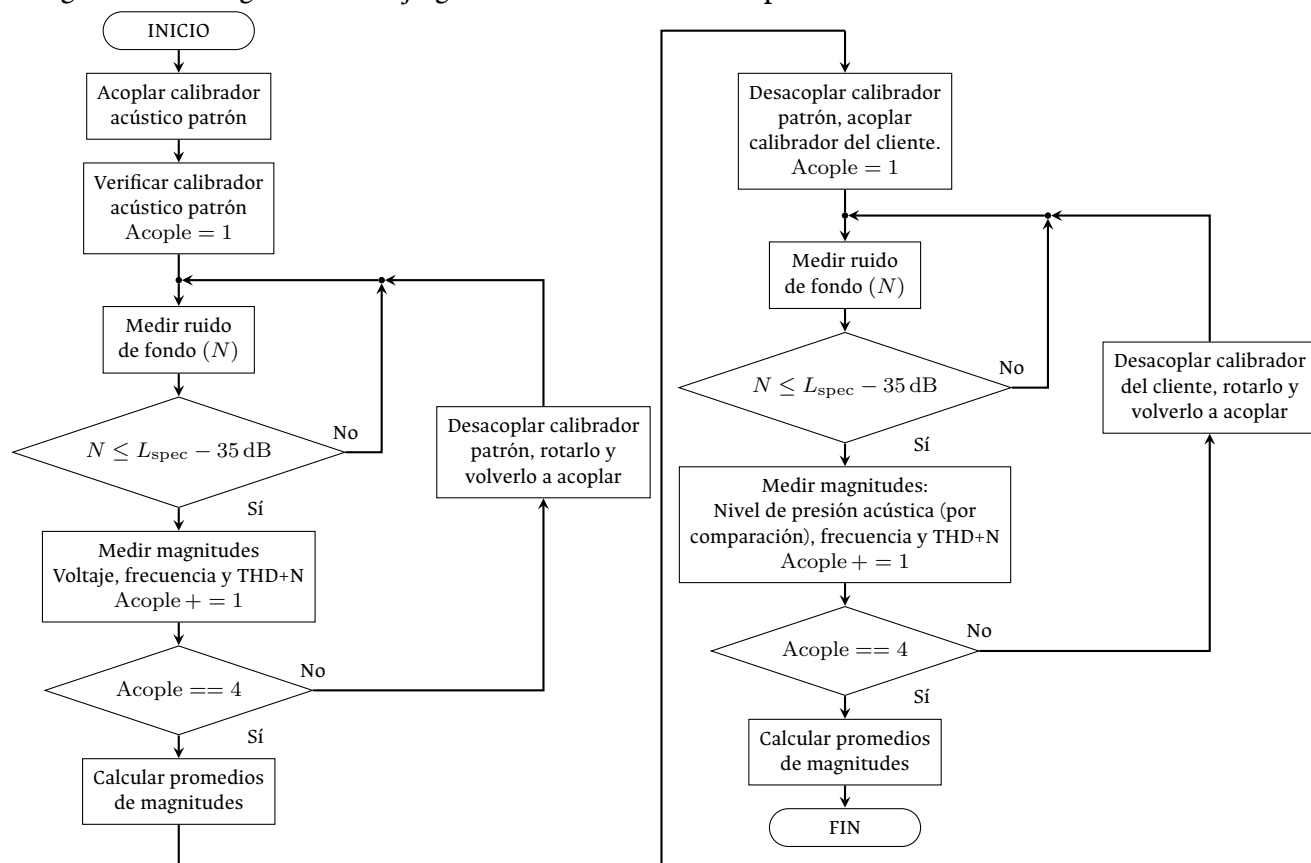
**Frecuencia**, debe ser medida con el calibrador acoplado al micrófono como un promedio durante un periodo de entre 20 s y 25 s de operación, para cada frecuencia disponible en el calibrador de la cual se indique en el manual que cumple con las especificaciones de la norma. El valor absoluto de la diferencia porcentual cada frecuencia medida y la correspondiente frecuencia especificada no debe exceder los límites establecidos en la Tabla 4 de la IEC 60942:2017 según la clase del calibrador.

**Distorsión armónica total más ruido (THD+N)**, la distorsión de la señal generada por el calibrador debe medirse en un ancho de banda de 22,4 Hz a 22,4 kHz, como un promedio durante un periodo de entre 20 s y 25 s, en los niveles máximo y mínimos disponibles a cada frecuencia de los que se indique en el manual que cumple con las especificaciones de la norma. La THD+N puede ser medido utilizando un filtro de rechazo (medidor de factor de distorsión) o un analizador FFT. La THD+N medida no debe exceder los límites establecidos en la Tabla 7 de la IEC 60942:2017 según la clase del calibrador. Es obligatorio que la magnitud medida sea no sólo distorsión armónica total, sino distorsión armónica total más ruido, reportada en %.

En la figura 2-6 se presenta un diagrama de bloques que describe en general el proceso de calibración de calibradores acústicos. La automatización de este proceso es el tema de la sección

## 4.1.

Figura 2-6.: Diagrama de flujo general de la calibración periódica de calibradores acústicos.

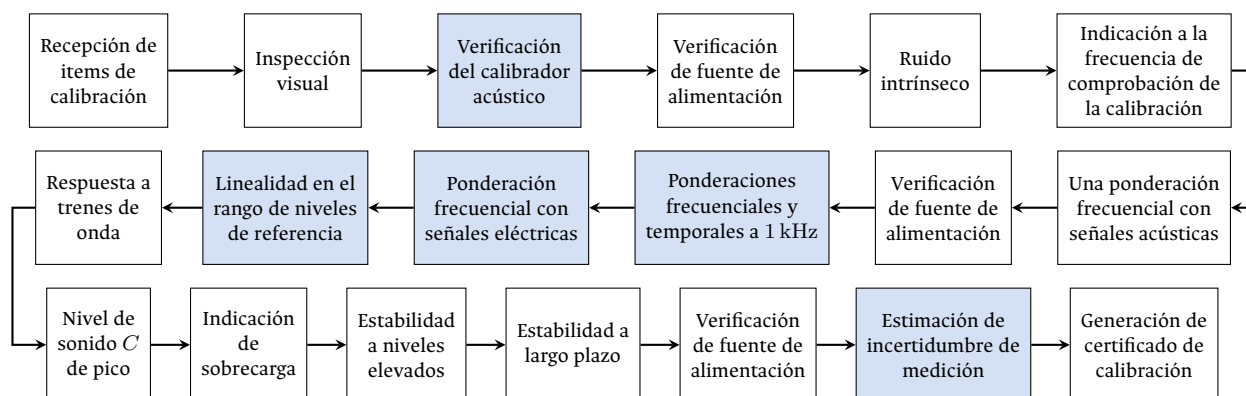


### 2.2.2. Descripción general de las pruebas periódicas seleccionadas de acuerdo con la IEC 61672-3:2013

Tal como se describe en la IEC 61672-3:2013, el sonómetro con todos sus accesorios necesarios (como preamplificador, micrófono, cable de extensión o adaptador de impedancia) debe ser entregado junto con el manual de instrucciones, si este es requerido por el laboratorio de calibración. Toda la información necesaria para los ensayos periódicos debe estar disponible, como correcciones de campo libre, rangos de medición, niveles de referencia, etc. Además, se debe contar con un calibrador acústico, ya sea suministrado por el cliente o por el laboratorio. Luego, se hace una inspección preliminar del sonómetro y todos sus accesorios, verificando que todos los controles están funcionando, que la pantalla está en buen estado, que no halla acumulación de material extraño en la rejilla o membrana del micrófono y que otros elementos esenciales estén en un funcionamiento adecuado. Después se verifica que la fuente de alimentación está

operando dentro de los límites especificados en el manual de instrucciones. La fuente de alimentación será verificada nuevamente después de los ensayos con señales acústicas y después de los ensayos con señales eléctricas. En seguida se procede con las pruebas presentadas en la figura 2-7.

Figura 2-7.: Diagrama de bloques del proceso de medición en la calibración periódica de sonómetros de acuerdo con la IEC 61672-3:2013.



De los bloques de la figura 2-7, los resaltados en azul son los procesos que, en alguna medida, son objeto de automatización en este proyecto. A continuación, se detallan las pruebas que serán efectuadas.

### Indicación a la frecuencia de comprobación de la calibración

El calibrador acústico entregado por el cliente o proporcionado por el laboratorio se acopla al micrófono del sonómetro, y, si es necesario, se ajusta el sonómetro para indicar el nivel de presión acústica requerido en las condiciones ambientales en las que se realizan los ensayos. Las indicaciones antes y después del ajuste deben registrarse. Se debe tomar en cuenta el efecto de la presión estática sobre el calibrador acústico empleado. Este calibrador ya debió haber sido verificado previamente con el procedimiento descrito en 2.2.1.

Después de haber ajustado el sonómetro en respuesta al nivel generado por el calibrador, un paso necesario antes de continuar con las otras pruebas es determinar el voltaje que produce una indicación del nivel de referencia, pues este es el voltaje a partir del cual se calculan los voltajes correspondientes a los niveles de señal en las demás pruebas. Ese voltaje de referencia es el voltaje en la mitad de un intervalo de voltajes que producen todos una misma indicación del nivel de referencia. La ecuación 2-2 es empleada para determinar el voltaje de referencia.

$$v_{\text{ref}} = 10^{\left( \frac{L_{v,l} + (L_{v,u} - L_{v,l})/2}{20} \right)} \quad (2-2)$$

Donde  $v_{\text{ref}}$  es el voltaje medio en una escala logarítmica que produce una indicación del nivel de referencia,  $L_{v,l}$  es el nivel de voltaje inferior del intervalo que produce una indicación del nivel de referencia, y  $L_{v,u}$  el nivel de voltaje superior. Los niveles de voltaje son referenciados a 1 V.

### **Ponderaciones frecuenciales y temporales a 1 kHz**

### **Ponderaciones frecuenciales con señales eléctricas**

### **Linealidad de nivel en el rango de niveles de referencia**

## **2.3. Instrumentación**

### **2.3.1. Patrones e instrumentos para la calibración periódica de calibradores acústicos**

### **2.3.2. Patrones e instrumentos para la calibración periódica de sonómetros**

### **2.3.3. Comandos SCPI**

### 3. Sistema de reconocimiento de imágenes para el valor de medición

En esta sección se discute el desarrollo del sistema de reconocimiento de caracteres que será empleado para adquirir automáticamente un valor de medición que sea indicado en la pantalla del sonómetro bajo calibración. Primero se introduce un algoritmo general con los pasos de procesamiento y clasificación de las imágenes; luego, se presenta el fundamento teórico de cada uno de esos pasos. Finalmente se muestran y discuten los resultados de procesamiento de imagen sobre una muestra de un dígito, como también los resultados del clasificador implementado.

#### Algoritmo de reconocimiento de caracteres

De manera general, la solución propuesta, para el reconocimiento del valor de medición indicado en la pantalla del sonómetro, consta de varios pasos que se presentan en el siguiente algoritmo.

---

**Algoritmo 3.1:** Algoritmo del sistema de reconocimiento de imágenes.

---

**Data:** images  $\leftarrow$  Imágenes de entrenamiento si va a entrenar o fotos de la pantalla si va reconocer.

**output:** Clases estimadas.

```
1 training  $\leftarrow$  True | False
2 foreach image  $\in$  images do
3   \Las operaciones sobre image son realizadas in place.
4   Paso 1: Filtrar image con filtro gaussiano.
5   Paso 2: Escalar y hacer padding a image para hacerla de  $31 \times 32$  píxeles.
6   Paso 3: Segmentar image determinando el umbral con el método de Otsu \(1979\).
7   if training = False then
8     | Detectar contornos y extraer dígitos.
9   Paso 4: Calcular las características de image con el descriptor SIFT (Lowe, 2004).
10  Paso 5: Reducir dimensionalidad de las características por KPCA (Schölkopf et al., 1997).
11  | Agregar las características a la matriz features.
12 Paso 6:
13 if training then
14   | Entrenar clasificador bayesiano normal con features y las correspondientes etiquetas de clase.
15 else
16   | Estimar las clases de las características en features con el clasificador bayesiano normal.
```

---

Concerniente al procesamiento y reconocimiento de imágenes, a continuación se presenta un breve marco de referencia teórico de cada paso del algoritmo 3.1.

## Paso 1: Filtro gaussiano

Como se explica en el libro de Robert Szeliski (2011), el filtro gaussiano, también llamado filtro de suavizado o de desenfoque, es una operación local en imágenes bidimensionales, pues se efectúa en vecindarios con un tamaño determinado en píxeles; el valor final de un píxel depende de los valores de los píxeles que pertenecen a su correspondiente vecindario y, como en todos los casos de filtros lineales, de una función de ponderación. Esta operación local viene a ser la de correlación ( $g = f \otimes h$ ), que básicamente es la suma ponderada de los píxeles de entrada, que se define como

$$g(i, j) = \sum_{k, l} f(i + k, j + l) h(k, l). \quad (3-1)$$

En que  $g$  es la imagen de salida,  $f$  es la imagen de entrada y  $h$  la máscara o *kernel*, que contiene los coeficientes del filtro.

La operación contraparte de la correlación sería la convolución ( $g = f * h$ ), en la que se usa el *kernel* invertido y se define como

$$g(i, j) = \sum_{k, l} f(k, l) h(i - k, j - l). \quad (3-2)$$

En que  $h$  es la respuesta al impulso, ya que si se convoluciona la máscara  $h$  con una señal impulsiva  $\delta(i, j)$ , se obtiene la misma máscara ( $h * \delta = h$ ).

Para el caso del filtro gaussiano, el *kernel* se obtiene a partir de la típica función exponencial de Gauss. Particularmente, considerando la implementación de OpenCV que se ejecuta con la instrucción `GaussianBlur()`, la función sería la bivariada no correlacionada definida como

$$h(x, y) = \frac{1}{2\pi\sigma_x\sigma_y} \exp\left(-\frac{(x - \mu_x)^2}{2\sigma_x^2} - \frac{(y - \mu_y)^2}{2\sigma_y^2}\right). \quad (3-3)$$

La función de OpenCV también permite especificar un tamaño definido de ventana y esta calculará automáticamente las varianzas como

$$\sigma_x = \left(\frac{n_x - 1}{2}\right) 0.3 + 0.8, \quad \text{en que } n_x = \text{ancho} - 1; \quad (3-4a)$$

$$\sigma_y = \left(\frac{n_y - 1}{2}\right) 0.3 + 0.8, \quad \text{en que } n_y = \text{alto} - 1. \quad (3-4b)$$

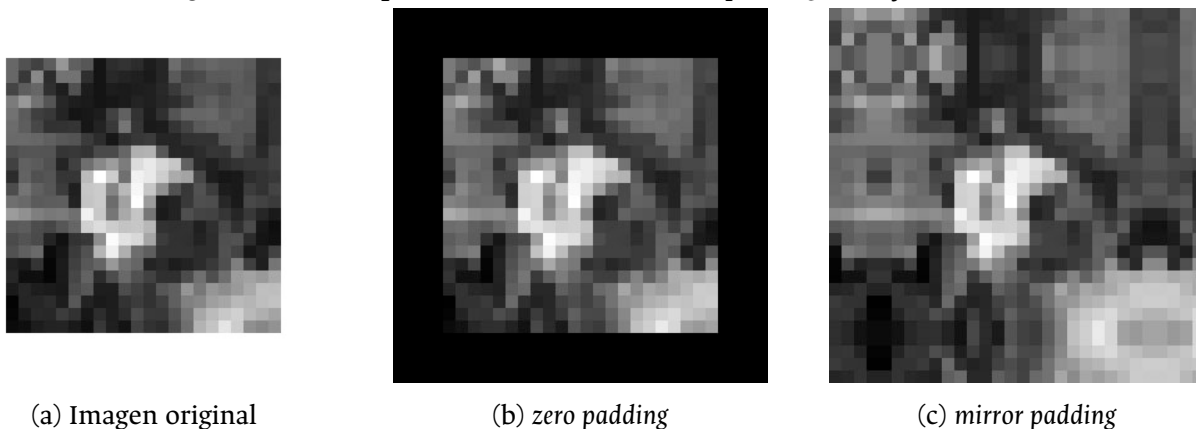
## Paso 2: Escalización y *padding*

Por supuesto, en la práctica, el filtrado requiere que se agreguen píxeles en los bordes de la imagen original, según el tamaño determinado de la ventana; a esto se le conoce como *padding* y es una operación que realiza por defecto OpenCV, con la que es posible elegir el modo del *padding*. Existen diferentes modos de *padding*, de los cuales se describen los siguientes:

- *zero*: Todos los píxeles añadidos se establecen en 0.
- *mirror*: Refleja los últimos píxeles del borde.

En la siguiente figura se muestra el resultado de ambos modos de *padding*.

Figura 3-1.: Comparación de los modos de *padding*: *zero* y *mirror*.



Tomado de (Richard, 2011).

El modo *mirror* es utilizado para el filtro gaussiano y el *zero* para adecuar la imagen antes del [paso 3](#) con el fin de completar el tamaño de  $32 \times 32$  píxeles requerido para el [paso 4](#).

Como la imagen que contiene el dígito tendrá un tamaño diferente a  $32 \times 32$ , antes de realizar el *zero padding* es necesario escalarla haciendo que el eje de mayor dimensión se ajuste a 32 píxeles y el otro eje se ajuste proporcionalmente; esta operación se realiza con la función `resize()` de OpenCV. Luego sí se añaden los píxeles faltantes al eje de menor dimensión para completar los 32 píxeles.

### Paso 3: Segmentación

Existen diferentes técnicas de segmentación: basada en umbrales, en bordes, en regiones, por agrupación o por *matching*. Por los propósitos del algoritmo, es suficiente con una umbralización sencilla para discriminar los segmentos de la imagen, que corresponderían a los dígitos indicados en la pantalla del sonómetro. Sin embargo, el umbral no puede ser el mismo para todas las imágenes, pues cada una puede estar influenciada por los efectos de iluminación, áreas o colores de los segmentos. Así que una forma sistemática de determinar el umbral es empleando el algoritmo de Otsu (Otsu, 1979), que básicamente busca maximizar la separación entre las clases de niveles de grises del histograma de la imagen usando los momentos de cero y primer orden.

La formulación de Otsu es un método no supervisado basado en el análisis discriminante para evaluar la bondad del umbral y seleccionar automáticamente un límite óptimo. En primer lugar, Otsu normaliza el histograma de niveles de grises y lo considera como una distribución de probabilidad. Si hay  $L$  niveles de grises, entonces el número de píxeles en la imagen es  $N = n_1 + n_2 + \dots + n_L$ ;  $n_i$  es el número de píxeles que tienen un nivel  $i$ . Luego, la distribución de probabilidad queda expresada como:

$$p_i = \frac{n_i}{N}, \quad p_i \geq 0, \quad \sum_{i=1}^L p_i = 1 \quad (3-5)$$

Ahora, se buscan dos clases  $C_0$  y  $C_1$ , que corresponden a los píxeles que pertenecen al fondo y a los que pertenecen a los objetos, separados por el nivel  $k$ . Las probabilidades de cada clase se definen intuitivamente en las ecuaciones (3-6a) y (3-6b).

$$\omega_0 = \Pr(C_0) = \sum_{i=1}^k p_i = \omega(k) \quad (3-6a)$$

$$\omega_1 = \Pr(C_1) = 1 - \omega(k) \quad (3-6b)$$

Luego, los valores esperados condicionales de cada clase son:

$$\mu_0 = \sum_{i=1}^k i \Pr(i|C_0) = \sum_{i=1}^k i \frac{p_i}{\omega_0} = \frac{\mu(k)}{\omega(k)} \quad (3-7a)$$



$$\mu_1 = \sum_{i=k+1}^L i \Pr(i|C_i) = \sum_{i=k+1}^L i \frac{p_i}{\omega_1} = \frac{\mu_T - \mu(k)}{1 - \omega(k)} \quad (3-7b)$$

Donde  $\omega(k)$  y  $\mu(k)$  son los momentos acumulados de cero y primer orden correspondientemente hasta el  $k$ -ésimo nivel, y están definidos como en las ecuaciones (3-8).

$$\omega(k) = \sum_{i=1}^k p_i \quad (3-8a)$$

$$\mu(k) = \sum_{i=1}^k i p_i \quad (3-8b)$$

Similarmemente,  $\mu_T$  es la media total de los niveles de grises de la imagen original y  $\sigma_T^2$  la varianza total, i.e. los momentos de primer y segundo orden de la imagen, definidos como:

$$\mu_T = \sum_{i=1}^L i p_i \quad (3-9a)$$

$$\sigma_T^2 = \sum_{i=1}^L (i - \mu_T)^2 p_i \quad (3-9b)$$

En principio, si las clases están separadas en sus niveles de grises entonces hay una umbralización adecuada; consecuentemente, un umbral que resulte en la mejor separación de clases según sus niveles de grises será un umbral óptimo. Hay por lo menos tres medidas de separación entre clases que se pueden maximizar, pero, por simplicidad (dado que depende de los momentos de orden cero y uno), conviene usar la medida definida en (3-10) como criterio para el análisis discriminante.

$$\eta = \frac{\sigma_B^2}{\sigma_T^2} \quad (3-10)$$

Donde  $\sigma_B^2$  puede ser denominado como varianza entre clases y se define como:

$$\sigma_B^2 = \omega_0 \omega_1 (\mu_1 - \mu_0)^2 \quad (3-11)$$

Finalmente, condensando las ecuaciones (3-7) a (3-11), el umbral óptimo  $k^*$  que maximiza  $\eta$  y, proporcionalmente,  $\sigma_B^2$  se encuentra con:

$$\sigma_B^2(k^*) = \max_{1 \leq k < L} \sigma_B^2(k) \quad (3-12)$$

Donde

$$\sigma_B^2(k) = \frac{[\mu_T \omega(k) - \mu(k)]^2}{\omega(k) [1 - \omega(k)]} \quad (3-13)$$

Esta optimización se puede realizar de forma iterativa con unos valores iniciales de  $\omega(0)$  y  $\mu(0)$ , luego iterando con todos los posibles valores de  $k = 0, 1, \dots, L$ , y calculando  $\sigma_B^2(k)$ . El umbral óptimo  $k^*$  será el máximo valor obtenido de  $\sigma_B^2(k)$ .

## Paso 4: Descriptor local SIFT

Como en esta aplicación particular, cuyo funcionamiento se pretende en tiempo real, el objeto de reconocimiento es simple, no hace falta el sofisticado algoritmo de detección, localización y orientación de puntos característicos de la presentación original del descriptor SIFT que hizo Lowe (Lowe, 2004). No obstante, la implementación del algoritmo aquí presentada sí tiene en cuenta su propuesta de descriptor local basada en la magnitud y dirección de los gradientes de cada píxel perteneciente a la región alrededor de cada punto característico.

En primer lugar se calcula la magnitud y dirección del gradiente de cada píxel, lo cual finalmente es una valoración del cambio direccional en la intensidad de la imagen. La dirección final del gradiente en un píxel es aquella en la que ocurre el máximo cambio de intensidad, y la magnitud sería el máximo cambio de intensidad. Las diferencias de intensidad en  $x$  y en  $y$  se determinan con las ecuaciones (3-14a) y (3-14b), luego, la dirección con (3-14c) y la magnitud con (3-14d).

$$\delta_x = I(x + 1, y) - I(x - 1, y) \quad (3-14a)$$

$$\delta_y = I(x, y + 1) - I(x, y - 1) \quad (3-14b)$$

$$\theta(x, y) = \tan^{-1} \left( \frac{\delta_y}{\delta_x} \right) \quad (3-14c)$$

$$|\nabla f(x, y)| = \sqrt{\delta_x^2 + \delta_y^2} \quad (3-14d)$$

Luego de obtener todas las magnitudes y direcciones de los gradientes, se conforma un histograma de orientaciones en 8 intervalos por cada ventana de  $n \times n = 4 \times 4$  píxeles; es decir, según la dirección de cada vector, su magnitud se suma en el respectivo intervalo del histograma de la ventana al que pertenece. Finalmente queda un vector de características de 128 valores que es la concatenación de todos los histogramas, cada uno de 8 valores. Pero la contribución de esta magnitud a su intervalo de orientación correspondiente es ponderada por la función gaussiana de la ecuación (3-15) con  $\sigma$  igual a la mitad del ancho de la ventana del descriptor, con el propósito de dar menor peso a los gradientes que están más lejos del centro del descriptor.

$$G(x, y) = \frac{1}{2\pi\sigma^2} \exp\left(-\frac{x^2 + y^2}{2\sigma^2}\right) \quad (3-15)$$

El objetivo del histograma es permitir que hayan cambios locales más grandes en las direcciones de los gradientes pero que contribuyan al mismo intervalo en el histograma. Ahora bien, pueden ocurrir cambios abruptos en el histograma cuando en realidad hay cambios suaves en las direcciones de las muestras de gradientes, esto debido a los efectos de los límites en los intervalos. Para mitigar este efecto se aplica una interpolación trilineal para distribuir la magnitud de cada muestra de gradiente en intervalos de histograma adyacentes, en función de la "distancia" de la dirección de la muestra desde el valor central del intervalo; esto queda reflejado en las funciones de ponderación de las ecuaciones (3-16a) a (3-16c).

$$\delta\theta = 360/n$$

$$i\theta(x, y) = \left\lceil \frac{\theta(x, y)}{\delta\theta} \right\rceil$$

$$ix(x, y) = \left\lceil \frac{x}{\delta x} \right\rceil$$

$$iy(x, y) = \left\lceil \frac{y}{\delta y} \right\rceil$$

$$\nabla\theta(x, y) = i\theta(x, y) - \frac{\theta(x, y)}{\delta\theta}$$

$$\nabla x(x, y) = ix(x, y) - \frac{x}{\delta x}$$

$$\nabla y(x, y) = iy(x, y) - \frac{y}{\delta y}$$

$$w_k(x, y) = \begin{cases} \nabla\theta(x, y), & k = i\theta(x, y) \\ 1 - \nabla\theta(x, y), & k = i\theta \text{ mód } 8 + 1 \\ 0, & \text{en caso contrario} \end{cases} \quad (3-16a)$$

$$w_i(x, y) = \begin{cases} \nabla x(x, y), & i = ix(x, y) \\ 1 - \nabla x(x, y), & i = ix(x, y) + 1 \\ 0, & \text{en caso contrario} \end{cases} \quad (3-16b)$$

$$w_j(x, y) = \begin{cases} \nabla y(x, y), & j = iy(x, y) \\ 1 - \nabla y(x, y), & j = iy(x, y) + 1 \\ 0, & \text{en caso contrario} \end{cases} \quad (3-16c)$$

En seguida, se conforma el histograma como se presenta a continuación:

$$\begin{aligned} H &= (H_{11}, H_{12}, \dots, H_{nn}) \\ H_j &= (h_1, h_2, \dots, h_n) \\ h_k(x, y) &= \sum_{(x,y)} w_k(x, y) w_i(x, y) w_j(x, y) |\nabla f(x, y)| G(x, y) \end{aligned} \quad (3-17)$$

Finalmente el arreglo resultante se normaliza para hacerlo invariante a los efectos de contrastes o cambios en la iluminación, y para reducir los efectos de cambios no lineales en iluminación debidos a la saturación de la cámara, se limitan los valores con un umbral experimental de 0,2, de manera que los valores inferiores a 0,2 son remplazados con 0,2, y se normaliza nuevamente. La normalización se efectúa empleando la norma  $L_2$ , como se muestra a continuación:

$$\begin{aligned} H &= (H_{11}, H_{12}, \dots, H_{nn}) \Rightarrow v = (v_1, v_2, \dots, v_m) \\ \|v\|_2 &= \sqrt{\sum_{i=1}^m v_i^2} \\ v' &= \left( \frac{v_1}{\|v\|_2}, \frac{v_2}{\|v\|_2}, \dots, \frac{v_m}{\|v\|_2} \right) \\ v'' &= (\max(v_1, 0.2), \max(v_2, 0.2), \dots, \max(v_m, 0.2)) \\ v''' &= \frac{v''}{\|v''\|_2} \end{aligned}$$

## Paso 5: Reducción de dimensionalidad por análisis de componentes principales (KPCA)

Una vez se obtienen los vectores de características de las muestras, conviene un proceso adicional para simplificar el análisis posterior de los datos, mejorar el desempeño en la clasificación, eliminar información redundante o incluso poder obtener representaciones gráficas de los vectores. Generalmente los vectores de características resultan ser de grandes dimensiones, lo que provoca ciertas desventajas como que al aumentar las dimensiones de los vectores el volumen del espacio aumenta exponencialmente y los datos tienden a volverse dispersos, y esto afecta negativamente la clasificación, pues los datos se organizan en áreas correspondientes a grupos con características similares, y finalmente las estrategias comunes de clasificación no son eficaces. Ese efecto llamado "la maldición de la dimensión" puede ser abordado con diferentes métodos, entre estos la reducción de dimensionalidad tomando las componentes principales del grupo de datos usando el truco del *kernel* (KPCA) originalmente propuesto por (Schölkopf et al., 1997).

En principio se toma el método de análisis de componentes principales (PCA), en el que básicamente se hace una transformación euclidia al rotar y trasladar los ejes para alcanzar la mayor variabilidad descendientemente en todas las dimensiones. En la práctica, se trazan planos de modo que las distancias de los puntos a estos sean las mínimas posibles. Las componentes principales corresponden a las primeras dimensiones del hiperplano resultante, en las que se encuentra la mayor variabilidad. Para lograr esto se diagonaliza la matriz de covarianza de los datos  $\mathbf{x}_k \in \mathbf{R}^N$ , con  $k = 1, \dots, \ell$  definida en 3-19. Los datos están centrados en el origen, de modo que  $\sum_{k=1}^{\ell} \mathbf{x}_k = 0$ .

$$\mathbf{C} = \frac{1}{\ell} \sum_{j=1}^{\ell} \mathbf{x}_j \mathbf{x}_j^{\top} \quad (3-19)$$

La diagonalización, en otras palabras, es una descomposición en valores y vectores propios de la matriz  $\mathbf{C}$ , y las proyecciones ortogonales de los puntos en los eigenvectores son las componentes principales.

Ahora, suele ocurrir que la separación entre los datos no es del todo lineal y entonces es necesario hacer una transformación no lineal de los datos a un nuevo espacio de características  $\mathcal{F}$ , como se describe en (3-20). En ese nuevo espacio  $\mathcal{F}$  también es posible hacer el análisis PCA. La transformación se realiza usando *kernels*, que son funciones continuas conocidas del método de las máquinas de vectores de soporte (SVM), que además mejoran el costo computacional, porque el cálculo depende del producto interno de los vectores en el nuevo espacio,

i.e  $\mathbf{k}(\mathbf{x}, \mathbf{x}') = \Phi(\mathbf{x})^\top \cdot \Phi(\mathbf{x}')$ .

$$\Phi : \mathbf{R}^N \rightarrow \mathcal{F}, \quad \mathbf{x} \mapsto \mathbf{X} \quad (3-20)$$

Luego, si en el espacio original el análisis PCA se hacía con la descomposición de  $\lambda \mathbf{x}_k \mathbf{V} = \mathbf{x}_k \mathbf{C} \mathbf{V}$ , en el nuevo espacio de características, equivalentemente se hace la descomposición del sistema 3-21.

$$\lambda (\Phi(\mathbf{x}_k) \cdot \mathbf{V}) = (\Phi(\mathbf{x}_k) \cdot \bar{\mathbf{C}} \mathbf{V}), \quad \forall k = 1, \dots, \ell \quad (3-21)$$

Con  $\bar{\mathbf{C}} = \frac{1}{\ell} \sum_{j=1}^{\ell} \Phi(\mathbf{x}_j) \Phi(\mathbf{x}_j)^\top$ . Luego, el vector propio puede ser expresado como una combinación lineal de los datos transformados:

$$\mathbf{V} = \frac{1}{\ell \lambda} \sum_{i=1}^{\ell} (\Phi(\mathbf{x}_i) \cdot \mathbf{V}) \Phi(\mathbf{x}_i) \quad (3-22a)$$

$$\mathbf{V} = \sum_{i=1}^{\ell} \alpha_i \Phi(\mathbf{x}_i) \quad (3-22b)$$

Ahora, para generar el producto interno de los vectores, se multiplica a ambos lados de 3-22b por  $\Phi(\mathbf{x}_j)$ , y se obtiene:

$$\mathbf{V} \cdot \Phi(\mathbf{x}_j) = \lambda \ell \alpha_j = \sum_{i=1}^{\ell} \alpha_i (\Phi(\mathbf{x}_i) \cdot \Phi(\mathbf{x}_j)) = \sum_{i=1}^{\ell} \alpha_i \mathbf{K}_{ij} \quad (3-23)$$

Recordando que  $\mathbf{K}_{ij} := (\Phi(\mathbf{x}_i) \cdot \Phi(\mathbf{x}_j))$ . Finalmente, expresándolo de forma vectorial y matricial se llega a que el problema de eigenvalores a resolver es:

$$\ell \lambda \boldsymbol{\alpha} = \mathbf{K} \boldsymbol{\alpha} \quad (3-24)$$

De este modo, los valores propios de  $\mathbf{K}$  son proporcionales a los valores propios de  $\bar{\mathbf{C}}$  y la extracción de características se haría con los eigenvalores más grandes.

Como funciones de *kernel* pueden usarse algunos de tipo polinomial, sigmoide o, como en este caso, uno de base radial como el *kernel* gaussiano que se presenta en (3-25).

$$k(\mathbf{x}, \mathbf{y}) = e^{\left(-\frac{\|\mathbf{x}-\mathbf{y}\|^2}{2\sigma^2}\right)} \quad (3-25)$$

## Paso 6: Clasificador bayesiano normal

En la última etapa de un sistema de visión de máquina se encuentra el reconocimiento e interpretación, en la cual se utilizan diversas técnicas. Una de las más clásicas es el clasificador paramétrico supervisado basado en la teoría de decisión de Bayes formulada de forma general en (3-26).

$$P(A|B) = \frac{P(A) P(B|A)}{P(B)} \quad (3-26)$$

Aquí se toma  $A$  como hipótesis y  $B$  como la evidencia. Generalmente, se hacen simplificaciones en el modelo asumiendo que hay independencia entre las características de entrada, de forma tal que se asume que la presencia o ausencia de una característica no afecta a las otras, entonces cada característica contribuye independientemente a la probabilidad del evento  $A$ . A este caso se le llama *clasificador ingenuo*.

Ahora, en términos de clases ( $y_i$ ) y características ( $\mathbf{X}$ ), (3-26) puede ser expresada como en (3-27b).

$$P(y_i|\mathbf{X}) = \frac{P(y_i) P(\mathbf{X}|y_i)}{P(\mathbf{X})} \quad (3-27a)$$

$$P(y_i|\mathbf{x}_1, \dots, \mathbf{x}_n) = \frac{P(y_i) P(\mathbf{x}_1, \dots, \mathbf{x}_n|y_i)}{P(\mathbf{x}_1, \dots, \mathbf{x}_n)} \quad (3-27b)$$

Al asumir la independencia entre las características de entrada, es posible reescribir (3-27b) usando la regla de la cadena, como se presenta en (3-28).

$$P(y_i | \mathbf{x}_1, \dots, \mathbf{x}_n) = \frac{P(y_i) \prod_{j=1}^n P(\mathbf{x}_j | y_i)}{P(\mathbf{x}_1, \dots, \mathbf{x}_n)} \quad (3-28)$$

En la práctica, el denominador de (3-28) permanece constante, y como además no depende de la clase, puede omitirse y queda que la probabilidad de una clase  $y_i$  dadas las características  $\mathbf{X}$  es proporcional a la productoria, como en (3-29).

$$P(y_i | \mathbf{x}_1, \dots, \mathbf{x}_n) \propto P(y_i) \prod_{j=1}^n P(\mathbf{x}_j | y_i) \quad (3-29)$$

Finalmente, de manera intuitiva, la clase por la que se decide el clasificador es aquella que tiene mayor probabilidad, según la expresión (3-30).

$$\hat{y} = \arg \max_{y_i} P(y_i) \prod_{j=1}^n P(\mathbf{x}_j | y_i) \quad (3-30)$$

Ahora, los parámetros del modelo, como las clases a priori y características de las distribuciones de probabilidad, se determinan sobre el conjunto de datos de entrenamiento haciendo estimaciones de máxima verosimilitud. Cuando los datos pueden tomar valores de una función continua, generalmente se asume que siguen una distribución normal, la cual se presenta su versión multivariada en (3-31).

$$\begin{aligned} p(\mathbf{x}_k) &\sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma}) \\ &\sim \frac{1}{(2\pi)^{d/2} |\boldsymbol{\Sigma}|^{1/2}} \exp \left( -\frac{1}{2} (\mathbf{x}_k - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x}_k - \boldsymbol{\mu}) \right) \end{aligned} \quad (3-31)$$

Para hacer la estimación de máxima verosimilitud (MLE) conviene operar (3-31) expresada en funciones monótonamente crecientes como el logaritmo natural y la suma, lo que se denomina *log-likelihood*, como se muestra en (3-32). De esta forma es más fácil maximizar la función y encontrar los parámetros de la distribución.

$$\ell(\boldsymbol{\theta}) = \sum_{k=1}^n -\frac{1}{2} (\mathbf{x}_k - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x}_k - \boldsymbol{\mu}) - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln |\boldsymbol{\Sigma}| \quad (3-32)$$



Los parámetros a encontrar son  $\theta_1 = \boldsymbol{\mu}$  y  $\theta_2 = \boldsymbol{\Sigma}$ , que al hacer la maximización de (3-32) quedan definidos en (3-33a) y (3-33b).

$$\nabla_{\boldsymbol{\theta}} \equiv \begin{bmatrix} \frac{\partial}{\partial \theta_1} \\ \frac{\partial}{\partial \theta_2} \end{bmatrix} = \begin{bmatrix} \frac{\partial}{\partial \boldsymbol{\mu}} \\ \frac{\partial}{\partial \boldsymbol{\Sigma}} \end{bmatrix}$$

$$\nabla_{\boldsymbol{\theta}} \ell(\boldsymbol{\theta}) = 0$$

$$\hat{\theta}_1 = \hat{\boldsymbol{\mu}} = \frac{1}{n} \sum_{k=1}^n \mathbf{x}_k \quad (3-33a)$$

$$\hat{\theta}_2 = \hat{\boldsymbol{\Sigma}} = \frac{1}{n} \sum_{k=1}^n (\mathbf{x}_k - \hat{\boldsymbol{\mu}}) (\mathbf{x}_k - \hat{\boldsymbol{\mu}})^\top \quad (3-33b)$$

Para conformar el clasificador normal bayesiano, en primer lugar se asume que cada clase tiene una distribución normal, de la misma forma que (3-31), y sus parámetros  $\boldsymbol{\mu}$  y  $\boldsymbol{\Sigma}$  dependen de los datos que, en la etapa de entrenamiento, se ha determinado que describen la distribución normal de cada clase. Y entonces (3-31) pasa a ser la probabilidad de  $\mathbf{x}_j$  dada una clase  $y_i$ , con los parámetros (3-34a) y (3-34b).

$$\boldsymbol{\mu}_i = \frac{1}{n_i} \sum_{j=1}^n z_{ij} \mathbf{x}_j \quad (3-34a)$$

$$\boldsymbol{\Sigma}_i = \frac{1}{n_i} \sum_{j=1}^n z_{ij} (\mathbf{x}_j - \boldsymbol{\mu}_i) (\mathbf{x}_j - \boldsymbol{\mu}_i)^\top \quad (3-34b)$$

$$z_{ij} = \begin{cases} 1, & \text{si } \mathbf{x}_j \in y_i \\ 0, & \text{si no} \end{cases}$$

Con estas probabilidades condicionales se combina (3-31) con (3-30), y primero se definen las funciones discriminantes con *log-likelihood*.

$$\begin{aligned} g_i(\mathbf{x}) &= \ln p(\mathbf{x}|y_i) + \ln P(y_i) \\ &= -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_i)^\top \boldsymbol{\Sigma}_i^{-1} (\mathbf{x} - \boldsymbol{\mu}_i) - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln |\boldsymbol{\Sigma}_i| + \ln P(y_i) \end{aligned} \quad (3-35)$$

Finalmente, la función (3-35) se utiliza para decidir la clase a la que pertenecen las características  $\mathbf{x} = x_1, \dots, x_d$  de una muestra dada. La clase de salida nuevamente es la que tenga la mayor probabilidad:

$$\hat{y} = \arg \max_{y_i} g_i(\mathbf{x}) \quad (3-36)$$

## Resultados

A continuación se presentarán algunos detalles en la implementación de los procesamiento presentados en las secciones anteriores y ejemplos de los resultados. Las imágenes del conjunto de entrenamiento y de prueba fueron obtenidas fotografiando la pantalla de un sonómetro marca 01dB, modelo CUBE; un ejemplo se muestra en la figura 3-2.


Figura 3-2.: Ejemplo de una fotografía de la pantalla de un sonómetro 01dB CUBE.



Para el filtro gaussiano se empleó  $\sigma_x = \sigma_y = 1,5$ . Luego, con el fin de simplificar el cálculo del descriptor SIFT, se escala la imagen de un dígito y se rellenan los píxeles faltantes para conformar una imagen de  $32 \times 32$ . Luego, se eligen cuatro puntos clave que corresponden a los centros de cada cuadrante como se presenta en la figura 3-3.

En esos puntos se calcula el descriptor SIFT, no sin previamente haber umbralizado la imagen

Figura 3-3.: Puntos clave para el cálculo del descriptor SIFT de una imagen de un dígito.



redimensionada con el método de Otsu. De forma tal que queda un vector de características con 512 valores para cada muestra. Una breve implementación de este procesamiento se presenta en el código 3.1, que posteriormente será usado en la aplicación desarrollada para automatizar la calibración de sonómetros. Los resultados del procesamiento se pueden ver en la figura 3-4 para tres ejemplos del conjunto de muestras de entrenamiento.

**Código 3.1:** Código para presentar resultados del procesamiento de 3 muestras del conjunto de imágenes entrenamiento.

```

1  import cv2 as cv
2  import matplotlib.pyplot as plt
3  import numpy as np
4
5
6  """
7  Programed by Felipe Maldonado,
8  Universidad Nacional de Colombia, Faculty of Engineering,
9  Department of Electrical and Electronic Engineering.
10 Created on 2022/03.
11 """
12 __autor__ = 'Juan Felipe Maldonado'
13 __version__ = '1.0 Beta'
14
15 path = "Images/Train"
16 img_name = ["2(0).jpg", "5(0).jpg", "7(0).jpg"] # 3 samples just for showing results of processing
17 descriptor = cv.SIFT_create(contrastThreshold=0.02, edgeThreshold=1, sigma=0.01) # Creates a SIFT descriptor
18 # Four key points for computing SIFT descriptor
19 key_points = [cv.KeyPoint(7, 7, 16), cv.KeyPoint(7, 13, 16),
20               cv.KeyPoint(13, 7, 16), cv.KeyPoint(13, 13, 16)]
21 X = []
22 y = []
23 for name in img_name:
24     img = cv.imread(path + "/" + name, cv.IMREAD_GRAYSCALE) # Read image in gray scale
25     img_blur = cv.GaussianBlur(img.copy(), ksize=(0, 0), sigmaX=1.5) # Gaussian filtering
26     mayor_axis = max(img_blur.shape) # The largest axis
27     # Normalize size
28     digit_scaled = cv.resize(img_blur, (0, 0), fx=32 / mayor_axis,
29                               fy=32 / mayor_axis, interpolation=cv.INTER_CUBIC)
30     # Build an image of 32 x 32 pixels with padding
31     if digit_scaled.shape[0] >= digit_scaled.shape[1]:
32         digit_scaled = np.pad(digit_scaled, ((0, 0), ((32 - digit_scaled.shape[1]) // 2,
33             (32 - digit_scaled.shape[1]) // 2)), 'constant')
34     else:
35         digit_scaled = np.pad(digit_scaled, (((32 - digit_scaled.shape[0]) // 2,
36             (32 - digit_scaled.shape[0]) // 2), (0, 0)), 'constant')
37
38     img_bin = cv.threshold(digit_scaled, 0, 255, cv.THRESH_BINARY | cv.THRESH_OTSU)[1] # Otsu binarization
39     # -- SIFT DESCRIPTOR --
40     _, features = descriptor.compute(img_bin, key_points) # Computes SIFT descriptor
41     X.append(features.flatten()) # Add the features vector of the actual training sample
42     y.append(img_name[0]) # Add the class of the actual training sample
43     # -- Plots results --
44     _, axes = plt.subplots(2, 2)

```

```

45  axs[0, 0].imshow(img, cmap='gray')
46  axs[0, 0].set_title('Imagen original')
47  axs[0, 1].imshow(img_blur, cmap='gray')
48  axs[0, 1].set_title('Imagen suavizada')
49  axs[1, 0].imshow(digit_scaled, cmap='gray')
50  axs[1, 0].set_title('Imagen escalada y con padding')
51  axs[1, 1].imshow(img_bin, cmap='gray')
52  axs[1, 1].set_title('Imagen umbralizada con Otsu')
53  plt.show()
54
55  # -- Plots SIFT features by sample --
56  fig = plt.figure()
57  axes = fig.add_subplot(111)
58  axes.set_title('Vectores de características SIFT')
59  axes.scatter(range(len(X[0])), X[0], s=8, c='b', marker='s', label='Muestra de número 2')
60  axes.scatter(range(len(X[1])), X[1], s=8, c='r', marker='o', label='Muestra de número 5')
61  axes.scatter(range(len(X[0])), X[2], s=8, c='g', marker='x', label='Muestra de número 7')
62  axes.grid(visible=True)
63  plt.legend()
64  plt.show()

```

Con las últimas líneas del código 3.1 también se grafican los vectores de características de las tres muestras. El resultado se presenta en la figura 3-5.

Ahora, el código 3.1 se puede ejecutar iterativamente para leer todas las imágenes de un conjunto de entrenamiento con entre 10 y 20 muestras por cada clase. Luego, complementando con el código 3.2 se efectúa la extracción de características y se entrena el clasificador bayesiano normal. La reducción de dimensionalidad se hizo hasta un valor de  $d = 16$ , empíricamente seleccionado según los resultados de clasificación obtenidos.

**Código 3.2:** Código para realizar la extracción de características de los vectores de entrenamiento y para entrenar el clasificador.

```

1  from sklearn.decomposition import KernelPCA
2  from sklearn.naive_bayes import GaussianNB
3
4  kpcaModel = KernelPCA(n_components=16) # KPCA for dimensionality reduction
5  gnbClassifier = GaussianNB() # Gaussian naive Bayes classifier
6
7  X = np.array(X) # Convert training features vector to numpy array
8  y = np.array(y) # Convert training samples labels to numpy array
9
10 # ----- DIMENSIONALITY REDUCTION BY KERNEL PCA ----- #
11 # Fits the model and apply transformation to the features vector
12 X = kpcaModel.fit_transform(X, y)
13 # ----- FITS THE CLASSIFIER -----#
14 gnbClassifier.fit(X, y)

```

Finalmente, para un muestra dada de prueba, se efectúa el mismo procesamiento de la imagen con el código 3.1, y la extracción y clasificación se efectúa con el código 3.3.

**Código 3.3:** Código para realizar la extracción de características de los vectores de prueba y para realizar la clasificación

```

1  X = np.array(X) # Convert test sample features vector to numpy array
2  # ----- DIMENSIONALITY REDUCTION BY KERNEL PCA ----- #
3  X = kpcaModel.transform(X)
4  # ----- CLASSIFY -----#

```

Figura 3-4.: Resultados de procesamiento para tres muestras del conjunto de entrenamiento.





Figura 3-5.: Vectores de características de las tres muestras de entrenamiento procesadas.



```
5 y_hat = gnbClassifier.predict(X)
6
```

La precisión del clasificador se puede medir fácilmente con una matriz de confusión, en la que directamente se identifican los falsos y verdaderos positivos. La matriz de confusión se genera rápidamente con el código 3.4, y el resultado se muestra en la figura 3-6.


**Código 3.4:** Código para generar la matriz de confusión del clasificador bayesiano normal.

```
1 from sklearn.metrics import confusion_matrix, ConfusionMatrixDisplay
2
3 # ----- CLASSIFICATION ACCURACY -----
4 cm = confusion_matrix(y_hat, y_test, labels=gnbClassifier.classes_)
5 disp = ConfusionMatrixDisplay(confusion_matrix=cm, display_labels=gnbClassifier.classes_)
6 disp.plot()
7 plt.show()
```

### 3.1. Discusión

Los resultados obtenidos demuestran un funcionamiento satisfactorio en general, tanto del procesamiento de las imágenes como del clasificador. Aunque evidentemente es un método simplificado, resulta ser eficaz y eficiente, pues cumple con el objetivo de reconocimiento de caracteres empleando pocos recursos computacionales y cortos tiempos de entrenamiento del

Figura 3-6.: Matriz de confusión del clasificador bayesiano propuesto.



clasificador y del procesamiento de las imágenes, lo que permite que el método sea empleado en ordenadores con baja capacidad de procesamiento y en aplicaciones de funcionamiento en tiempo real, como se pretende en este proyecto. Además, aunque el clasificador bayesiano es de las técnicas más sencillas de aprendizaje de máquina, tiene un desempeño aceptable en muchas aplicaciones reales y no requiere una base de datos de entrenamiento demasiado extensa (scikit Developers, 2022).

Particularmente, cada una de las etapas de procesamiento resulta ser crucial en el resultado. Por ejemplo la etapa de suavizado permite eliminar variaciones de intensidad de alta frecuencia como las irregularidades en el relleno de los dígitos debidas a la construcción de la pantalla del sonómetro, como en pantallas led, por ejemplo. Sin este suavizado es posible que en la umbralización no se obtengan segmentos homogéneos que representen correctamente un dígito. La binarización de la imagen, buscando el umbral con el método de Otsu, garantiza que se haga una discriminación correcta entre el fondo de la pantalla y el dígito, en función de la distribución de las intensidades de píxeles, esto aporta confiabilidad en la segmentación independientemente de la forma y color de los números. Y el descriptor SIFT es bien conocido por su robustez frente a transformaciones afines o cambios en el punto de vista 3D, lo que contribuye a asegurar la eficacia en la medición de características aún cuando hay variaciones en las condiciones normales de adquisición de las imágenes; además, que esté basado en la dirección de los gradientes, lo hace adecuado para cuantizar de algún modo las formas de los contornos de los dígitos.

No obstante, a pesar de la eficiencia y simplicidad del clasificador bayesiano normal, lo cierto es que el resultado de clasificación es bastante sensible si se obtienen resultados erróneos en el

procesamiento anterior. Por ejemplo, por efectos de bajo contraste o desenfokes que deforman los segmentos, podrían haber confusiones en la clasificación, principalmente en clases que son muy similares en sus características, como entre el 6 y el 8 o entre el 9 y el 8, pues al deformarse el segmento a causa de esos ruidos, el 6 o el 9 cierran el trazo faltante y se asemejan a un 8. Sin embargo, en los ensayos del sistema de reconocimiento se pudo comprobar que esto ocurre cuando la posición o configuración de la cámara no es la adecuada y los efectos del desenfoco o la iluminación son más pronunciados. Cuando las condiciones de captura de la imagen son controladas, la eficacia del clasificador es de un 100 %, como se puede notar en la matriz de confusión de la figura 3-6.



## **4. Implementación de los procedimientos de calibración**

### **4.1. Automatización de la calibración periódica de calibradores acústicos**

#### **4.1.1. GRAFCET descriptivo del proceso**

#### **4.1.2. Implementación en Python**

Arquitectura de software

### **4.2. Automatización de la calibración periódica de sonómetros**

#### **4.2.1. Implementación en Python**

Arquitectura de software



## **5. Modelamiento de incertidumbre de medición en la calibración periódica de sonómetros**

### **5.1. Cadenas de Markov de tiempo discreto**

#### **5.1.1. Matriz de probabilidades de transición**

#### **5.1.2. Valor esperado**

#### **5.1.3. Probabilidad estacionaria**

### **5.2. Incertidumbre de medición**

Definición matemática del mesurando

#### **5.2.1. Incertidumbre tipo A**

#### **5.2.2. Incertidumbre tipo B**

#### **5.2.3. Incertidumbre típica combinada**

#### **5.2.4. Grados efectivos de libertad, factor de cobertura e incertidumbre expandida**

### **5.3. Algoritmo para creación de estados y tasas de transición de la cadena de Markov**

#### **5.3.1. Implementación de la cadena de Markov en Python**

## **6. Conclusiones y recomendaciones**

### **6.1. Conclusiones**

Las conclusiones constituyen un capítulo independiente y presentan, en forma lógica, los resultados de la tesis o trabajo de investigación. Las conclusiones deben ser la respuesta a los objetivos o propósitos planteados. Se deben titular con la palabra conclusiones en el mismo formato de los títulos de los capítulos anteriores (Títulos primer nivel), precedida por el numeral correspondiente (según la presente plantilla).

### **6.2. Recomendaciones**

Se presentan como una serie de aspectos que se podrían realizar en un futuro para emprender investigaciones similares o fortalecer la investigación realizada. Deben contemplar las perspectivas de la investigación, las cuales son sugerencias, proyecciones o alternativas que se presentan para modificar, cambiar o incidir sobre una situación específica o una problemática encontrada. Pueden presentarse como un texto con características argumentativas, resultado de una reflexión acerca de la tesis o trabajo de investigación.

## **A. Anexo: Certificado de calibración de calibrador acústico**

## **B. Anexo: Certificado de calibración de sonómetro**

# Bibliografía

- Brüel & Kjær (2016). *Instruction Manual, Hand-held Analyzer Types 2250, 2250-L and 2270*. Brüel & Kjær Sound & Vibration Measurement A/S, Nærum, Denmark.
- Brüel & Kjær (2021). What is a Sound Level Meter? <https://www.bksv.com/en/knowledge/blog/sound/what-is-a-sound-level-meter>. En línea: consultada en marzo del 2022.
- Fletcher, H. and Munson, W. A. (1933). Loudness, Its Definition, Measurement and Calculation. *The Journal of the Acoustical Society of America*, 5(2):82–108.
- IEC technical committee 29: Electroacoustics (2013). Electroacoustics – sound level meters - part 1: Specifications. Standard IEC 61672-1:2013, International Electrotechnical Commission, Geneva, Switzerland.
- IEC technical committee 29: Electroacoustics (2017). Electroacoustics – sound calibrators. Standard IEC 60942:2017, International Electrotechnical Commission, Geneva, Switzerland.
- Lowe, D. G. (2004). Distinctive image features from scale-invariant keypoints. *International Journal of Computer Vision*, 60(2):91–110.
- Otsu, N. (1979). A Threshold Selection Method from Gray-Level Histograms. *IEEE Trans Syst Man Cybern*, SMC-9(1):62–66.
- Richard, S. (2011). *Algorithms and Applications: Computer vision*. Springer, London, 2 edition.
- Schölkopf, B., Smola, A., and Müller, K. R. (1997). *Kernel principal component analysis*, volume 1327. Springer, Alemania.
- Scikit-learn developers (2022). 1.9. Naive Bayes. [https://scikit-learn.org/stable/modules/naive\\_bayes.html#gaussian-naive-bayes](https://scikit-learn.org/stable/modules/naive_bayes.html#gaussian-naive-bayes). En línea: consultada en marzo del 2022.