



Desarrollo de un procedimiento de calibración de sonómetros y calibradores acústicos de conformidad con las normas IEC 61672-3 e IEC 60942

Juan Felipe Maldonado Pedraza

Universidad Nacional de Colombia
Facultad de Ingeniería, Departamento de Ingeniería Eléctrica y Electrónica
Bogotá, Colombia
2021

Desarrollo de un procedimiento de calibración de sonómetros y calibradores acústicos de conformidad con las normas IEC 61672-3 e IEC 60942

Juan Felipe Maldonado Pedraza

Trabajo de grado presentado como requisito parcial para optar al título de:
Magister en Automatización Industrial

Director:
Ph.D. Leonardo Enrique Bermeo Clavijo

Línea de investigación:
Automatización en procesos de metrología
Universidad Nacional de Colombia
Facultad de Ingeniería
Bogotá, Colombia
2022

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Lorem ipsum dolor sit amet, consectetur adipiscing elit.

Agradecimientos

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Resumen

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Palabras clave: Calibración, metrología, sonómetros, calibradores acústicos, automatización, visión de máquina, cadena de Markov

Abstract

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Keywords: Calibration, metrology, sound level meters, acoustic calibrators, automation, computer vision, Markov chain

Índice general

Agradecimientos	VII
Resumen	IX
Lista de figuras	XIII
Lista de tablas	1
1. Introducción	2
1.1. Planteamiento del problema	2
1.2. Objetivos	3
1.2.1. General	3
1.2.2. Específicos	3
1.2.3. Alcance de los objetivos	3
1.2.4. Antecedentes	4
2. Metodología e instrumentación	5
2.1. Instrumentos bajo calibración	5
2.1.1. Calibradores acústicos	5
2.1.2. Sonómetros integradores	7
2.2. Métodos normalizados	10
2.2.1. Descripción general de la calibración periódica de calibradores acústicos de acuerdo con la IEC 60942:2017	11
2.2.2. Descripción general de las pruebas periódicas seleccionadas de acuerdo con la IEC 61672-3:2013	12
2.3. Instrumentación	17
2.3.1. Patrones e instrumentos para la calibración periódica de calibradores acústicos	17
2.3.2. Patrones e instrumentos para la calibración periódica de sonómetros	17
2.3.3. Comandos SCPI	17
3. Sistema de reconocimiento de imágenes para el valor de medición	18

4. Implementación de los procedimientos de calibración	36
4.1. Automatización de la calibración periódica de calibradores acústicos	36
4.1.1. GRAFCET descriptivo del proceso	36
4.1.2. Implementación en Python	36
4.2. Automatización de la calibración periódica de sonómetros	36
4.2.1. Implementación en Python	36
5. Modelamiento de incertidumbre de medición en la calibración periódica de sonómetros	37
5.1. Cadenas de Markov de tiempo discreto	38
5.1.1. Matriz de probabilidades de transición	38
5.1.2. Valor esperado	38
5.1.3. Probabilidad estacionaria	38
5.2. Incertidumbre de medición	38
5.2.1. Incertidumbre tipo A	38
5.2.2. Incertidumbre tipo B	38
5.2.3. Incertidumbre típica combinada	38
5.2.4. Grados efectivos de libertad, factor de cobertura e incertidumbre expandida	38
5.3. Algoritmo para creación de estados y tasas de transición de la cadena de Markov	38
5.3.1. Implementación de la cadena de Markov en Python	38
6. Conclusiones y recomendaciones	39
6.1. Conclusiones	39
6.2. Recomendaciones	39
A. Anexo: Códigos de Python	40
B. Anexo: Certificado de calibración de calibrador acústico	42
C. Anexo: Certificado de calibración de sonómetro	43
Bibliografía	44

Índice de figuras

2-1. Calibrador acústico multifunción Brüel & Kjær 4226.	6
2-2. Calibrador acústico Brüel & Kjær 4231 acoplado al micrófono de un sonómetro Brüel & Kjær 2250.	6
2-3. Configuraciones de <i>hardware</i> del sonómetro Brüel & Kjær 2250.	8
2-4. Gráfico de las ponderaciones frecuenciales A , C y Z	9
2-5. Gráfico de las respuestas en el tiempo de las ponderaciones temporales <i>fast</i> , <i>slow</i> e <i>impulse</i>	9
2-6. Diagrama de flujo general de la calibración periódica de calibradores acústicos.	13
2-7. Diagrama de bloques del proceso de medición en la calibración periódica de sonómetros de acuerdo con la IEC 61672-3:2013.	13
3-1. Comparación de los modos de <i>padding</i> : <i>zero</i> y <i>mirror</i>	20
3-2. Ejemplo de una fotografía de la pantalla de un sonómetro 01dB CUBE.	30
3-3. Puntos clave para el cálculo del descriptor SIFT de una imagen de un dígito.	30
3-4. Resultados de procesamiento de una muestra de entrenamiento del número 5.	31
3-5. Vector de características de la muestra de entrenamiento procesadas.	32
3-6. Comparación del procesamiento de imágenes tomadas en condiciones controladas y no controladas.	33
3-7. Matriz de confusión del clasificador bayesiano propuesto para el conjunto de imágenes tomadas en condiciones no controladas.	34
3-8. Matriz de confusión del clasificador bayesiano propuesto para el conjunto de imágenes tomadas en condiciones controladas.	34

Índice de cuadros

1. Introducción

1.1. Planteamiento del problema

En la actualidad, la creciente contaminación acústica amerita la implementación de redes de monitoreo continuo de ruido o mediciones puntuales empleando instrumentos adecuados como son los sonómetros con el propósito de cuantizar los niveles de ruido ambiental, de emisión de ruido de fuentes sonoras específicas y de exposición sonora, para luego comparar con los niveles máximos permitidos por la normativa relacionada nacional e internacional y tomar decisiones al respecto. Para garantizar la confiabilidad de tales mediciones o asegurar la validez de sus resultados, en Colombia, entidades como el Instituto de Hidrología, Meteorología y Estudios Ambientales (IDEAM) exigen que las organizaciones que prestan estos servicios cuenten con sonómetros calibrados periódicamente bajo el estándar internacional IEC 61672-3:2013. por parte de un organismo de evaluación de la conformidad (OEC), en este caso un laboratorio de calibración acreditado por el Organismo Nacional de Acreditación de Colombia (ONAC) bajo el estándar ISO 17025, con el fin de verificar que estos instrumentos continúan cumpliendo las especificaciones normalizadas según su clase. La norma IEC 61672-3 describe una serie de pruebas acústicas y eléctricas que se realizan a sonómetros integradores clase 1 y 2, cuyo propósito es comprobar el funcionamiento del sonómetro en: 1) La sensibilidad de su micrófono (para lo cual se usa un calibrador acústico calibrado previamente y que esté en conformidad con las especificaciones de la IEC 60942). 2) Las redes de ponderación frecuencial A, C y Z. 3) En las ponderaciones temporales F (*fast*) y S (*slow*). 4) En el rango lineal. 5) En la medición de niveles promediados en el tiempo, niveles de exposición sonora y niveles pico. 6) En la indicación de sobrecarga. 7) En la exposición a largos periodos de medición y a niveles de sonido elevados. Dicha comprobación se hace comparando con las especificaciones definidas en la norma IEC 61672-1:2013.

1.2. Objetivos

1.2.1. General

Desarrollar un sistema de calibración periódica de sonómetros y calibradores acústicos de conformidad con las normas IEC 61672-3:2013 e IEC 60942:2017.

1.2.2. Específicos

1. Formular un modelo en GRAFCET como base para el desarrollo de un sistema de calibración periódica de calibradores acústicos.
2. Implementar las secuencias de comando (a través de bus GPIB) para configurar parámetros de señal y, a su vez, recibir resultados de los instrumentos de medición.
3. Desarrollar un método de reconocimiento de imágenes para detectar los niveles instantáneos ponderados en tiempo y en frecuencia desde la pantalla del sonómetro.
4. Desarrollar un método que permita tener en cuenta la variabilidad de los niveles en pantalla instantáneos ponderados en tiempo y en frecuencia del objetivo 3, (mediante mediciones de larga duración), para la estimación del mesurando y de la incertidumbre de medición.

1.2.3. Alcance de los objetivos

El sistema de calibración se implementará para ejecutar las pruebas de calibración de los numerales 9.3 (apoyado en la IEC 60942), 13, 14 y 16 de la IEC 61672-3. Los indicadores de interés serán los niveles instantáneos con ponderación temporal (*slow* o *fast*) y ponderación frecuencial (*A*, *C*, o *Z*), i.e. $L_{AF}, L_{AS}, L_{CF}, L_{CS}, L_{ZF}$ o L_{ZS} , dependiendo de la prueba y según estén disponibles en el sonómetro sujetos al periodo de actualización de la pantalla del sonómetro. El sistema tendrá en cuenta el modelo del proceso estocástico para la estimación de incertidumbre expandida de medición.

1.2.4. Antecedentes

Sistemas de calibración comerciales desarrollados por fabricantes

Sistemas de calibración desarrollados por otras organizaciones

2. Metodología e instrumentación

En este capítulo se hace una descripción de los instrumentos bajo calibración (calibradores acústicos y sonómetros), seguida de un resumen de los lineamientos de las normas internacionales para las calibraciones periódicas, incluyendo expresiones matemáticas para el cálculo de los voltajes de prueba y otras consideraciones prácticas para los ensayos. Luego se presentan los patrones y otros instrumentos importantes necesarios para la calibración junto con los esquemas de interconexión. Finalmente se explican brevemente los comandos para el control remoto de los instrumentos de medición.

2.1. Instrumentos bajo calibración

2.1.1. Calibradores acústicos

De acuerdo con la normativa internacional, un calibrador acústico es un dispositivo diseñado para producir uno o más niveles de presión sonora conocidos (en dB referenciados a $20 \mu\text{Pa}$) a una o más frecuencias especificadas (en Hz) cuando se acopla a modelos específicos de micrófono en configuraciones específicas ([IEC-TC29, 2017](#)). Normalmente, la señal senoidal generada por algún transductor, como un altavoz o, en el caso de los pistófonos, un pistón mecánico cuyo movimiento genera en la cavidad una velocidad de volumen conocida. Como ejemplo, en la figura 2-1 se muestra un calibrador acústico multifunción usado como referencia en muchos laboratorios: el Brüel & Kjær 4226, que es capaz de generar 94 dB, 104 dB y 114 dB en las frecuencias de octava desde 31,5 Hz hasta 16 kHz, más la frecuencia de 12,5 Hz.

Generalmente los calibradores acústicos son empleados para determinar la sensibilidad en campo de presión (típicamente en mV/Pa o en dB referenciados a 1 V) de modelos especificados de micrófonos en configuraciones dadas, pero también es utilizado para verificar o ajustar la sensibilidad de algún dispositivo o sistema de medición acústica. Un ejemplo de calibrador acoplado para comprobar la indicación de un sonómetro se muestra en la siguiente figura.

La norma IEC 60942:2017 establece una clasificación de los calibradores según sus especifica-

ciones (límites de aceptación), de la más a la menos restrictiva: Clase LS (*laboratory standard*), clase 1 o clase 2. La comprobación de que cierto modelo de calibrador cumple con todas las especificaciones normalizadas según su clase la realiza una organización independiente acreditada para hacer pruebas de aprobación de modelo de acuerdo con los lineamientos del Anexo A de la IEC 60942:2017. Pero además, un usuario de un calibrador acústico debería calibrar periódicamente su instrumento para garantizar la trazabilidad a los estándares nacionales y la confiabilidad de sus resultados. Esta calibración periódica es llevada a cabo por organismos evaluadores de la conformidad acreditados en ISO 17025 para realizar los ensayos periódicos de acuerdo con el Anexo B de la IEC 60942:2017. Los ensayos periódicos son el objeto de automatización en este proyecto y se describen en la sección 2.2.1.

Figura 2-1.: Calibrador acústico multifunción Brüel & Kjær 4226.



Tomado de <https://www.transcat.com/bruel-kjaer-4226-acoustic-calibrator-94-104-and-114db-used>

Figura 2-2.: Calibrador acústico Brüel & Kjær 4231 acoplado al micrófono de un sonómetro Brüel & Kjær 2250.




Tomado de <https://www.bksv.com/en/knowledge/blog/sound/getting-started-sound-level-meter>

2.1.2. Sonómetros integradores

Brüel & Kjær, uno de los fabricantes más prominentes de sonómetros define consistentemente los conceptos básicos sobre dichos instrumentos en uno de sus artículos (B&K, 2021). Básicamente, un sonómetro es un instrumento diseñado para medir niveles de sonido de una forma estandarizada; su respuesta al sonido se asemeja a la del oído humano y proporciona medidas de niveles de presión sonora objetivas y reproducibles. Generalmente, los sonómetros son empleados en el monitoreo de ruido proveniente de diversas fuentes sonoras, como plantas industriales, tráfico rodado, aeronáutico o ferroviario, conciertos, etc. Como se puede ver en la figura 2-3, un sonómetro típico consta de un micrófono, un preamplificador, una unidad de procesamiento de señal (interna) y una pantalla. Regularmente el preamplificador hace parte del cuerpo del sonómetro, pero no siempre es el caso; un sonómetro podría estar provisto de cables de extensión que separen el preamplificador de la unidad de procesamiento.

En cuanto al flujo de señal, el micrófono es un transductor electroacústico que transforma la señal acústica en una señal eléctrica. La mayoría de los micrófonos empleados en mediciones acústicas son de condensador, y gracias a su construcción es el mejor tipo para garantizar precisión, estabilidad y confiabilidad en los resultados. No obstante, la señal eléctrica proporcionada por un micrófono es de baja amplitud (aún con micrófonos de alta gama cuya sensibilidad se encuentra típicamente en el orden de los 50 mV/Pa , por lo que se requiere una amplificación para que la unidad de procesamiento manipule la señal en un nivel adecuado, este es el objetivo del preamplificador. Luego, en la unidad de procesamiento se ejecutan diferentes cálculos a partir de la señal, los mínimos requeridos por la norma internacional IEC 61672-1:2013 y utilizados en este proyecto son:

- **Ponderación frecuencial:** Diferencia, como una función especificada de la frecuencia, entre el nivel de la señal ponderada en frecuencia indicado en el dispositivo de presentación de resultados y el nivel correspondiente de una señal de entrada sinusoidal de amplitud constante (IEC-TC29, 2013). Las ponderaciones frecuenciales estandarizadas A , C , o Z , para las bandas de tercio de octavas están definidas en la Tabla 3 de la IEC 61672-1:2013. En concreto, cada una de estas ponderaciones modifican la respuesta del sonómetro frente a diferentes frecuencias de sonido. Por ejemplo, la ponderación A asemeja la respuesta en frecuencia al comportamiento del oído humano en un rango medio de niveles, tomando como referencia la curva de igual sonoridad de 40 dB (Fletcher and Munson, 1933), por tal motivo es el más empleado en ruido ambiental y ocupacional. Pero el oído humano no tiene un comportamiento lineal, y la percepción del sonido varía con el nivel, la ponderación C está basada en la curva de igual sonoridad de 100 dB, por eso esta es empleada en la evaluación de niveles pico de sonidos altos. Finalmente, la ponderación zero (Z) es completamente plana en todo el rango de frecuencias (sin tener en cuenta la respuesta del micrófono). En la figura 2-4 se pueden ver gráficamente las ponderaciones


Figura 2-4.: Gráfico de las ponderaciones frecuenciales A , C y Z .

Tomado de (B&K, 2021).

tanto, tal como lo define la norma, para una señal con ponderación X , el nivel de sonido con ponderación temporal Y será:

$$L_{XY}(t) = 10 \log \left(\frac{\frac{1}{\tau_Y} \int_{-\infty}^t p_X^2(\xi) e^{-(t-\xi)/\tau_Y} d\xi}{p_0^2} \right) \text{ dB} \quad (2-1)$$

Donde τ_Y es la constante de tiempo en segundos de la ponderación temporal, ξ es una variable ficticia del tiempo de integración desde un instante de tiempo en el pasado ($-\infty$) hasta el instante de observación t , $p_X(\xi)$ es la señal de presión acústica instantánea con ponderación frecuencial X , y p_0 es el valor de referencia de $20 \mu\text{Pa}$. Una comparación entre las respuestas en el tiempo de cada ponderación temporal se muestra en la siguiente figura.

Figura 2-5.: Gráfico de las respuestas en el tiempo de las ponderaciones temporales *fast*, *slow* e *impulse*.

Tomado de (B&K, 2021).

Consecuentemente, un nivel de sonido, objeto de evaluación en las pruebas aquí implementadas puede ser L_{AF} , L_{AS} , L_{CF} , L_{CS} , L_{ZF} o L_{ZS} para las ponderaciones frecuenciales A , C , o Z y para las ponderaciones temporales *fast* o *slow*. El resultado de la medición de nivel de sonido es mostrado directamente en la pantalla del sonómetro o alguna otra herramienta de visualización como una interfaz web. En algunos sonómetros según su tecnología y disposiciones del fabricante, el resultado de medición es enviado vía serial o en forma de una señal DC o AC de amplitud proporcional al nivel de sonido.

La norma IEC 61672-1:2013 establece una clasificación de los sonómetros según sus especificaciones: clase 1 o clase 2. La comprobación de que cierto modelo de sonómetro cumple con todas las especificaciones normalizadas según su clase la realiza una organización independiente acreditada para hacer pruebas de aprobación de modelo de acuerdo con los lineamientos de la IEC 61672-2:2013. Pero también un usuario de un sonómetro debería calibrar periódicamente su instrumento para garantizar la trazabilidad a los estándares nacionales y la confiabilidad de sus resultados. Esta calibración periódica es llevada a cabo por organismos evaluadores de la conformidad acreditados en ISO 17025 para realizar los ensayos periódicos de acuerdo con la IEC 61672-3:2013. Los ensayos periódicos son el objeto de automatización en este proyecto y se describen en la sección 2.2.2.

Adicionalmente, la sensibilidad del transductor (micrófono) y la respuesta de los circuitos electrónicos puede variar con el paso del tiempo presentando una pequeñas derivas o también pueden verse afectadas por las condiciones ambientales como la temperatura y la humedad. Por esto, es una buena práctica verificar regularmente la sensibilidad del sonómetro, preferiblemente antes y después de cada campaña de medición. De este modo el sonómetro será ajustado a un nivel de referencia conocido emitido por un calibrador acústico cuyo nivel tenga trazabilidad metrológica.

2.2. Métodos normalizados

Las especificaciones y metodología de calibración de instrumentación acústica y de vibraciones son normalizadas por el comité técnico 29 de la Comisión Electrotécnica Internacional (IEC) en colaboración con la Organización Internacional de Metrología Legal (OIML). A continuación se hace una descripción que resume el proceso de calibración periódica de calibradores acústicos y sonómetros, dando especial enfoque a los pasos operativos más que a las disposiciones preliminares o generales de las normas.

2.2.1. Descripción general de la calibración periódica de calibradores acústicos de acuerdo con la IEC 60942:2017

Tal como se describe en el Anexo B de la IEC 60942:2017, el calibrador acústico o pistófono con todos sus accesorios necesarios (como adoptadores o barómetro) debe ser entregado junto con el manual de instrucciones, si este es requerido por el laboratorio de calibración. Luego, se hace una inspección visual del calibrador acústico verificando que todos los controles están funcionando y que la fuente de alimentación está operando dentro de los límites especificados en el manual de instrucciones. En seguida se toman en cuenta o se realizan las siguientes secciones.

Orientación para los ensayos, si en el manual de instrucciones se especifica alguna orientación del calibrador acústico, esta debe ser la utilizada en la calibración periódica.

Ruido ambiental, para evitar que el ruido ambiental afecte las mediciones, las pruebas sólo se realizan si el nivel de presión sonora con el calibrador acoplado al micrófono, pero con el calibrador apagado, es por lo menos 30 dB por debajo del nivel especificado que se está midiendo.

Influencia de las condiciones ambientales, cuando es apropiado, la información suministrada en el manual de instrucciones sobre la influencia de la presión estática debe ser aplicada para corregir el nivel de presión medido a la presión estática de referencia.

Nivel de presión sonora, después de acoplar el calibrador acústico al micrófono, se debe dejar el tiempo de estabilización indicado en el manual de instrucciones, luego, el nivel de presión sonora generado por el calibrador debe ser medido como un promedio durante un periodo de entre 20 s y 25 s de operación.

Para medir el nivel de presión sonora hay propuestos dos métodos en la norma internacional, usando un micrófono de referencia o usando un calibrador acústico de referencia para comparación. En este proyecto se utiliza el segundo, en el que el nivel del calibrador bajo prueba es determinado por comparación contra el nivel generado por un calibrador acústico calibrado cuya trazabilidad metrológica esté establecida.

El nivel de presión sonora debe ser medido al menos tres veces, cada vez acoplando el micrófono y el calibrador acústico antes de la medición y desacoplándolo después. En cada nuevo acoplamiento se debe rotar el micrófono sobre su eje. La diferencia absoluta entre el nivel medido medio y el nivel especificado no debe exceder los límites establecidos en la Tabla 2 de la IEC 60942:2017 según la clase del calibrador y la frecuencia medida. La medición de nivel de presión sonora debe ser repetida para cada combinación de nivel y frecuencia que indique el manual de instrucciones que cumple con las especificaciones de la norma.

Frecuencia, debe ser medida con el calibrador acoplado al micrófono como un promedio duran-

te un periodo de entre 20 s y 25 s de operación, para cada frecuencia disponible en el calibrador de la cual se indique en el manual que cumple con las especificaciones de la norma. El valor absoluto de la diferencia porcentual a cada frecuencia medida y la correspondiente frecuencia especificada no debe exceder los límites establecidos en la Tabla 4 de la IEC 60942:2017 según la clase del calibrador.

Distorsión armónica total más ruido (THD+N), la distorsión de la señal generada por el calibrador debe medirse en un ancho de banda de 22,4 Hz a 22,4 kHz, como un promedio durante un periodo de entre 20 s y 25 s, en los niveles máximo y mínimos disponibles a cada frecuencia de los que se indique en el manual que cumple con las especificaciones de la norma. La THD+N puede ser medida utilizando un filtro de rechazo (medidor de factor de distorsión) o un analizador FFT. La THD+N medida no debe exceder los límites establecidos en la Tabla 7 de la IEC 60942:2017 según la clase del calibrador. Es obligatorio que la magnitud medida sea no sólo distorsión armónica total, sino distorsión armónica total *más* ruido, reportada en %.

En la figura 2-6 se presenta un diagrama de bloques que describe en general el proceso de calibración de calibradores acústicos. La automatización de este proceso es el tema de la sección 4.1.

2.2.2. Descripción general de las pruebas periódicas seleccionadas de acuerdo con la IEC 61672-3:2013

Tal como se describe en la IEC 61672-3:2013, el sonómetro con todos sus accesorios necesarios (como preamplificador, micrófono, cable de extensión o adaptador de impedancia) debe ser entregado junto con el manual de instrucciones, si este es requerido por el laboratorio de calibración. Toda la información necesaria para los ensayos periódicos debe estar disponible, como correcciones de campo libre, rangos de medición, niveles de referencia, etc. Se debe contar con un calibrador acústico conforme con las especificaciones de la IEC 60942:2017 según su clase, ya sea suministrado por el cliente o por el laboratorio.

Luego, se hace una inspección preliminar del sonómetro y todos sus accesorios, verificando que todos los controles están funcionando, que la pantalla está en buen estado, que no halla acumulación de material extraño en la rejilla o membrana del micrófono y que otros elementos esenciales estén en un funcionamiento adecuado. Después se verifica que la fuente de alimentación está operando dentro de los límites especificados en el manual de instrucciones. La fuente de alimentación será verificada nuevamente después de los ensayos con señales acústicas y después de los ensayos con señales eléctricas. En seguida se procede con las pruebas presentadas en la figura 2-7.

Figura 2-6.: Diagrama de flujo general de la calibración periódica de calibradores acústicos.

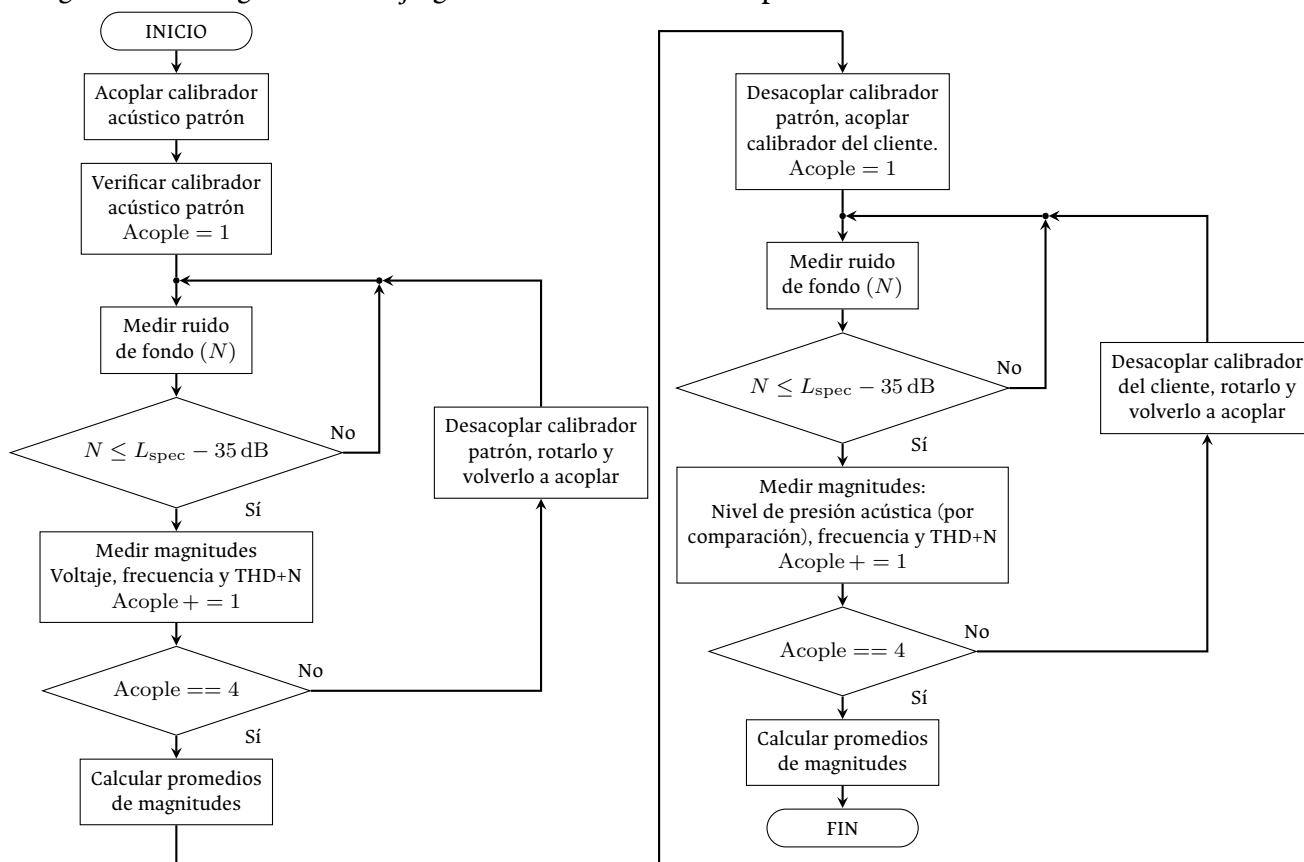
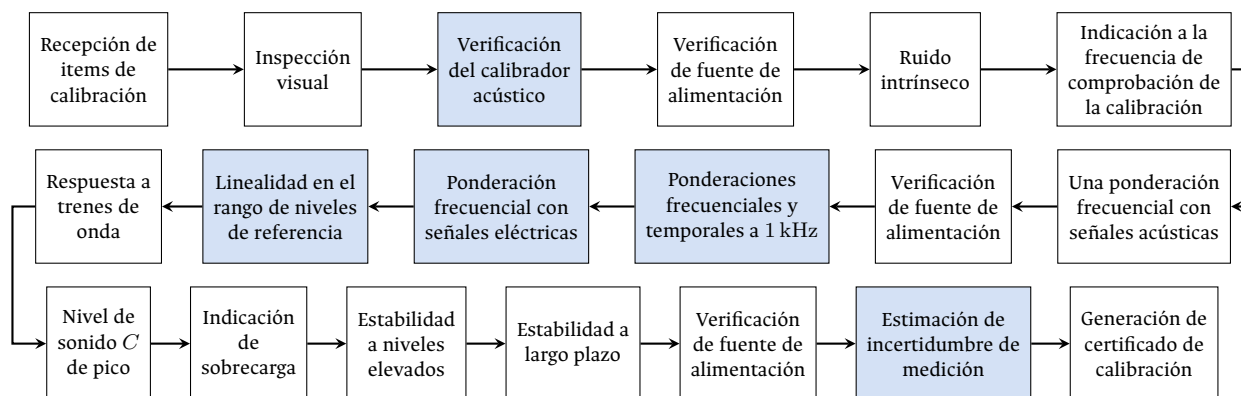


Figura 2-7.: Diagrama de bloques del proceso de medición en la calibración periódica de sonómetros de acuerdo con la IEC 61672-3:2013.



De los bloques de la figura 2-7, los resaltados en azul son los procesos que, en alguna medida, son objeto de automatización en este proyecto. A continuación, se detallan las pruebas que serán efectuadas. Para todas las pruebas eléctricas se emplea el dispositivo de entrada (acoplador de impedancia) recomendado por el fabricante del sonómetro o uno que tenga una capacitancia

similar que emule adecuadamente la carga del micrófono en el preamplificador.

Indicación a la frecuencia de comprobación de la calibración

El calibrador acústico entregado por el cliente o proporcionado por el laboratorio se acopla al micrófono del sonómetro, y, si es necesario, se ajusta el sonómetro para indicar el nivel de presión acústica requerido en las condiciones ambientales en las que se realizan los ensayos. Las indicaciones antes y después del ajuste deben registrarse. Se debe tomar en cuenta el efecto de la presión estática sobre el calibrador acústico empleado. Este calibrador ya debió haber sido verificado previamente con el procedimiento descrito en 2.2.1.

Después de haber ajustado el sonómetro en respuesta al nivel generado por el calibrador, un paso necesario antes de continuar con las otras pruebas es determinar el voltaje que produce una indicación del nivel de referencia, pues este es el voltaje a partir del cual se calculan los voltajes correspondientes a los niveles de señal en las demás pruebas. Ese voltaje de referencia es el voltaje en la “mitad” de un intervalo de voltajes que producen todos una misma indicación del nivel de referencia. La siguiente ecuación es empleada para determinar el voltaje de referencia:

$$v_{\text{ref}} = 10^{\left(\frac{L_{v,l} + (L_{v,u} - L_{v,l})/2}{20} \right)}. \quad (2-2)$$

Donde v_{ref} es el voltaje medio en una escala logarítmica que produce una indicación del nivel de referencia, $L_{v,l}$ es el nivel de voltaje inferior del intervalo que produce una indicación del nivel de referencia, y $L_{v,u}$ el nivel de voltaje superior. Los niveles de voltaje son referenciados a 1 V.

Ponderaciones frecuenciales y temporales a 1 kHz

Se utiliza una señal eléctrica continua de 1 kHz con una amplitud tal que produzca una indicación del nivel de referencia en el sonómetro (i.e. v_{ref}) y se siguen los pasos a continuación:

- Registrar el nivel indicado en las ponderaciones frecuenciales A , C y Z , según estén disponibles, con el sonómetro ajustado en ponderación temporal F o nivel promediado en el tiempo¹; i.e. L_{AF} , L_{CF} , L_{ZF} , L_{Aeq} , L_{Ceq} o L_{Zeq} .
- Registrar el nivel indicado en las ponderaciones temporales F y S , y el nivel promedia-

¹Como en este trabajo se busca reconocer el resultado instantáneo mostrado en pantalla, el nivel elegido preferiblemente sería que tiene ponderación temporal F .

do en el tiempo², según estén disponibles, con el sonómetro ajustado en ponderación frecuencial A ; i.e. L_{AF} , L_{AS} o L_{Aeq} .

- Calcular las desviaciones de los niveles ponderados en frecuencia C y Z respecto al ponderado en frecuencia A del paso 1. Estas desviaciones no deben superar los límites de aceptación de $\pm 0,2$ dB.
- Calcular las desviaciones del nivel promediado en el tiempo y del nivel con ponderación temporal S respecto al nivel con ponderación temporal F del paso 2. Estas desviaciones no deben superar los límites de aceptación de $\pm 0,1$ dB.

Ponderaciones frecuenciales con señales eléctricas

Se utilizan señales eléctricas sinusoidales continuas para todas las ponderaciones frecuenciales reguladas en la IEC 61672-1:2013 y que estén disponibles en el sonómetro. Y se siguen los pasos a continuación:

- Se ajusta el sonómetro para mostrar niveles de sonido con ponderación temporal F , niveles promediados en el tiempo o niveles de exposición sonora³.
- Se ajusta el sonómetro en el rango de niveles de referencia y se envía una señal de 1 kHz cuya amplitud produzca una indicación en el sonómetro que sea 45 dB menos que el límite superior indicado en el manual de instrucciones para el rango de funcionamiento lineal a 1 kHz.

Para automatizar este paso, se usa la siguiente ecuación:

$$v_{1\text{ kHz}} = 10^{\left(\frac{20 \log(v_{\text{ref}}) + L_{\text{ref}} - (L_{u@1\text{ kHz}} - 45)}{20} \right)}. \quad (2-3)$$

En que $v_{1\text{ kHz}}$ es el voltaje que produce una indicación de 45 dB menos que el límite superior del rango lineal a 1 kHz, v_{ref} es el voltaje que produce una indicación del nivel de referencia L_{ref} y $L_{u@1\text{ kHz}}$ es el límite superior del rango lineal a 1 kHz especificado en el manual de instrucciones.

- Se registran los niveles de las señales de entrada y las correspondientes indicaciones, para sonómetros clase 1: en las nueve frecuencias nominales en intervalos de octava de 63 Hz a 16 kHz; para sonómetros clase 2: en las ocho frecuencias nominales en intervalos de octava de 63 Hz a 8 kHz.

²El nivel promediado en el tiempo sólo sería posible registrarlo automáticamente si este es mostrado en pantalla.

³Como en este trabajo se busca reconocer el resultado instantáneo mostrado en pantalla, el nivel elegido es preferiblemente el que tiene ponderación temporal F .

En frecuencias diferentes a 1 kHz el nivel de la señal de entrada se determina como

$$v_f = 10^{\left(\frac{20 \log(v_{1 \text{ kHz}}) + W_{X,f}}{20} \right)}. \quad (2-4)$$

En que v_f es el voltaje de la señal a la frecuencia f , $v_{1 \text{ kHz}}$ es el voltaje del paso anterior y $W_{X,f}$ es el factor de la ponderación frecuencial elegida X para la frecuencia f .

- Se calculan las ponderaciones frecuenciales relativas como $L_f - L_{1 \text{ kHz}}$, i.e. el nivel indicado a una frecuencia de ensayo menos el nivel indicado a 1 kHz.
- Aplicar factores de corrección a las ponderaciones frecuenciales relativas del paso anterior que den cuenta de:
 - La desviación de la respuesta en frecuencia en campo libre o para incidencia aleatorio de un micrófono en la dirección de referencia respecto a una respuesta en frecuencia uniforme.
 - Los efectos de las reflexiones en la carcasa del sonómetro y de la difracción del sonido alrededor del micrófono y del amplificador.
 - Si aplica, la influencia de la pantalla antiviento y de cualquier accesorio que sea parte de la configuración normal del sonómetro.
- Las ponderaciones frecuenciales relativas corregidas son las desviaciones respecto a los objetivos de diseño según la ponderación frecuencial bajo calibración y no deben exceder los límites de aceptación dados en la Tabla 3 de la IEC 61672-1:2013.

Linealidad de nivel en el rango de niveles de referencia

Se utilizan señales eléctricas sinusoidales continuas a una frecuencia de 8 kHz con el sonómetro ajustado en el rango de niveles de referencia, en ponderación frecuencial A , y con ponderación temporal F o un nivel promediado en el tiempo, i.e. L_{AF} o L_{Aeq} , y se siguen los pasos a continuación:

- Comenzar una señal de entrada cuya amplitud produce el punto de partida para los ensayos de linealidad a 8 kHz especificado en el manual de instrucciones. Y registrar el nivel indicado.
- Aumentar el nivel de la señal de entrada en saltos de 5 dB desde el punto de partida hasta un nivel que se encuentre dentro de 5 dB por debajo del límite superior del rango de funcionamiento lineal a 8 kHz especificado en el manual. Luego, aumentar en saltos de

1 dB hasta, pero sin incluir, la primera indicación de sobrecarga. Se deben registrar las indicaciones del sonómetro en cada punto.

- Disminuir el nivel de la señal de entrada en saltos de 5 dB desde el punto de partida hasta un nivel que se encuentre dentro de 5 dB por encima del límite inferior del rango de funcionamiento lineal a 8 kHz especificado en el manual. Luego, disminuir en saltos de 1 dB hasta, pero sin incluir, la primera indicación de “por debajo del rango”. Se deben registrar las indicaciones del sonómetro en cada punto.
- Calcular las desviaciones de nivel como la diferencia entre el nivel indicado y el nivel previsto. Estas desviaciones no deben superar los límites de $\pm 0,8$ dB para la clase 1 o de $\pm 1,1$ dB para la clase 2.

Para automatizar esta prueba, el voltaje en el punto de partida se determina como

$$v_{L_{\text{start}}} = 10^{\left(\frac{20 \log(v_{\text{ref}}) + L_{\text{start}} - L_{\text{ref}} - W_{A,8\text{kHz}} - E_{A,8\text{kHz}}}{20} \right)}. \quad (2-5)$$

En que $v_{L_{\text{start}}}$ es el voltaje que causa una indicación del nivel en el punto de partida L_{start} , v_{ref} es el voltaje que produce una indicación del nivel de referencia, $W_{A,8\text{kHz}}$ es el factor estandarizado de la ponderación A en la frecuencia de 8 kHz que tiene el valor de $-1,1$ dB y $E_{A,8\text{kHz}}$ es la ponderación relativa a 1 kHz, sin corregir, obtenida en la prueba de ponderaciones frecuenciales en la frecuencia de 8 kHz en la ponderación frecuencial A .

Luego, a partir de ese voltaje en el punto de partida, el voltaje $v_{L_{\text{prev}}}$ para cada punto de calibración o nivel previsto L_{prev} a lo largo del rango de niveles, se calcula como

$$v_{L_{\text{prev}}} = 10^{\left(\frac{20 \log(v_{L_{\text{start}}}) + L_{\text{prev}} - L_{\text{start}}}{20} \right)}. \quad (2-6)$$

2.3. Instrumentación

2.3.1. Patrones e instrumentos para la calibración periódica de calibradores acústicos

2.3.2. Patrones e instrumentos para la calibración periódica de sonómetros

2.3.3. Comandos SCPI

3. Sistema de reconocimiento de imágenes para el valor de medición

En esta sección se discute el desarrollo del sistema de reconocimiento de caracteres que será empleado para adquirir automáticamente un valor de medición que sea indicado en la pantalla del sonómetro bajo calibración. Primero se introduce un algoritmo general con los pasos de procesamiento y clasificación de las imágenes; luego, se presenta el fundamento teórico de cada uno de esos pasos. Finalmente se muestran y discuten los resultados de procesamiento de imagen sobre una muestra de un dígito, como también los resultados del clasificador implementado.

Algoritmo de reconocimiento de caracteres

De manera general, la solución propuesta, para el reconocimiento del valor de medición indicado en la pantalla del sonómetro, consta de varios pasos que se presentan en el siguiente algoritmo.

Algoritmo 3.1: Algoritmo del sistema de reconocimiento de imágenes.

Data: images \leftarrow Imágenes de entrenamiento si va a entrenar o fotos de la pantalla si va reconocer.

output: Clases estimadas.

```
1 training  $\leftarrow$  True | False
2 foreach image  $\in$  images do
3     \\Las operaciones sobre image son realizadas in place.
4     Paso 1: Filtrar image con filtro gaussiano.
5     Paso 2: Escalar y hacer padding a image para hacerla de  $31 \times 32$  pixeles.
6     Paso 3: Segmentar image determinando el umbral con el método de Otsu (1979).
7     if training = False then
8         | Detectar contornos y extraer dígitos.
9     Paso 4: Calcular las características de image con el descriptor SIFT (Lowe, 2004).
10    Paso 5: Reducir dimensionalidad de las características por KPCA (Schölkopf et al., 1997).
11    | Agregar las características a la matriz features.
12 Paso 6:
13 if training then
14     | Entrenar clasificador bayesiano normal con features y las correspondientes etiquetas de clase.
15 else
16     | Estimar las clases de las características en features con el clasificador bayesiano normal.
```

Concerniente al procesamiento y reconocimiento de imágenes, a continuación se presenta un breve marco de referencia teórico de cada paso del algoritmo 3.1.

Paso 1: Filtro gaussiano

Como se explica en el libro de Robert Szeliski (2011), el filtro gaussiano, también llamado filtro de suavizado o de desenfoque, es una operación local en imágenes bidimensionales, pues se efectúa en vecindarios con un tamaño determinado en píxeles; el valor final de un píxel depende de los valores de los píxeles que pertenecen a su correspondiente vecindario y, como en todos los casos de filtros lineales, de una función de ponderación. Esta operación local viene a ser la de correlación ($g = f \otimes h$), que básicamente es la suma ponderada de los píxeles de entrada, que se define como

$$g(i, j) = \sum_{k, l} f(i + k, j + l) h(k, l). \quad (3-1)$$

En que g es la imagen de salida, f es la imagen de entrada y h la máscara o *kernel*, que contiene los coeficientes del filtro.

La operación contraparte de la correlación sería la convolución ($g = f * h$), en la que se usa el *kernel* invertido y se define como

$$g(i, j) = \sum_{k, l} f(k, l) h(i - k, j - l). \quad (3-2)$$

En que h es la respuesta al impulso, ya que si se convoluciona la máscara h con una señal impulsiva $\delta(i, j)$, se obtiene la misma máscara ($h * \delta = h$).

Para el caso del filtro gaussiano, el *kernel* se obtiene a partir de la típica función exponencial de Gauss. Particularmente, considerando la implementación de OpenCV que se ejecuta con la instrucción `GaussianBlur()`, la función sería la bivariada no correlacionada definida como

$$h(x, y) = \frac{1}{2\pi\sigma_x\sigma_y} \exp \left(-\frac{(x - \mu_x)^2}{2\sigma_x^2} - \frac{(y - \mu_y)^2}{2\sigma_y^2} \right). \quad (3-3)$$

La función de OpenCV también permite especificar un tamaño definido de ventana y esta calculará automáticamente las varianzas como

$$\sigma_x = \left(\frac{n_x - 1}{2} \right) 0.3 + 0.8, \quad \text{en que } n_x = \text{ancho} - 1; \quad (3-4a)$$

$$\sigma_y = \left(\frac{n_y - 1}{2} \right) 0.3 + 0.8, \quad \text{en que } n_y = \text{alto} - 1. \quad (3-4b)$$


Paso 2: Escalización y *padding*

Por supuesto, en la práctica, el filtrado requiere que se agreguen píxeles en los bordes de la imagen original, según el tamaño determinado de la ventana; a esto se le conoce como *padding* y es una operación que realiza por defecto OpenCV, con la que es posible elegir el modo del *padding*. Existen diferentes modos de *padding*, de los cuales se describen los siguientes:

- *zero*: Todos los píxeles añadidos se establecen en 0.
- *mirror*: Refleja los últimos píxeles del borde.

En la siguiente figura se muestra el resultado de ambos modos de *padding*.

Figura 3-1.: Comparación de los modos de *padding*: *zero* y *mirror*.



Tomado de (Richard, 2011).

El modo *mirror* es utilizado para el filtro gaussiano y el *zero* para adecuar la imagen antes del [paso 3](#) con el fin de completar el tamaño de 32×32 píxeles requerido para el [paso 4](#).

Como la imagen que contiene el dígito tendrá un tamaño diferente a 32×32 , antes de realizar el *zero padding* es necesario escalarla haciendo que el eje de mayor dimensión se ajuste a 32 píxeles y el otro eje se ajuste proporcionalmente; esta operación se realiza con la función `resize()` de OpenCV. Luego sí se añaden los píxeles faltantes al eje de menor dimensión para completar los 32 píxeles.

Paso 3: Segmentación

Existen diferentes técnicas de segmentación: basada en umbrales, en bordes, en regiones, por agrupación o por *matching*. Para los propósitos de este trabajo, es suficiente con una umbralización para discriminar los segmentos de la imagen, que corresponderían a los dígitos indicados en la pantalla del sonómetro. Sin embargo, el umbral no puede ser el mismo para todas las imágenes, pues cada una puede estar influenciada por los efectos de iluminación, áreas o colores de los segmentos. Una forma sistemática de determinar el umbral es empleando el algoritmo de [Otsu \(1979\)](#). Este algoritmo busca maximizar la separación entre las clases de niveles de grises del histograma de la imagen usando los momentos de cero y primer orden.

La formulación de Otsu es un *método no supervisado*¹ basado en el análisis discriminante para evaluar la bondad del umbral y seleccionar automáticamente un límite óptimo. En primer lugar, el método normaliza el histograma de niveles de grises y lo considera como una distribución de probabilidad.

Si hay L niveles de grises, entonces el número de píxeles en la imagen es $N = n_1 + n_2 + \dots + n_L$; n_i es el número de píxeles que tienen un nivel i . Luego, la distribución de probabilidad queda expresada como

$$p_i = \frac{n_i}{N}, \quad \text{en que } p_i \geq 0, \sum_{i=1}^L p_i = 1. \quad (3-5)$$

Ahora, se buscan dos clases C_0 y C_1 , que corresponden a los píxeles que pertenecen al fondo y a los que pertenecen a los objetos, separados por el nivel de gris de valor k . Las probabilidades de cada clase se definen de acuerdo con

$$\omega_0 = \Pr(C_0) = \sum_{i=1}^k p_i = \omega(k); \quad (3-6a)$$

$$\omega_1 = \Pr(C_1) = 1 - \omega(k). \quad (3-6b)$$

Luego, los valores esperados condicionales de cada clase son:

$$\mu_0 = \sum_{i=1}^k i \Pr(i|C_0) = \sum_{i=1}^k i \frac{p_i}{\omega_0} = \frac{\mu(k)}{\omega(k)}; \quad (3-7a)$$

$$\mu_1 = \sum_{i=k+1}^L i \Pr(i|C_1) = \sum_{i=k+1}^L i \frac{p_i}{\omega_1} = \frac{\mu_T - \mu(k)}{1 - \omega(k)}. \quad (3-7b)$$

¹Los métodos no supervisados son aquellos que no requieren que las muestras de entrenamiento estén etiquetadas previamente según su clase, sino que a partir de los datos identifican patrones que permiten agruparlos.

En que $\omega(k)$ y $\mu(k)$ son los momentos acumulados de cero y primer orden del histograma hasta el k -ésimo nivel. Estos momentos acumulados se definen como

$$\omega(k) = \sum_{i=1}^k p_i; \quad (3-8a)$$

$$\mu(k) = \sum_{i=1}^k i p_i. \quad (3-8b)$$

Similarmente, los momentos de primer y segundo orden de la imagen se definen como

$$\mu_T = \sum_{i=1}^L i p_i; \quad (3-9a)$$

$$\sigma_T^2 = \sum_{i=1}^L (i - \mu_T)^2 p_i. \quad (3-9b)$$

En que μ_T es la media total de los niveles de grises de la imagen original y σ_T^2 la varianza.

En principio, si las clases están separadas en sus niveles de grises entonces hay una umbralización adecuada. Consecuentemente, un umbral que resulte en la mejor separación de clases según sus niveles de grises será un umbral óptimo. Hay por lo menos tres medidas de separación entre clases que se pueden maximizar. Sin embargo, por simplicidad (dado que depende de los momentos de orden cero y uno), conviene usar la medida definida en la siguiente ecuación como criterio para el análisis discriminante.

$$\eta = \frac{\sigma_B^2}{\sigma_T^2}. \quad (3-10)$$

Donde el coeficiente σ_B^2 se define como

$$\sigma_B^2 = \omega_0 \omega_1 (\mu_1 - \mu_0)^2. \quad (3-11)$$

Finalmente, condensando las ecuaciones (3-7) a (3-11), el umbral óptimo k^* que maximiza η y, proporcionalmente, σ_B^2 se encuentra por medio de la siguiente expresión:

$$\sigma_B^2(k^*) = \max_{1 \leq k < L} \sigma_B^2(k). \quad (3-12)$$

En la cual,

$$\sigma_B^2(k) = \frac{[\mu_T \omega(k) - \mu(k)]^2}{\omega(k) [1 - \omega(k)]}. \quad (3-13)$$

Esta optimización se puede realizar de forma iterativa con unos valores iniciales de $\omega(0)$ y $\mu(0)$,

luego iterando con todos los posibles valores de $k = 0, 1, \dots, L$, y calculando $\sigma_B^2(k)$. El umbral óptimo k^* será el máximo valor obtenido de $\sigma_B^2(k)$.

Paso 4: Descriptor local SIFT

En esta aplicación particular (cuyo funcionamiento se pretende en tiempo real), el objeto de reconocimiento es simple, por lo que no hace falta el sofisticado algoritmo de detección, localización y orientación de puntos característicos de la presentación original del descriptor SIFT propuesto por Lowe (2004). No obstante, la implementación del algoritmo aquí presentada sí tiene en cuenta su propuesta de descriptor local basada en la magnitud y dirección de los gradientes de cada píxel perteneciente a la región alrededor de cada punto característico.

En primer lugar, se calcula la magnitud y dirección del gradiente de cada píxel. Esto finalmente es una valoración del cambio direccional en la intensidad de la imagen. La dirección final del gradiente en un píxel es aquella en la que ocurre el máximo cambio de intensidad, y la magnitud sería el máximo cambio de intensidad. Para lo cual se emplean las siguientes ecuaciones:

$$\delta_x = I(x + 1, y) - I(x - 1, y); \quad (3-14a)$$

$$\delta_y = I(x, y + 1) - I(x, y - 1); \quad (3-14b)$$

$$\theta(x, y) = \tan^{-1} \left(\frac{\delta_y}{\delta_x} \right); \quad (3-14c)$$

$$|\nabla f(x, y)| = \sqrt{\delta_x^2 + \delta_y^2}. \quad (3-14d)$$

Las diferencias de intensidad en x y en y se determinan con las ecuaciones (3-14a) y (3-14b), luego, la dirección con (3-14c) y la magnitud con (3-14d).

Después de obtener todas las magnitudes y direcciones de los gradientes, se conforma un histograma de orientaciones en 8 intervalos por cada ventana de $n \times n = 4 \times 4$ píxeles; es decir, según la dirección de cada vector, su magnitud se suma en el respectivo intervalo del histograma de la ventana al que pertenece. Finalmente queda un vector de características de 128 valores que es la concatenación de todos los histogramas, cada uno de 8 valores. Pero la contribución de esta magnitud a su intervalo de orientación correspondiente es ponderada por la función gaussiana de la ecuación (3-15) con σ igual a la mitad del ancho de la ventana del descriptor, con el propósito de dar menor peso a los gradientes que están más lejos del centro del descriptor.

$$G(x, y) = \frac{1}{2\pi\sigma^2} \exp\left(-\frac{x^2 + y^2}{2\sigma^2}\right). \quad (3-15)$$

El objetivo del histograma es permitir que hayan cambios locales más grandes en las direcciones de los gradientes pero que contribuyan al mismo intervalo en el histograma. Ahora bien, pueden ocurrir cambios abruptos en el histograma cuando en realidad hay cambios suaves en las direcciones de las muestras de gradientes, esto debido a los efectos de los límites en los intervalos. Para mitigar este efecto, se aplica una interpolación trilineal² para distribuir la magnitud de cada muestra de gradiente en intervalos de histograma adyacentes, en función de la “distancia” de la dirección de la muestra desde el valor central del intervalo. Esto queda reflejado en las siguientes funciones de ponderación:

$$w_k(x, y) = \begin{cases} \nabla\theta(x, y), & \text{si } k = i\theta(x, y) \\ 1 - \nabla\theta(x, y), & \text{si } k = i\theta \text{ mód } 8 + 1 \\ 0, & \text{en caso contrario} \end{cases} \quad (3-16a)$$

$$w_i(x, y) = \begin{cases} \nabla x(x, y), & \text{si } i = ix(x, y) \\ 1 - \nabla x(x, y), & \text{si } i = ix(x, y) + 1 \\ 0, & \text{en caso contrario} \end{cases} \quad (3-16b)$$

$$w_j(x, y) = \begin{cases} \nabla y(x, y), & \text{si } j = iy(x, y) \\ 1 - \nabla y(x, y), & \text{si } j = iy(x, y) + 1 \\ 0, & \text{en caso contrario} \end{cases} \quad (3-16c)$$

Con las siguientes definiciones:

$$\nabla\theta(x, y) = i\theta(x, y) - \frac{\theta(x, y)}{\delta\theta}, \quad \text{en que } i\theta(x, y) = \left\lceil \frac{\theta(x, y)}{\delta\theta} \right\rceil \text{ y } \delta\theta = 360/n; \quad (3-17a)$$

$$\nabla x(x, y) = ix(x, y) - \frac{x}{\delta x}, \quad \text{en que } ix(x, y) = \left\lceil \frac{x}{\delta x} \right\rceil; \quad (3-17b)$$

$$\nabla y(x, y) = iy(x, y) - \frac{y}{\delta y}, \quad \text{en que } iy(x, y) = \left\lceil \frac{y}{\delta y} \right\rceil. \quad (3-17c)$$

En seguida, se conforma el histograma como se presenta a continuación:

$$H = (H_{11}, H_{12}, \dots, H_{nn});$$

$$H_j = (h_1, h_2, \dots, h_n);$$

²La interpolación trilineal es la extensión de la interpolación lineal a un espacio tridimensional ($D = 3$) usando polinomios de primer orden. En la práctica resulta ser la interpolación lineal de dos interpolaciones bilineales. Con esta operación se encuentra un valor intermedio teniendo en cuenta los 2^D valores adyacentes.

$$h_k(x, y) = \sum_{(x,y)} w_k(x, y) w_i(x, y) w_j(x, y) |\nabla f(x, y)| G(x, y). \quad (3-18)$$

Finalmente el arreglo resultante se normaliza para hacerlo invariante a los efectos de contrastes o cambios en la iluminación, y para reducir los efectos de cambios no lineales en iluminación debidos a la saturación de la cámara, se limitan los valores con un umbral experimental de 0,2, de manera que los valores inferiores a 0,2 son remplazados con 0,2, y se normaliza nuevamente. La normalización se efectúa empleando la norma L_2 , como se muestra a continuación:

$$\begin{aligned} H &= (H_{11}, H_{12}, \dots, H_{nn}) \Rightarrow v = (v_1, v_2, \dots, v_m). \\ \|v\|_2 &= \sqrt{\sum_{i=1}^m v_i^2}. \\ v' &= \left(\frac{v_1}{\|v\|_2}, \frac{v_2}{\|v\|_2}, \dots, \frac{v_m}{\|v\|_2} \right); \\ v'' &= (\max(v_1, 0.2), \max(v_2, 0.2), \dots, \max(v_m, 0.2)); \\ v''' &= \frac{v''}{\|v''\|_2}. \end{aligned}$$

Paso 5: Reducción de dimensionalidad por análisis de componentes principales (KPCA)

Una vez se obtienen los vectores de características de las muestras, conviene un proceso adicional para simplificar el análisis posterior de los datos, mejorar el desempeño en la clasificación, eliminar información redundante o incluso poder obtener representaciones gráficas de los vectores. Generalmente los vectores de características resultan ser de grandes dimensiones, lo que provoca ciertas desventajas como que al aumentar las dimensiones de los vectores el volumen del espacio aumenta exponencialmente y los datos tienden a volverse dispersos, y esto afecta negativamente la clasificación, pues los datos se organizan en áreas correspondientes a grupos con características similares, y finalmente las estrategias comunes de clasificación no son eficaces. Ese efecto llamado "la maldición de la dimensión" puede ser abordado con diferentes métodos, entre estos la reducción de dimensionalidad tomando las componentes principales del grupo de datos usando el truco del *kernel* (KPCA) originalmente propuesto por [Schölkopf et al. \(1997\)](#).

En principio se toma el método de análisis de componentes principales (PCA), en el que básica-

mente se hace una transformación euclídea al rotar y trasladar los ejes para alcanzar la mayor variabilidad descendientemente en todas las dimensiones. En la práctica, se trazan planos de modo que las distancias de los puntos a estos sean las mínimas posibles. Las componentes principales corresponden a las primeras dimensiones del hiperplano resultante, en las que se encuentra la mayor variabilidad. Para lograr esto se diagonaliza la matriz de covarianza de los datos $\mathbf{x}_k \in \mathbf{R}^N$, con $k = 1, \dots, \ell$ definida en 3-20. Los datos están centrados en el origen, de modo que $\sum_{k=1}^{\ell} \mathbf{x}_k = 0$.

$$\mathbf{C} = \frac{1}{\ell} \sum_{j=1}^{\ell} \mathbf{x}_j \mathbf{x}_j^{\top}. \quad (3-20)$$

La diagonalización, en otras palabras, es una descomposición en valores y vectores propios de la matriz \mathbf{C} , y las proyecciones ortogonales de los puntos en los eigenvectores son las componentes principales.

Ahora, suele ocurrir que la separación entre los datos no es del todo lineal y entonces es necesario hacer una transformación no lineal de los datos a un nuevo espacio de características \mathcal{F} , como se describe a continuación:

$$\Phi : \mathbf{R}^N \rightarrow \mathcal{F}, \quad \mathbf{x} \mapsto \mathbf{X}. \quad (3-21)$$

En ese nuevo espacio \mathcal{F} también es posible hacer el análisis PCA. La transformación se realiza usando *kernels*, que son funciones continuas conocidas del método de las máquinas de vectores de soporte (SVM), que además mejoran el costo computacional, porque el cálculo depende del producto interno de los vectores en el nuevo espacio, i.e $\mathbf{k}(\mathbf{x}, \mathbf{x}') = \Phi(\mathbf{x})^{\top} \cdot \Phi(\mathbf{x}')$.

Luego, si en el espacio original el análisis PCA se hacía con la descomposición de $\lambda \mathbf{x}_k \mathbf{V} = \mathbf{x}_k \mathbf{C} \mathbf{V}$, en el nuevo espacio de características, equivalentemente se hace la descomposición del sistema

$$\lambda (\Phi(\mathbf{x}_k) \cdot \mathbf{V}) = (\Phi(\mathbf{x}_k) \cdot \bar{\mathbf{C}} \mathbf{V}), \quad \forall k = 1, \dots, \ell. \quad (3-22)$$

Con $\bar{\mathbf{C}} = \frac{1}{\ell} \sum_{j=1}^{\ell} \Phi(\mathbf{x}_j) \Phi(\mathbf{x}_j)^{\top}$.

Luego, el vector propio puede ser expresado como una combinación lineal de los datos transformados:

$$\mathbf{V} = \frac{1}{\ell \lambda} \sum_{i=1}^{\ell} (\Phi(\mathbf{x}_i) \cdot \mathbf{V}) \Phi(\mathbf{x}_i); \quad (3-23a)$$

$$\mathbf{V} = \sum_{i=1}^{\ell} \alpha_i \Phi(\mathbf{x}_i). \quad (3-23b)$$

Ahora, para generar el producto interno de los vectores, se multiplica a ambos lados de 3-23b por $\Phi(\mathbf{x}_j)$, y se obtiene

$$\mathbf{V} \cdot \Phi(\mathbf{x}_j) = \lambda \ell \alpha_j = \sum_{i=1}^{\ell} \alpha_i (\Phi(\mathbf{x}_i) \cdot \Phi(\mathbf{x}_j)) = \sum_{i=1}^{\ell} \alpha_i \mathbf{K}_{ij}. \quad (3-24)$$

Recordando que $\mathbf{K}_{ij} := \Phi(\mathbf{x}_i) \cdot \Phi(\mathbf{x}_j)$.

Finalmente, expresando (3-24) de forma vectorial y matricial se llega a que el problema de eigenvalores a resolver es:

$$\ell \lambda \boldsymbol{\alpha} = \mathbf{K} \boldsymbol{\alpha}. \quad (3-25)$$

De este modo, los valores propios de \mathbf{K} son proporcionales a los valores propios de $\bar{\mathbf{C}}$ y la extracción de características se haría tomando los eigenvalores más grandes.

Como funciones de *kernel* pueden usarse diferentes funciones (e.g. polinomial, sigmoide, etc). En este caso, se usó uno de base radial como el *kernel* gaussiano que se presenta en la siguiente ecuación:

$$\mathbf{k}(\mathbf{x}, \mathbf{y}) = e^{\left(-\frac{\|\mathbf{x}-\mathbf{y}\|^2}{2\sigma^2}\right)}. \quad (3-26)$$

Paso 6: Clasificador bayesiano normal

En la última etapa de un sistema de visión de máquina se encuentra el reconocimiento e interpretación, en la cual se utilizan diversas técnicas. Una de las más clásicas es el clasificador paramétrico supervisado basado en la teoría de decisión de Bayes formulada de forma general a continuación.

$$P(A|B) = \frac{P(A) P(B|A)}{P(B)}. \quad (3-27)$$

En la que se toma A como hipótesis y B como la evidencia.

Generalmente, se hacen simplificaciones en el modelo asumiendo que hay independencia entre las características de entrada, de forma tal que se asume que la presencia o ausencia de una característica no afecta a las otras, entonces cada característica contribuye independientemente a la probabilidad del evento A . A este caso se le llama *clasificador ingenuo*.

Ahora, en términos de clases (y_i) y características (\mathbf{X}) , la ecuación (3-27) puede ser expresada

como

$$P(y_i|\mathbf{X}) = \frac{P(y_i) P(\mathbf{X}|y_i)}{P(\mathbf{X})}; \quad (3-28a)$$

$$P(y_i|\mathbf{x}_1, \dots, \mathbf{x}_n) = \frac{P(y_i) P(\mathbf{x}_1, \dots, \mathbf{x}_n|y_i)}{P(\mathbf{x}_1, \dots, \mathbf{x}_n)}. \quad (3-28b)$$

Al asumir la independencia entre las características de entrada, es posible reescribir (3-28b) usando la regla de la cadena, y queda que

$$P(y_i|\mathbf{x}_1, \dots, \mathbf{x}_n) = \frac{P(y_i) \prod_{j=1}^n P(\mathbf{x}_j|y_i)}{P(\mathbf{x}_1, \dots, \mathbf{x}_n)}. \quad (3-29)$$

En la práctica, el denominador de (3-29) permanece constante, y como además no depende de la clase, puede omitirse y queda que la probabilidad de una clase y_i dadas las características \mathbf{X} es proporcional a la productoria, es decir,

$$P(y_i|\mathbf{x}_1, \dots, \mathbf{x}_n) \propto P(y_i) \prod_{j=1}^n P(\mathbf{x}_j|y_i). \quad (3-30)$$

Finalmente, la clase por la que se decide el clasificador es aquella que tiene mayor probabilidad, como se define en la siguiente expresión:

$$\hat{y} = \arg \max_{y_i} P(y_i) \prod_{j=1}^n P(\mathbf{x}_j|y_i). \quad (3-31)$$

Ahora, tanto los parámetros del modelo, como las clases a priori y las características de las distribuciones de probabilidad, se determinan sobre el conjunto de datos de entrenamiento. Los parámetros del modelo se determinan haciendo estimaciones de máxima verosimilitud, maximizando la función de distribución de probabilidad, i.e. derivando respecto a cada parámetro e igualando a 0.

Cuando los datos pueden tomar valores de una función continua, generalmente se asume que siguen una distribución normal, la cual se presenta su versión multivariada en la siguiente expresión:

$$\begin{aligned} p(\mathbf{x}_k) &\sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma}); \\ &\sim \frac{1}{(2\pi)^{d/2} |\boldsymbol{\Sigma}|^{1/2}} \exp \left(-\frac{1}{2} (\mathbf{x}_k - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x}_k - \boldsymbol{\mu}) \right). \end{aligned} \quad (3-32)$$

En la estimación de máxima verosimilitud (MLE), con el fin de maximizar la función y encon-

trar los parámetros de la distribución, conviene operar (3-32) expresada en funciones monótonamente crecientes como el logaritmo natural y la suma, lo que se denomina *log-verosimilitud*, como se muestra a continuación.

$$\ell(\theta) = \sum_{k=1}^n -\frac{1}{2} (\mathbf{x}_k - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x}_k - \boldsymbol{\mu}) - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln |\boldsymbol{\Sigma}|. \quad (3-33)$$

Los parámetros a encontrar son $\theta_1 = \boldsymbol{\mu}$ y $\theta_2 = \boldsymbol{\Sigma}$, que al hacer la maximización de (3-33) quedan definidos como

$$\hat{\theta}_1 = \hat{\boldsymbol{\mu}} = \frac{1}{n} \sum_{k=1}^n \mathbf{x}_k; \quad (3-34a)$$

$$\hat{\theta}_2 = \hat{\boldsymbol{\Sigma}} = \frac{1}{n} \sum_{k=1}^n (\mathbf{x}_k - \hat{\boldsymbol{\mu}}) (\mathbf{x}_k - \hat{\boldsymbol{\mu}})^\top. \quad (3-34b)$$

Para conformar el clasificador normal bayesiano, en primer lugar se asume que cada clase tiene una distribución normal de la misma forma que la ecuación (3-32), y sus parámetros $\boldsymbol{\mu}$ y $\boldsymbol{\Sigma}$ dependen de los datos que, en la etapa de entrenamiento, se ha determinado que describen la distribución normal de cada clase. Y entonces la ecuación (3-32) pasa a ser la probabilidad de \mathbf{x}_j dada una clase y_i , cuyos parámetros de distribución de probabilidad están dados por:

$$\boldsymbol{\mu}_i = \frac{1}{n_i} \sum_{j=1}^n z_{ij} \mathbf{x}_j, \quad \text{en que } z_{ij} = \begin{cases} 1, & \text{si } \mathbf{x}_j \in y_i; \\ 0, & \text{si no} \end{cases}; \quad (3-35a)$$

$$\boldsymbol{\Sigma}_i = \frac{1}{n_i} \sum_{j=1}^n z_{ij} (\mathbf{x}_j - \boldsymbol{\mu}_i) (\mathbf{x}_j - \boldsymbol{\mu}_i)^\top, \quad \text{en que } z_{ij} = \begin{cases} 1, & \text{si } \mathbf{x}_j \in y_i; \\ 0, & \text{si no} \end{cases}. \quad (3-35b)$$

Con estas probabilidades condicionales se combina (3-32) con (3-31); primero definiendo las funciones discriminantes con *log-verosimilitud* como

$$\begin{aligned} g_i(\mathbf{x}) &= \ln p(\mathbf{x}|y_i) + \ln P(y_i); \\ &= -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_i)^\top \boldsymbol{\Sigma}_i^{-1} (\mathbf{x} - \boldsymbol{\mu}_i) - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln |\boldsymbol{\Sigma}_i| + \ln P(y_i). \end{aligned} \quad (3-36)$$

Finalmente, la función (3-36) se utiliza para decidir la clase a la que pertenecen las características $\mathbf{x} = x_1, \dots, x_d$ de una muestra dada. La clase de salida nuevamente es la que tenga la mayor probabilidad, es decir:

$$\hat{y} = \arg \max_{y_i} g_i(\mathbf{x}). \quad (3-37)$$

Resultados


A continuación se presentarán algunos detalles en la implementación de los procesamientos presentados en las secciones anteriores y ejemplos de los resultados. Las imágenes del conjunto de entrenamiento y de prueba fueron obtenidas fotografiando la pantalla de un sonómetro marca 01dB, modelo CUBE. Un ejemplo se muestra en la siguiente figura.

Figura 3-2.: Ejemplo de una fotografía de la pantalla de un sonómetro 01dB CUBE.



Para el filtro gaussiano se empleó $\sigma_x = \sigma_y = 1,5$. Luego, con el fin de simplificar el cálculo del descriptor SIFT, se escala la imagen de un dígito y se rellenan los píxeles faltantes para conformar una imagen de 32×32 . Luego, se eligen cuatro puntos clave que corresponden a los centros de cada cuadrante como se presenta en la siguiente figura.

Figura 3-3.: Puntos clave para el cálculo del descriptor SIFT de una imagen de un dígito.

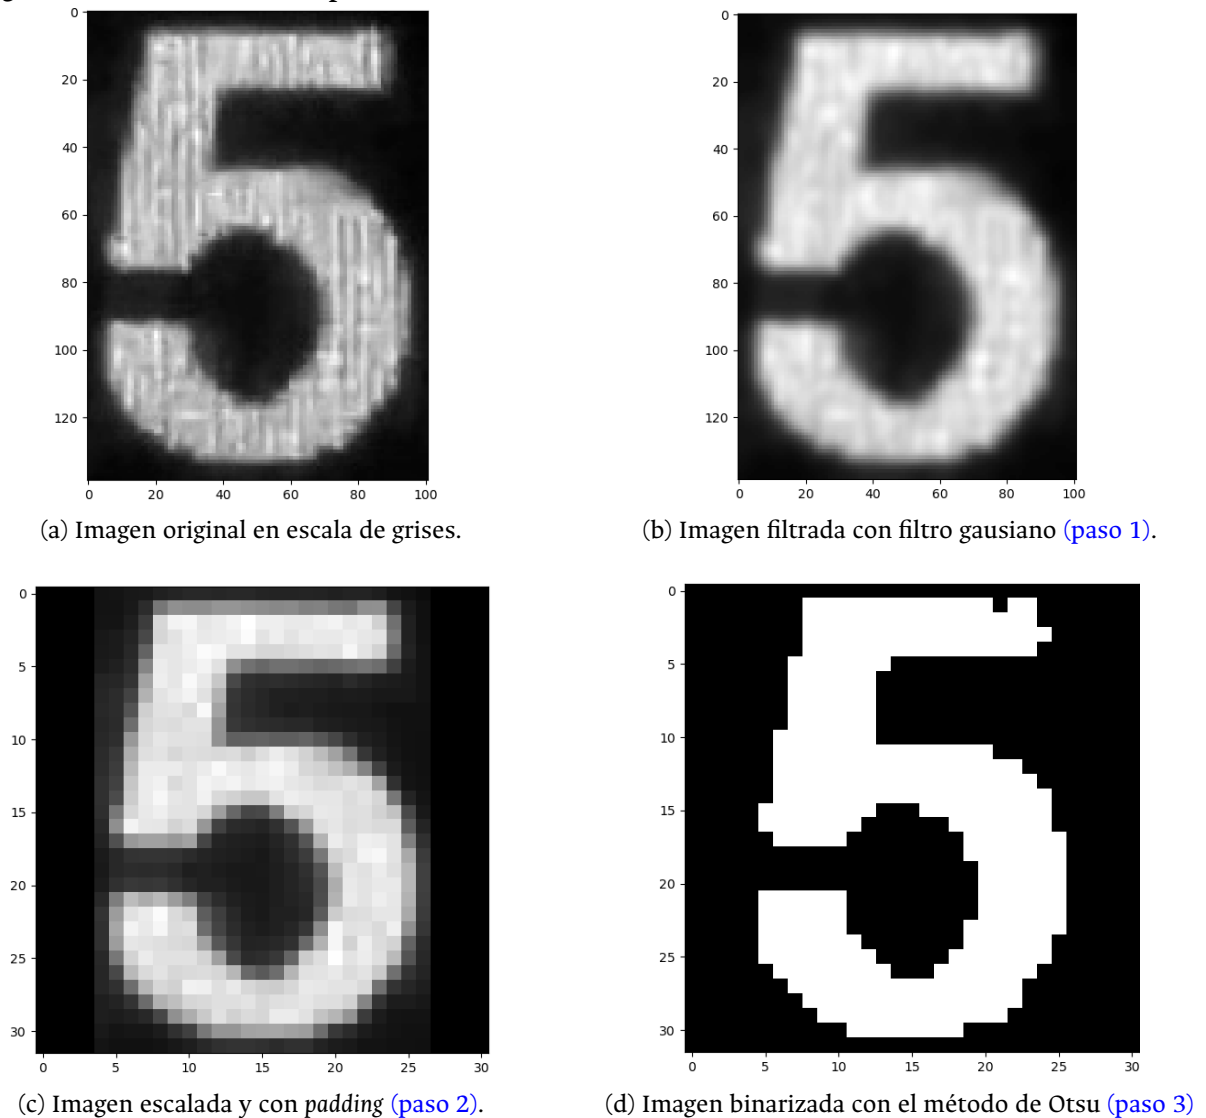


En esos puntos se calcula el descriptor SIFT, no sin previamente haber umbralizado la imagen redimensionada con el método de Otsu. De forma tal que queda un vector de características con 512 valores para cada muestra.

Una breve implementación de este procesamiento se presenta en el código [A.1](#), que posteriormente será usado en la aplicación desarrollada para automatizar la calibración de sonómetros.


En la siguiente figura se muestran los resultados de los pasos 1 al 3 del algoritmo [3.1](#) para una muestra de entrenamiento del número 5.

Figura 3-4.: Resultados de procesamiento de una muestra de entrenamiento del número 5.



Para el [paso 4](#), con las últimas líneas del código [A.1](#) también se grafican los vectores de características de la muestra del dígito 5. El resultado se presenta en la figura [3-5](#).

Figura 3-5.: Vector de características de la muestra de entrenamiento procesadas.



Ahora, el código [A.1](#) se puede ejecutar iterativamente para leer todas las imágenes de un conjunto de entrenamiento con entre 10 y 20 muestras por cada clase. Luego, para el [paso 5](#), complementando con el código [A.2](#) se efectúa la extracción de características y se entrena el clasificador bayesiano normal. La reducción de dimensionalidad se hizo hasta un valor de $d = 16$, empíricamente seleccionado según los resultados de clasificación obtenidos.

Finalmente, para una muestra dada de prueba, se efectúa el mismo procesamiento de la imagen con el código [A.1](#), y la extracción y clasificación se efectúa con el código [A.3](#).

Durante los primeros ensayos del algoritmo se pudo notar que si las condiciones de captura de la imagen no son controladas, factores como el desenfoque de la cámara, la alta exposición controlada por el diafragma de la cámara, reflejos, destellos de luz o bajo contraste, pueden afectar significativamente la clasificación. Por ejemplo, en la figura [3-6](#) se presenta una comparación entre dos números fotografiados en condiciones controladas y no controladas, y el respectivo resultado de procesamiento.

La precisión del clasificador se puede medir fácilmente con una matriz de confusión, en la que directamente se identifican los falsos y verdaderos positivos. La matriz de confusión se genera rápidamente con el código [A.4](#). Se armaron dos conjuntos de prueba, uno en condiciones no controladas y otro en que sí, y se probó el clasificador en ambos. En la figura [3-7](#) se muestra la matriz de confusión para el primer conjunto (condiciones no controladas) y en la figura [3-8](#) la del segundo (condiciones controladas).

Figura 3-6.: Comparación del procesamiento de imágenes tomadas en condiciones controladas y no controladas.

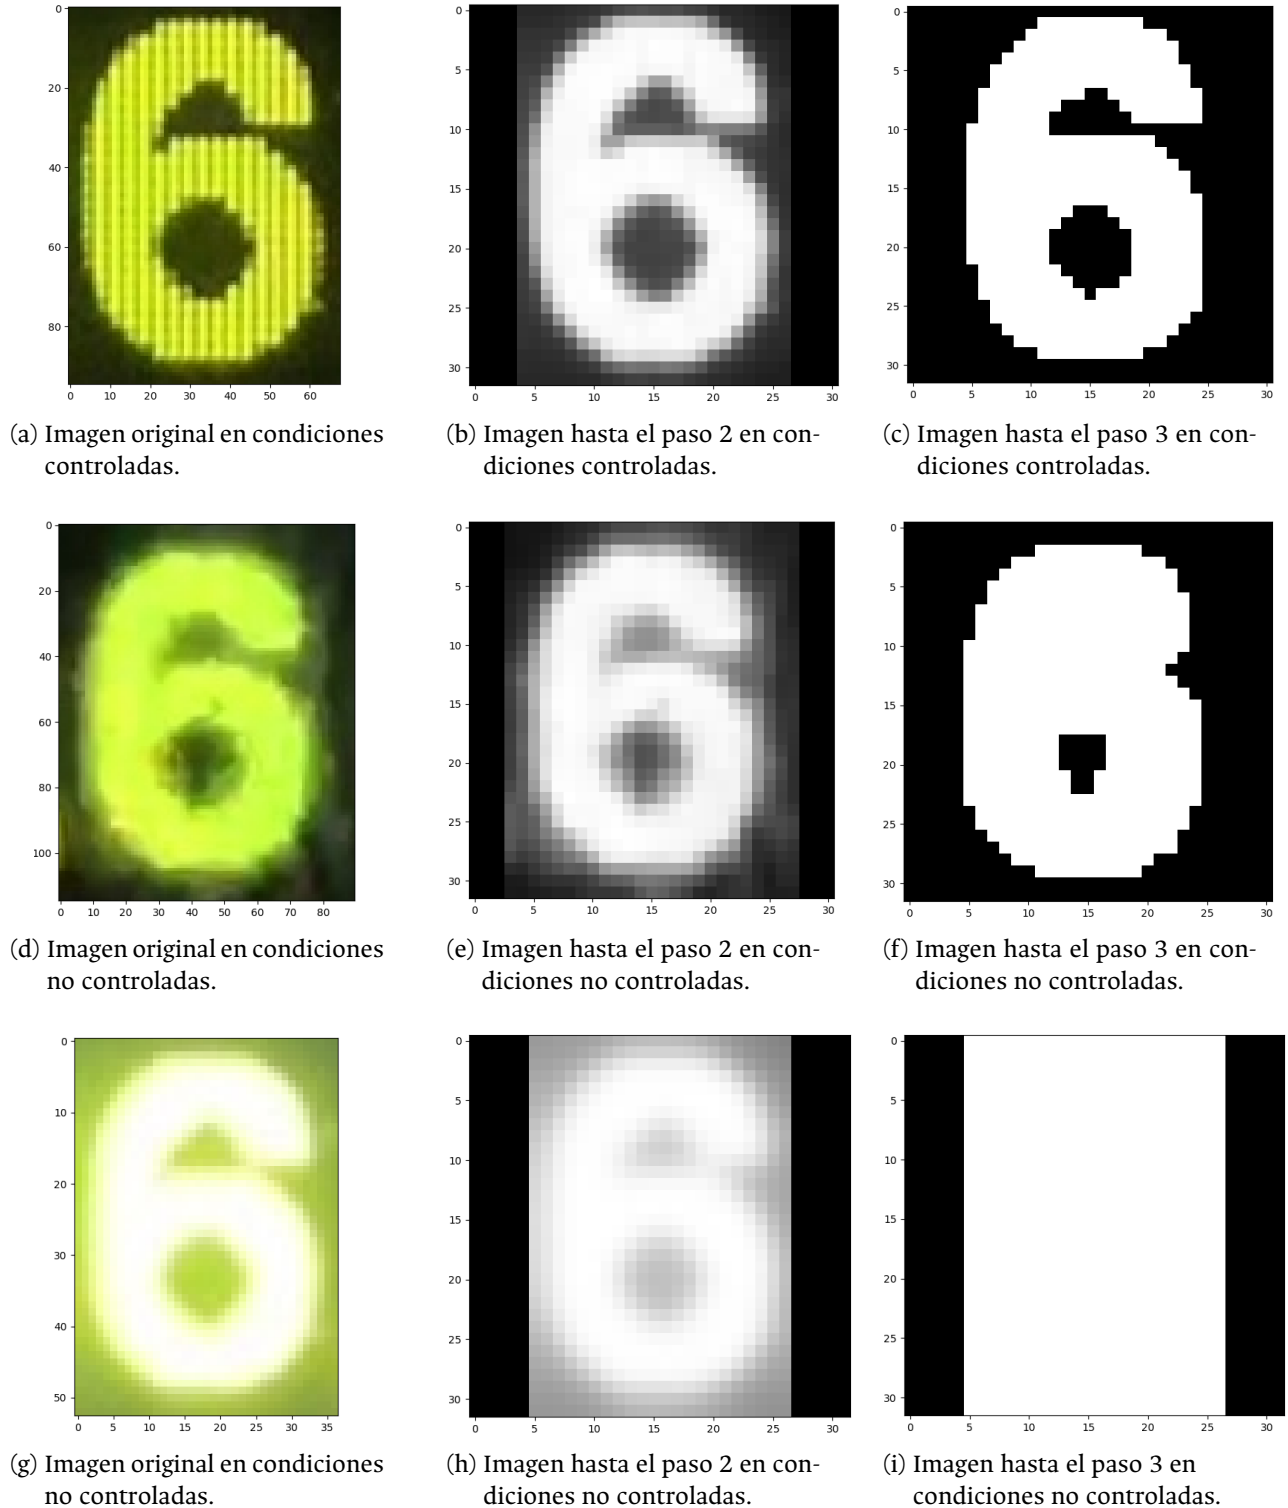


Figura 3-7.: Matriz de confusión del clasificador bayesiano propuesto para el conjunto de imágenes tomadas en condiciones no controladas.





Figura 3-8.: Matriz de confusión del clasificador bayesiano propuesto para el conjunto de imágenes tomadas en condiciones controladas.



Discusión

Los resultados obtenidos demuestran un funcionamiento satisfactorio en general, tanto del procesamiento de las imágenes como del clasificador. Aunque evidentemente es un método simplificado, resulta ser eficaz y eficiente, pues cumple con el objetivo de reconocimiento de caracteres empleando pocos recursos computacionales y cortos tiempos de entrenamiento del clasificador y del procesamiento de las imágenes, lo que permite que el método sea emplea-

do en ordenadores con baja capacidad de procesamiento y en aplicaciones de funcionamiento en tiempo real, como se pretende en este proyecto. Aunque el clasificador bayesiano es de las técnicas más sencillas de aprendizaje de máquina, tiene un desempeño aceptable en muchas aplicaciones reales y no requiere una base de datos de entrenamiento demasiado extensa ([scikit Developers, 2022](#)).

Particularmente, cada una de las etapas de procesamiento resulta ser crucial en el resultado. Por ejemplo la etapa de suavizado permite eliminar variaciones de intensidad de alta frecuencia como las irregularidades en el relleno de los dígitos debidas a la construcción de la pantalla del sonómetro, como en pantallas led, por ejemplo (cf. [3-6a](#) y [3-6b](#)). Sin este suavizado es posible que en la umbralización no se obtengan segmentos homogéneos que representen correctamente un dígito. La binarización de la imagen, buscando el umbral con el método de Otsu, garantiza que se haga una discriminación correcta entre el fondo de la pantalla y el dígito, en función de la distribución de las intensidades de píxeles, esto aporta confiabilidad en la segmentación independientemente de la forma y color de los números. Y el descriptor SIFT es bien conocido por su robustez frente a transformaciones afines o cambios en el punto de vista 3D, lo que contribuye a asegurar la eficacia en la medición de características aún cuando hay variaciones en la posición de la cámara respecto a la pantalla del sonómetro; además, que esté basado en la dirección de los gradientes, lo hace adecuado para cuantizar de algún modo las formas de los contornos de los dígitos.

No obstante, a pesar de la eficiencia y simplicidad del clasificador bayesiano normal, lo cierto es que el resultado de clasificación es bastante sensible si se obtienen resultados erróneos en el procesamiento anterior. Por ejemplo, por efectos de bajo contraste o desenfoques que deforman los segmentos, podrían haber confusiones en la clasificación, principalmente en clases que son muy similares en sus características, como entre el 6 y el 8 o entre el 9 y el 8, pues al deformarse el segmento a causa de esos ruidos, el 6 o el 9 cierran el trazo faltante y se asemejan a un 8, o alguno de los huecos se rellena y se asemejan a un 0. Sin embargo, en los ensayos del sistema de reconocimiento se pudo comprobar que esto ocurre cuando la posición o configuración de la cámara no es la adecuada y los efectos del desenfoque o la iluminación son más pronunciados. Cuando las condiciones de captura de la imagen son controladas (por ejemplo, ajustando en la cámara la distancia focal y la apertura del diafragma adecuadas, limpiando la pantalla del equipo para evitar borrosidad e incluso buscando una posición apropiada del sonómetro y la cámara para mitigar las reflexiones de las fuentes de luz del lugar), la eficacia del clasificador es de un 100 %, como se puede notar en la matriz de confusión de la figura [3-8](#).

4. Implementación de los procedimientos de calibración

4.1. Automatización de la calibración periódica de calibradores acústicos

4.1.1. GRAFCET descriptivo del proceso

4.1.2. Implementación en Python

Arquitectura de software

4.2. Automatización de la calibración periódica de sonómetros

4.2.1. Implementación en Python

Arquitectura de software

5. Modelamiento de incertidumbre de medición en la calibración periódica de sonómetros

5.1. Cadenas de Markov de tiempo discreto

5.1.1. Matriz de probabilidades de transición

5.1.2. Valor esperado

5.1.3. Probabilidad estacionaria

5.2. Incertidumbre de medición

Definición matemática del mesurando

5.2.1. Incertidumbre tipo A

5.2.2. Incertidumbre tipo B

5.2.3. Incertidumbre típica combinada

5.2.4. Grados efectivos de libertad, factor de cobertura e incertidumbre expandida

5.3. Algoritmo para creación de estados y tasas de transición de la cadena de Markov

5.3.1. Implementación de la cadena de Markov en Python

6. Conclusiones y recomendaciones

6.1. Conclusiones

Las conclusiones constituyen un capítulo independiente y presentan, en forma lógica, los resultados de la tesis o trabajo de investigación. Las conclusiones deben ser la respuesta a los objetivos o propósitos planteados. Se deben titular con la palabra conclusiones en el mismo formato de los títulos de los capítulos anteriores (Títulos primer nivel), precedida por el numeral correspondiente (según la presente plantilla).

6.2. Recomendaciones

Se presentan como una serie de aspectos que se podrían realizar en un futuro para emprender investigaciones similares o fortalecer la investigación realizada. Deben contemplar las perspectivas de la investigación, las cuales son sugerencias, proyecciones o alternativas que se presentan para modificar, cambiar o incidir sobre una situación específica o una problemática encontrada. Pueden presentarse como un texto con características argumentativas, resultado de una reflexión acerca de la tesis o trabajo de investigación.

A. Anexo: Códigos de Python

Código A.1: Código para presentar resultados del procesamiento de una muestras del número 5 del conjunto de imágenes entrenamiento.

```
1 import cv2 as cv
2 import matplotlib.pyplot as plt
3 import numpy as np
4
5
6 """
7 Programed by Felipe Maldonado,
8 Universidad Nacional de Colombia, Faculty of Engineering,
9 Department of Electrical and Electronic Engineering.
10 Created on 2022/03.
11 """
12 __autor__ = 'Juan Felipe Maldonado'
13 __version__ = '1.0 Beta'
14
15 path = "Images/Test1"
16 img_name = ["6(8).jpg"] # Samples just for showing results of processing
17 descriptor = cv.SIFT_create(contrastThreshold=0.02, edgeThreshold=1, sigma=0.01) # Creates a SIFT descriptor
18 # Four key points for computing SIFT descriptor
19 key_points = [cv.KeyPoint(7, 7, 16), cv.KeyPoint(7, 13, 16),
20               cv.KeyPoint(13, 7, 16), cv.KeyPoint(13, 13, 16)]
21
22 X = []
23 y = []
24 for name in img_name:
25     img = cv.imread(path + "/" + name, cv.IMREAD_GRAYSCALE) # Read image in gray scale
26     img_col = cv.cvtColor(cv.imread(path + "/" + name), cv.COLOR_BGR2RGB) # Read image in gray scale
27     img_blur = cv.GaussianBlur(img.copy(), ksize=(0, 0), sigmaX=1.5) # Gaussian filtering
28     mayor_axis = max(img_blur.shape) # The largest axis
29     # Normalize size
30     digit_scaled = cv.resize(img_blur, (0, 0), fx=32 / mayor_axis,
31                                fy=32 / mayor_axis, interpolation=cv.INTER_CUBIC)
32     # Build an image of 32 x 32 pixels with padding
33     if digit_scaled.shape[0] > digit_scaled.shape[1]:
34         digit_scaled = np.pad(digit_scaled, ((0, 0), ((32 - digit_scaled.shape[1]) // 2,
35                                                       (32 - digit_scaled.shape[1]) // 2)), 'constant')
36     else:
37         digit_scaled = np.pad(digit_scaled, (((32 - digit_scaled.shape[0]) // 2,
38                                                (32 - digit_scaled.shape[0]) // 2), (0, 0)), 'constant')
39
40     img_bin = cv.threshold(digit_scaled, 0, 255, cv.THRESH_BINARY | cv.THRESH_OTSU)[1] # Otsu binarization
41     # -- SIFT DESCRIPTOR --
42     _, features = descriptor.compute(img_bin, key_points) # Computes SIFT descriptor
43     X.append(features.flatten()) # Add the features vector of the actual training sample
44     y.append(img_name[0]) # Add the class of the actual training sample
45     # -- Plots results --
46     plt.imshow(img, cmap='gray'), plt.show()
47     plt.imshow(img_col), plt.show()
48     plt.imshow(img_blur, cmap='gray'), plt.show()
49     plt.imshow(digit_scaled, cmap='gray'), plt.show()
50     plt.imshow(img_bin, cmap='gray'), plt.show()
51
52 # -- Plots SIFT features by sample --
53 fig = plt.figure()
54 axes = fig.add_subplot(111)
55 axes.set_title('Vectores de características SIFT')
56 axes.scatter(range(len(X[0])), X[0], s=8, c='b', marker='s', label='Muestra de número 5')
57 # axes.scatter(range(len(X[1])), X[1], s=8, c='r', marker='o', label='Muestra de número 5')
58 # axes.scatter(range(len(X[2])), X[2], s=8, c='g', marker='x', label='Muestra de número 7')
59 axes.grid(visible=True)
```

```

59 plt.legend()
60 plt.show()

```

Código A.2: Código para realizar la extracción de características de los vectores de entrenamiento y para entrenar el clasificador.

```

1  from sklearn.decomposition import KernelPCA
2  from sklearn.naive_bayes import GaussianNB
3
4  kpcaModel = KernelPCA(n_components=16) # KPCA for dimensionality reduction
5  gnbClassifier = GaussianNB() # Gaussian naive Bayes classifier
6
7  X = np.array(X) # Convert training features vector to numpy array
8  y = np.array(y) # Convert training samples labels to numpy array
9
10 # ----- DIMENSIONALITY REDUCTION BY KERNEL PCA ----- #
11 # Fits the model and apply transformation to the features vector
12 X = kpcaModel.fit_transform(X, y)
13 # ----- FITS THE CLASSIFIER -----#
14 gnbClassifier.fit(X, y)

```

Código A.3: Código para realizar la extracción de características de los vectores de prueba y para realizar la clasificación.

```

1  X = np.array(X) # Convert test sample features vector to numpy array
2  # ----- DIMENSIONALITY REDUCTION BY KERNEL PCA ----- #
3  X = kpcaModel.transform(X)
4  # ----- CLASSIFY -----#
5  y_hat = gnbClassifier.predict(X)
6

```

Código A.4: Código para generar la matriz de confusión del clasificador bayesiano normal.

```

1  from sklearn.metrics import confusion_matrix, ConfusionMatrixDisplay
2
3  # ----- CLASSIFICATION ACCURACY -----#
4  cm = confusion_matrix(y_hat, y_test, labels=gnbClassifier.classes_)
5  disp = ConfusionMatrixDisplay(confusion_matrix=cm, display_labels=gnbClassifier.classes_)
6  disp.plot()
7  plt.show()

```

B. Anexo: Certificado de calibración de calibrador acústico

C. Anexo: Certificado de calibración de sonómetro

Bibliografía

Brüel & Kjær (2016). *Instruction Manual, Hand-held Analyzer Types 2250, 2250-L and 2270*. Brüel & Kjær Sound & Vibration Measurement A/S, Nærum, Denmark.

Brüel & Kjær (2021). What is a Sound Level Meter? <https://www.bksv.com/en/knowledge/blog/sound/what-is-a-sound-level-meter>. En línea: consultada en marzo del 2022.

Fletcher, H. and Munson, W. A. (1933). Loudness, Its Definition, Measurement and Calculation. *The Journal of the Acoustical Society of America*, 5(2):82–108.

IEC technical committee 29: Electroacoustics (2013). Electroacoustics – sound level meters - part 1: Specifications. Standard IEC 61672-1:2013, International Electrotechnical Commission, Geneva, Switzerland.

IEC technical committee 29: Electroacoustics (2017). Electroacoustics – sound calibrators. Standard IEC 60942:2017, International Electrotechnical Commission, Geneva, Switzerland.

Lowe, D. G. (2004). Distinctive image features from scale-invariant keypoints. *International Journal of Computer Vision*, 60(2):91–110.

Otsu, N. (1979). A Threshold Selection Method from Gray-Level Histograms. *IEEE Trans Syst Man Cybern*, SMC-9(1):62–66.

Richard, S. (2011). *Algorithms and Applications: Computer vision*. Springer, London, 2 edition.

Schölkopf, B., Smola, A., and Müller, K. R. (1997). *Kernel principal component analysis*, volume 1327. Springer, Alemania.

Scikit-learn developers (2022). 1.9. Naive Bayes. https://scikit-learn.org/stable/modules/naive_bayes.html#gaussian-naive-bayes. En línea: consultada en marzo del 2022.