



Desarrollo de un procedimiento de calibración de sonómetros y calibradores acústicos de conformidad con las normas IEC 61672-3 e IEC 60942

Juan Felipe Maldonado Pedraza

Universidad Nacional de Colombia
Facultad de Ingeniería, Departamento de Ingeniería Eléctrica y Electrónica
Bogotá, Colombia
2021

Desarrollo de un procedimiento de calibración de sonómetros y calibradores acústicos de conformidad con las normas

IEC 61672-3 e IEC 60942

Juan Felipe Maldonado Pedraza

Trabajo de grado presentado como requisito parcial para optar al título de:
Magister en Automatización Industrial

Director:
Ph.D. Leonardo Enrique Bermeo Clavijo

Línea de investigación:
Automatización en procesos de metrología
Universidad Nacional de Colombia
Facultad de Ingeniería
Bogotá, Colombia
2022

Lore ipsum dolor sit amet, consectetuer adipisciing elit. Ut purus elit, vestibulum ut, placerat ac, adipisciing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetuer id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Text
Lorem ipsum dolor sit amet, consectetuer adipiscing elit.

Agradecimientos

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Resumen

Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetuer id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Palabras clave: Calibración, metrología, sonómetros, calibradores acústicos, automatización, visión de máquina, cadena de Markov

Abstract

Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetuer id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Keywords: Calibration, metrology, sound level meters, acoustic calibrators, automation, computer vision, Markov chain

Índice general

Agradecimientos	VII
Resumen	IX
Lista de figuras	XIII
Lista de tablas	1
1. Introducción	2
1.1. Planteamiento del problema	2
1.2. Objetivos	3
1.2.1. General	3
1.2.2. Específicos	3
1.2.3. Alcance de los objetivos	3
1.2.4. Antecedentes	4
2. Metodología e instrumentación	5
2.1. Instrumentos bajo calibración	5
2.1.1. Calibradores acústicos	5
2.1.2. Sonómetros integradores	8
2.2. Métodos normalizados	10
2.2.1. Descripción general de la calibración periódica de calibradores acústicos de acuerdo con la IEC 60942:2017	11
2.2.2. Descripción general de las pruebas periódicas seleccionadas de acuerdo con la IEC 61672-3:2013	13
2.3. Instrumentación	18
2.3.1. Patrones e instrumentos para la calibración periódica de calibradores acústicos	18
2.3.2. Patrones e instrumentos para la calibración periódica de sonómetros	21
2.3.3. Comandos SCPI	23
3. Sistema de reconocimiento de imágenes para el valor de medición	25

4. Implementación de los procedimientos de calibración	43
4.1. Automatización de la calibración periódica de calibradores acústicos	43
4.1.1. GRAFCET descriptivo del proceso	43
4.1.2. Implementación en Python	49
4.2. Automatización de la calibración periódica de sonómetros	53
4.2.1. Implementación en Python	54
5. Caracterización de la variabilidad del valor de medición usando modelos de Markov	61
5.1. Cadenas de Markov de tiempo discreto	64
5.2. Ejemplo de resultado de ejecución del método	68
5.3. Evaluación tipo A de la incertidumbre típica	69
6. Conclusiones y recomendaciones	70
6.1. Conclusiones	70
6.2. Recomendaciones	70
A. Anexo: Códigos de Python	71
Bibliografía	73

Índice de figuras

2-1. Calibrador acústico multifunción Brüel & Kjær 4226.	5
2-2. Calibrador acústico Brüel & Kjær 4231 acoplado al micrófono de un sonómetro Brüel & Kjær 2250.	6
2-3. Configuraciones de <i>hardware</i> del sonómetro Brüel & Kjær 2250.	7
2-4. Gráfico de las ponderaciones frecuenciales <i>A</i> , <i>C</i> y <i>Z</i>	8
2-5. Gráfico de las respuestas en el tiempo de las ponderaciones temporales <i>fast</i> , <i>slow</i> e <i>impulse</i>	9
2-6. Diagrama de flujo general de la calibración periódica de calibradores acústicos.	11
2-7. Diagrama de bloques del proceso de medición en la calibración periódica de sonómetros de acuerdo con la IEC 61672-3:2013.	13
2-8. Esquema de conexiones de los instrumentos para la calibración periódica de calibradores acústicos.	18
2-9. Patrones acústicos para la calibración de calibradores acústicos.	19
2-10. Instrumentos para adecuación de la señal eléctrica.	19
2-11. Instrumentos de medición para la calibración periódica de calibradores acústicos.	20
2-12. Esquema de conexiones de los instrumentos para la calibración periódica de sonómetros.	21
2-13. Instrumentos utilizados en la calibración periódica de sonómetros.	22
3-1. Comparación de los modos de <i>padding</i> : <i>zero</i> y <i>mirror</i>	27
3-2. Ejemplo de una fotografía de la pantalla de un sonómetro 01dB CUBE.	37
3-3. Puntos clave para el cálculo del descriptor SIFT de una imagen de un dígito.	37
3-4. Resultados de procesamiento de una muestra de entrenamiento del número 5.	38
3-5. Vectores de características de una muestra de cada clase 2, 5 y 7.	39
3-6. Comparación del procesamiento de imágenes tomadas en condiciones controladas y no controladas.	40
3-7. Matriz de confusión del clasificador bayesiano propuesto para el conjunto de imágenes tomadas en condiciones no controladas.	41
3-8. Matriz de confusión del clasificador bayesiano propuesto para el conjunto de imágenes tomadas en condiciones controladas.	41

4-1. GRAFCET de la rutina principal de la calibración periódica de calibradores acústicos.	44
4-2. GRAFCET's de las subrutinas para la calibración periódica de calibradores acústicos.	45
4-2. GRAFCET's de las subrutinas para la calibración periódica de calibradores acústicos (continuación).	46
4-2. GRAFCET's de las subrutinas para la calibración periódica de calibradores acústicos (continuación).	47
4-2. GRAFCET's de las subrutinas para la calibración periódica de calibradores acústicos (continuación).	48
4-3. Representación gráfica del paradigma Model-View-Controller.	49
4-4. Diagrama de clases de la aplicación desarrollada para la calibración periódica de calibradores acústicos.	50
4-5. Interfaz gráfica de usuario de la aplicación para calibradores acústicos. Se muestra la pestaña de Patrones.	51
4-6. Interfaz gráfica de usuario de la aplicación para calibradores acústicos. Se muestra la pestaña de Información IBC.	52
4-7. Interfaz gráfica de usuario de la aplicación para calibradores acústicos. Se muestra la pestaña de Resultados.	53
4-8. Diagrama de clases de la aplicación desarrollada para la calibración periódica de sonómetros.	55
4-8. Diagrama de clases de la aplicación desarrollada para la calibración periódica de sonómetros. (Continuación)	56
4-9. Interfaz gráfica de usuario de la aplicación para sonómetros. Se muestra la pestaña de Patrones.	57
4-10. Interfaz gráfica de usuario de la aplicación para sonómetros. Se muestra la pestaña de Información del IBC.	58
4-11. Interfaz gráfica de usuario de la aplicación para sonómetros. Se muestra la pestaña de Pruebas preliminares y un cuadro de diálogo con una instrucción.	59
4-12. Interfaz gráfica de usuario de la aplicación para sonómetros. Se muestra la pestaña de Pruebas preliminares y la selección del área de interés sobre el vídeo.	59
4-13. Interfaz gráfica de usuario de la aplicación para sonómetros. Se muestra la pestaña de Ponderaciones frecuenciales y temporales y la presentación de resultados.	60
5-1. Grafo de estados y probabilidades de transición que representa la matriz de transición (5-56).	68

Índice de cuadros

4-1. Descripción de los operandos del GRAFCET de la secuencia principal. 48

1. Introducción

1.1. Planteamiento del problema

En la actualidad, la creciente contaminación acústica amerita la implementación de redes de monitoreo continuo de ruido o mediciones puntuales empleando instrumentos adecuados como son los sonómetros con el propósito de cuantizar los niveles de ruido ambiental, de emisión de ruido de fuentes sonoras específicas y de exposición sonora, para luego comparar con los niveles máximos permitidos por la normativa relacionada nacional e internacional y tomar decisiones al respecto. Para garantizar la confiabilidad de tales mediciones o asegurar la validez de sus resultados, en Colombia, entidades como el Instituto de Hidrología, Meteorología y Estudios Ambientales (IDEAM) exigen que las organizaciones que prestan estos servicios cuenten con sonómetros calibrados periódicamente bajo el estándar internacional IEC 61672-3:2013, por parte de un organismo de evaluación de la conformidad (OEC), en este caso un laboratorio de calibración acreditado por el Organismo Nacional de Acreditación de Colombia (ONAC) bajo el estándar ISO 17025, con el fin de verificar que estos instrumentos continúan cumpliendo las especificaciones normalizadas según su clase. La norma IEC 61672-3 describe una serie de pruebas acústicas y eléctricas que se realizan a sonómetros integradores clase 1 y 2, cuyo propósito es comprobar el funcionamiento del sonómetro en: 1) La sensibilidad de su micrófono (para lo cual se usa un calibrador acústico calibrado previamente y que esté en conformidad con las especificaciones de la IEC 60942). 2) Las redes de ponderación frecuencial A, C y Z. 3) En las ponderaciones temporales F (fast) y S (slow). 4) En el rango lineal. 5) En la medición de niveles promediados en el tiempo, niveles de exposición sonora y niveles pico. 6) En la indicación de sobrecarga. 7) En la exposición a largos períodos de medición y a niveles de sonido elevados. Dicha comprobación se hace comparando con las especificaciones definidas en la norma IEC 61672-1:2013.

1.2. Objetivos

1.2.1. General

Desarrollar un sistema de calibración periódica de sonómetros y calibradores acústicos de conformidad con las normas IEC 61672-3:2013 e IEC 60942:2017.

1.2.2. Específicos

1. Formular un modelo en GRAFCET como base para el desarrollo de un sistema de calibración periódica de calibradores acústicos.
2. Implementar las secuencias de comando (a través de bus GPIB) para configurar parámetros de señal y, a su vez, recibir resultados de los instrumentos de medición.
3. Desarrollar un método de reconocimiento de imágenes para detectar los niveles instantáneos ponderados en tiempo y en frecuencia desde la pantalla del sonómetro.
4. Desarrollar un método que permita tener en cuenta la variabilidad de los niveles en pantalla instantáneos ponderados en tiempo y en frecuencia del objetivo 3, (mediante mediciones de larga duración), para la estimación del mesurando y de la incertidumbre de medición.

1.2.3. Alcance de los objetivos

El sistema de calibración se implementará para ejecutar las pruebas de calibración de los numerales 9.3 (apoyado en la IEC 60942), 13, 14 y 16 de la IEC 61672-3. Los indicadores de interés serán los niveles instantáneos con ponderación temporal (*slow* o *fast*) y ponderación frecuencial (A , C , o Z), i.e. L_{AF} , L_{AS} , L_{CF} , L_{CS} , L_{ZF} o L_{ZS} , dependiendo de la prueba y según estén disponibles en el sonómetro sujetos al periodo de actualización de la pantalla del sonómetro. El sistema tendrá en cuenta el modelo del proceso estocástico para la estimación de incertidumbre expandida de medición.

1.2.4. Antecedentes

Sistemas de calibración comerciales desarrollados por fabricantes

Sistemas de calibración desarrollados por otras organizaciones

2. Metodología e instrumentación

En este capítulo se hace una descripción de los instrumentos bajo calibración (calibradores acústicos y sonómetros), seguida de un resumen de los lineamientos de las normas internacionales para las calibraciones periódicas, incluyendo expresiones matemáticas para el cálculo de los voltajes de prueba y otras consideraciones prácticas para los ensayos. Luego se presentan los patrones y otros instrumentos importantes necesarios para la calibración junto con los esquemas de interconexión. Finalmente se explican brevemente los comandos para el control remoto de los instrumentos de medición.

2.1. Instrumentos bajo calibración

2.1.1. Calibradores acústicos

De acuerdo con la normativa internacional, un calibrador acústico es un dispositivo diseñado para producir uno o más niveles de presión sonora conocidos (en dB referenciados a $20 \mu\text{Pa}$) a una o más frecuencias especificadas (en Hz) cuando se acopla a modelos específicos de micrófono en configuraciones específicas ([IEC-TC29, 2017](#)).

Figura 2-1.: Calibrador acústico multifunción Brüel & Kjær 4226.



Tomado de <https://www.transcat.com/bruel-kjaer-4226-acoustic-calibrator-94-104-and-114db-used>

Normalmente, la señal senoidal es generada por algún transductor, como un altavoz o, en el caso de los pistófonos, un pistón mecánico cuyo movimiento genera en la cavidad una velocidad de volumen conocida. Como ejemplo, en la figura 2-1 se muestra un calibrador acústico multi-función usado como referencia en muchos laboratorios: el Brüel & Kjær 4226, que es capaz de generar 94 dB, 104 dB y 114 dB en las frecuencias de octava desde 31,5 Hz hasta 16 kHz, más la frecuencia de 12,5 Hz.

Figura 2-2.: Calibrador acústico Brüel & Kjær 4231 acoplado al micrófono de un sonómetro Brüel & Kjær 2250.

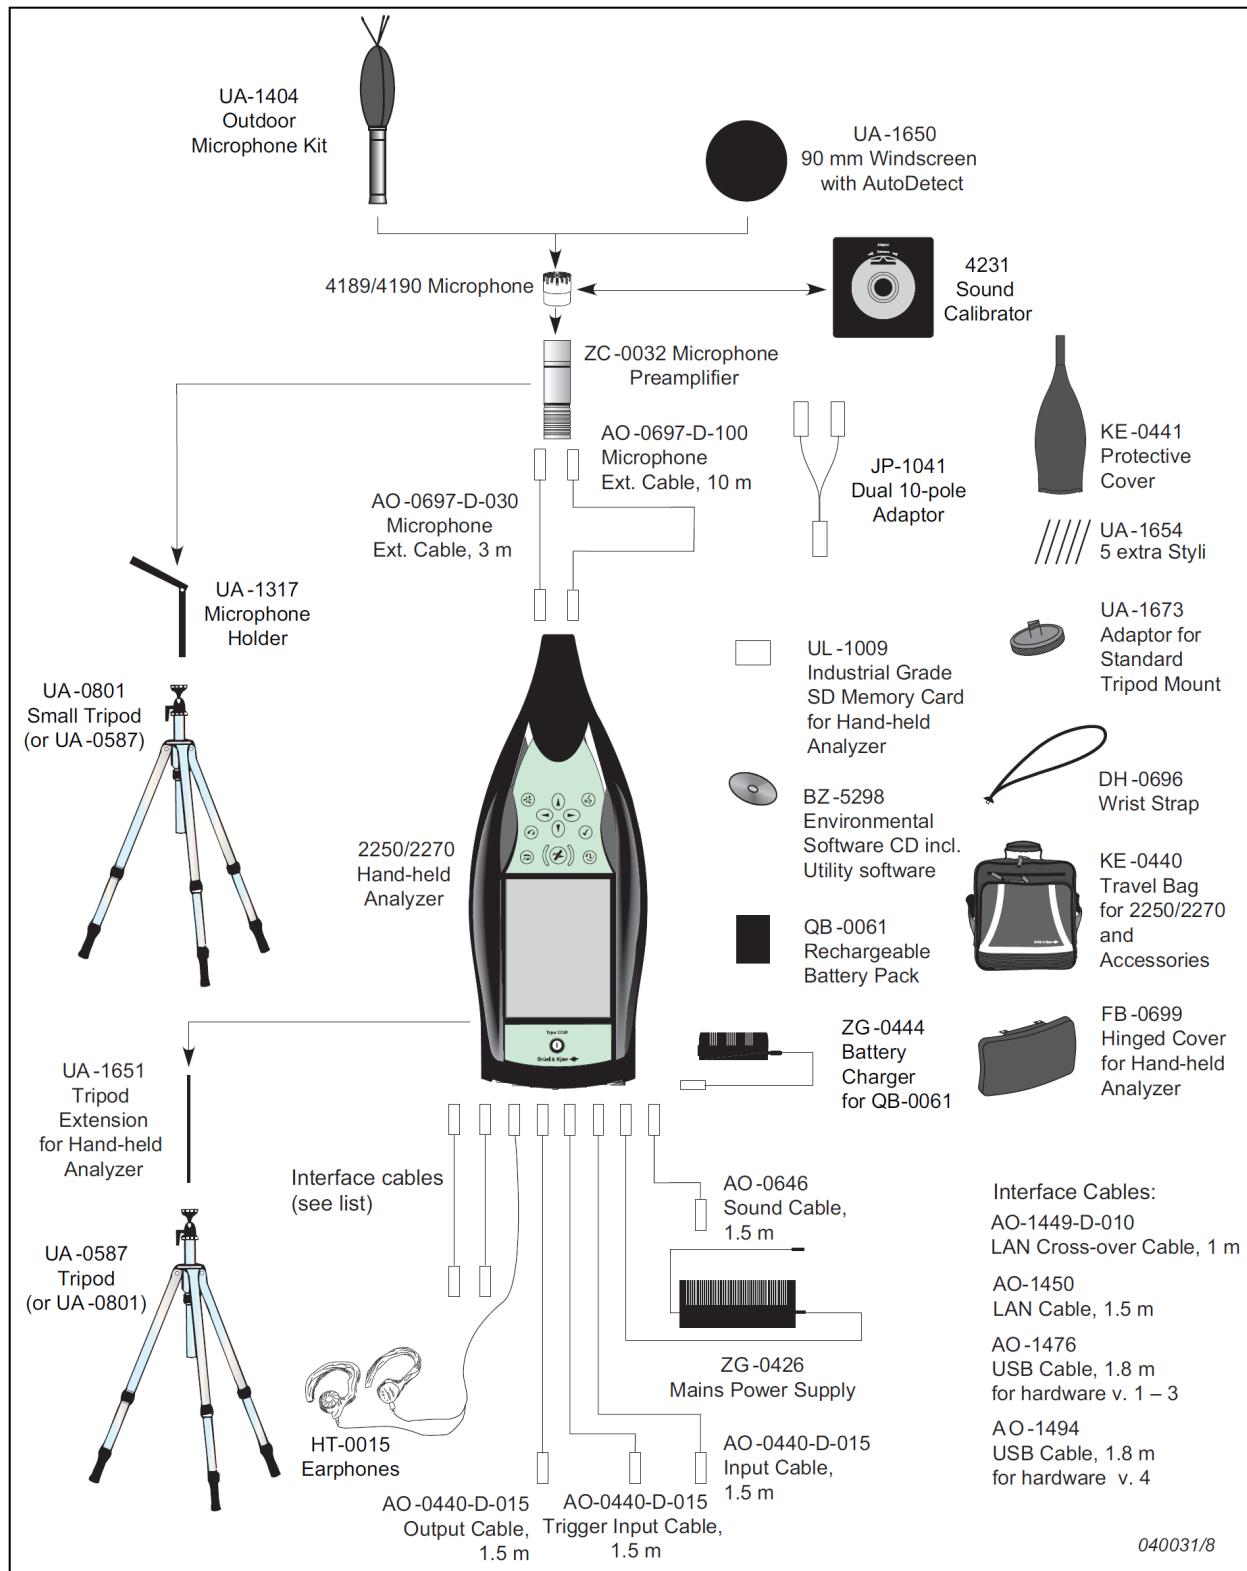


Tomado de <https://www.bksv.com/en/knowledge/blog/sound/getting-started-sound-level-meter>

Generalmente los calibradores acústicos son empleados para determinar la sensibilidad en campo de presión (típicamente en mV/Pa o en dB referenciados a 1 V) de modelos especificados de micrófonos en configuraciones dadas, pero también es utilizado para verificar o ajustar la sensibilidad de algún dispositivo o sistema de medición acústica. Un ejemplo de calibrador acoplado para comprobar la indicación de un sonómetro se muestra en la figura 2-2.

La norma IEC 60942 (2017) establece una clasificación de los calibradores según sus especificaciones (límites de aceptación), de la más a la menos restrictiva: Clase LS (*laboratory standard*), clase 1 o clase 2. La comprobación de que cierto modelo de calibrador cumple con todas las especificaciones normalizadas según su clase la realiza una organización independiente acreditada para hacer pruebas de aprobación de modelo de acuerdo con los lineamientos de la IEC 60942 (Anexo A 2017). Adicionalmente, un usuario de un calibrador acústico debería calibrar periódicamente su instrumento para garantizar la trazabilidad a los estándares nacionales y la confiabilidad de sus resultados. Esta calibración periódica es llevada a cabo por organismos evaluadores de la conformidad acreditados en ISO 17025 (2017) para realizar los ensayos periódicos de acuerdo con la IEC 60942 (Anexo B 2017).

Figura 2-3.: Configuraciones de hardware del sonómetro Brüel & Kjær 2250.

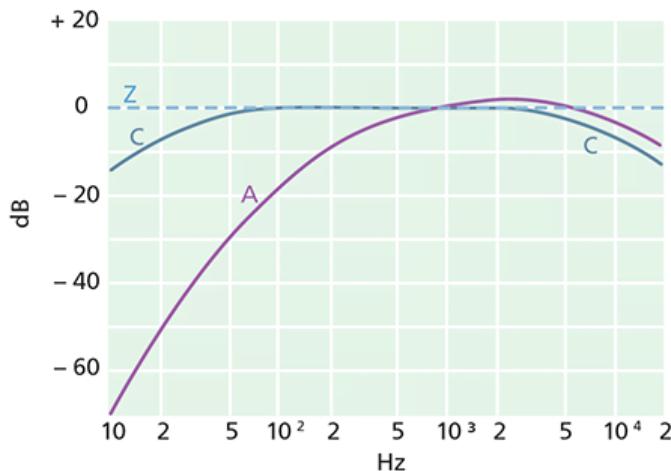


2.1.2. Sonómetros integradores

Brüel & Kjær, uno de los fabricantes más prominentes de sonómetros define consistentemente los conceptos básicos sobre dichos instrumentos en uno de sus artículos (B&K, 2021). Básicamente, un sonómetro es un instrumento diseñado para medir niveles de sonido de una forma estandarizada; su respuesta al sonido se asemeja a la del oído humano y proporciona medidas de niveles de presión sonora objetivas y reproducibles. Generalmente, los sonómetros son empleados en el monitoreo de ruido proveniente de diversas fuentes sonoras, como plantas industriales, tráfico rodado, aeronáutico o ferroviario, conciertos, etc. Como se puede ver en la figura 2-3, un sonómetro típico consta de un micrófono, un preamplificador, una unidad de procesamiento de señal (interna) y una pantalla. Regularmente el preamplificador hace parte del cuerpo del sonómetro, pero no siempre es el caso; un sonómetro podría estar provisto de cables de extensión que separan el preamplificador de la unidad de procesamiento.

En cuanto al flujo de señal, el micrófono es un transductor electroacústico que transforma la señal acústica en una señal eléctrica. La mayoría de los micrófonos empleados en mediciones acústicas son de condensador, y gracias a su construcción es el mejor tipo para garantizar precisión, estabilidad y confiabilidad en los resultados. No obstante, la señal eléctrica proporcionada por un micrófono es de baja amplitud (aún con micrófonos de alta gama cuya sensibilidad se encuentra típicamente en el orden de los 50 mV/Pa , por lo que se requiere una amplificación para que la unidad de procesamiento manipule la señal en un nivel adecuado, este es el objetivo del preamplificador. Luego, en la unidad de procesamiento se ejecutan diferentes cálculos a partir de la señal. Los mínimos requeridos por la norma internacional IEC 61672-1 (2013a) y utilizados en este proyecto se detallan a continuación.

Figura 2-4.: Gráfico de las ponderaciones frecuenciales A, C y Z.



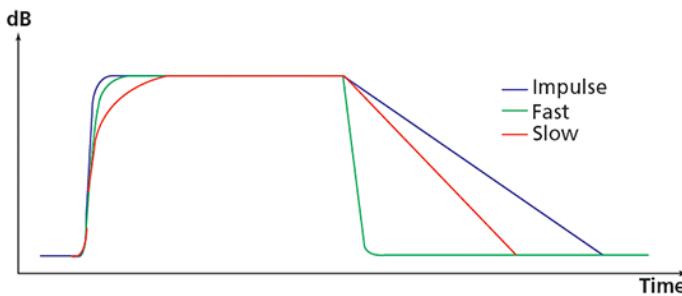
Tomado de (B&K, 2021).

Ponderación frecuencial: Diferencia (como una función especificada de la frecuencia) entre el nivel de la señal ponderada en frecuencia indicado en el dispositivo de presentación de resultados y el nivel correspondiente de una señal de entrada sinusoidal de amplitud constante (IEC-TC29, 2013). En la figura 2-4 se pueden ver gráficamente las ponderaciones frecuenciales.

Estas ponderaciones frecuenciales estandarizadas A , C , o Z , para las bandas de tercio de octavas están definidas en la IEC61672-11 (Tabla 2013a). En concreto, cada una de estas ponderaciones modifican la respuesta del sonómetro frente a diferentes frecuencias de sonido. Por ejemplo, la ponderación A asemeja la respuesta en frecuencia al comportamiento del oído humano en un rango medio de niveles, tomando como referencia la curva de igual sonoridad de 40 dB (Fletcher y Munson, 1933), por tal motivo es el más empleado en ruido ambiental y ocupacional. Pero el oído humano no tiene un comportamiento lineal, y la percepción del sonido varía con el nivel. La ponderación C está basada en la curva de igual sonoridad de 100 dB, por eso esta es empleada en la evaluación de niveles pico de sonidos altos. Finalmente, la ponderación zero (Z) es completamente plana en todo el rango de frecuencias (sin tener en cuenta la respuesta del micrófono).

Ponderación temporal: Es una función exponencial temporal que modifica la respuesta temporal del sonómetro frente a las variaciones en el nivel de presión sonora. Una comparación entre las respuestas en el tiempo de cada ponderación temporal se muestra en la siguiente figura.

Figura 2-5.: Gráfico de las respuestas en el tiempo de las ponderaciones temporales fast, slow e impulse.



Tomado de (B&K, 2021).

Esta función exponencial obedece a una constante de tiempo especificada que depende de la ponderación temporal elegida, bien sea F (fast, $\tau_F = 125$ ms), S (slow, $\tau_S = 1$ s) o I (impulse, $\tau_I = 35$ ms). Por lo tanto, tal como lo define la norma, para una señal con ponderación X , el nivel de sonido con ponderación temporal Y está dado por la siguiente ecuación:

$$L_{XY}(t) = 10 \log \left(\frac{\frac{1}{\tau_Y} \int_{-\infty}^t p_X^2(\xi) e^{-(t-\xi)/\tau_Y} d\xi}{p_0^2} \right) \text{dB.} \quad (2-1)$$

Donde τ_Y es la constante de tiempo en segundos de la ponderación temporal, ξ es una variable ficticia del tiempo de integración desde un instante de tiempo en el pasado ($-\infty$) hasta el instante de observación t , $p_X(\xi)$ es la señal de presión acústica instantánea con ponderación frecuencial X , y p_0 es el valor de referencia de $20 \mu\text{Pa}$.

Consecuentemente, un nivel de sonido, objeto de evaluación en las pruebas aquí implementadas puede ser L_{AF} , L_{AS} , L_{CF} , L_{CS} , L_{ZF} o L_{ZS} para las ponderaciones frecuenciales A , C , o Z y para las ponderaciones temporales *fast* o *slow*. El resultado de la medición de nivel de sonido es mostrado directamente en la pantalla del sonómetro o alguna otra herramienta de visualización como una interfaz web. En algunos sonómetros según su tecnología y disposiciones del fabricante, el resultado de medición es enviado vía serial o en forma de una señal DC o AC de amplitud proporcional al nivel de sonido.

La norma IEC 61672-1 (2013a) establece una clasificación de los sonómetros según sus especificaciones: clase 1 o clase 2. La comprobación de que cierto modelo de sonómetro cumple con todas las especificaciones normalizadas, según su clase, la realiza una organización independiente acreditada para hacer pruebas de aprobación de modelo de acuerdo con los lineamientos de la IEC61672-22 (2013b). Pero también un usuario de un sonómetro debería calibrar periódicamente su instrumento para garantizar la trazabilidad a los estándares nacionales y la confiabilidad de sus resultados. Esta calibración periódica es llevada a cabo por organismos evaluadores de la conformidad acreditados en ISO 17025 (2017) para realizar los ensayos periódicos de acuerdo con la IE61672-3-3 (2013c).

Adicionalmente, la sensibilidad del transductor (micrófono) y la respuesta de los circuitos electrónicos puede variar con el paso del tiempo presentando unas pequeñas derivas o también pueden verse afectadas por las condiciones ambientales como la temperatura y la humedad. Por esto, es una buena práctica verificar regularmente la sensibilidad del sonómetro (preferiblemente antes y después de cada campaña de medición). De este modo, el sonómetro será ajustado a un nivel de referencia conocido emitido por un calibrador acústico cuyo nivel tenga trazabilidad metrológica.

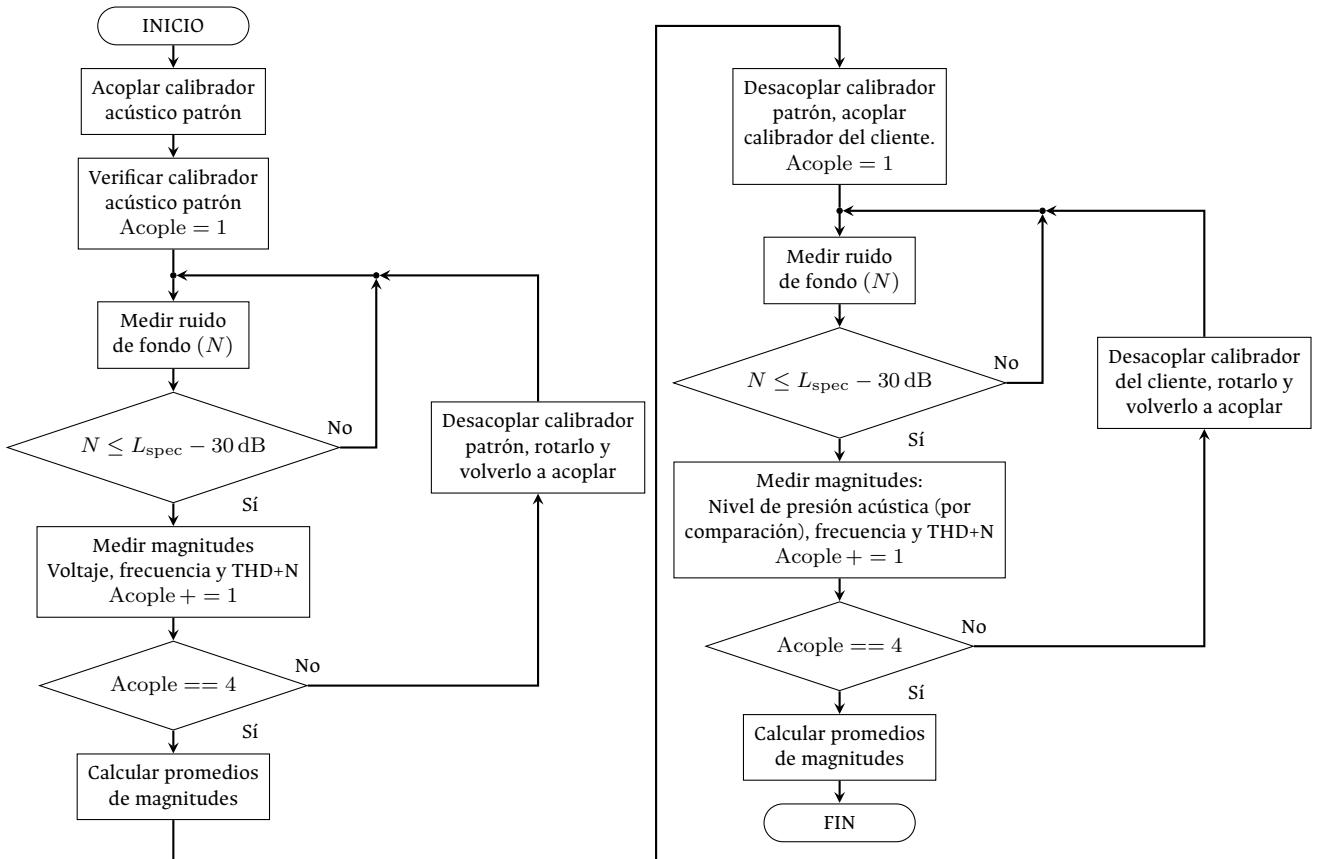
2.2. Métodos normalizados

Las especificaciones y metodología de calibración de instrumentación acústica y de vibraciones son normalizadas por el comité técnico 29 de la Comisión Electrotécnica Internacional (IEC) en colaboración con la Organización Internacional de Metrología Legal (OIML). A continuación, un resumen del proceso de calibración de calibradores acústicos y sonómetros, con especial enfoque en los pasos operativos, más que en las disposiciones preliminares de las normas.

2.2.1. Descripción general de la calibración periódica de calibradores acústicos de acuerdo con la IEC 60942:2017

En la siguiente figura se presenta un diagrama que describe en general el proceso de calibración de calibradores acústicos, el cual es explicado en detalle a continuación.

Figura 2-6.: Diagrama de flujo general de la calibración periódica de calibradores acústicos.



Fuente: Elaboración propia.

Tal como se describe en la IEC 60942 (Anexo B 2017), el calibrador acústico o pistófono con todos sus accesorios necesarios (como adoptadores o barómetro) debe ser entregado junto con el manual de instrucciones, si este es requerido por el laboratorio de calibración. Luego, se hace una inspección visual del calibrador acústico, verificando que todos los controles están funcionando y que la fuente de alimentación está operando dentro de los límites especificados en el manual de instrucciones. En seguida, se toman en cuenta o se realizan las siguientes secciones.

Orientación para los ensayos. Si en el manual de instrucciones se especifica alguna orientación del calibrador acústico, esta debe ser la utilizada en la calibración periódica.

Ruido ambiental. Para evitar que el ruido ambiental afecte las mediciones, las pruebas sólo se realizan si el nivel de presión sonora con el calibrador acoplado al micrófono (pero con el calibrador apagado) es por lo menos 30 dB por debajo del nivel especificado que se está midiendo.

Influencia de las condiciones ambientales. Cuando es apropiado, la información suministrada en el manual de instrucciones sobre la influencia de la presión estática debe ser aplicada para corregir el nivel de presión medido a la presión estática de referencia.

Nivel de presión sonora. Después de acoplar el calibrador acústico al micrófono, se debe dejar el tiempo de estabilización indicado en el manual de instrucciones. Luego, el nivel de presión sonora generado por el calibrador debe ser medido como un promedio de los valores instantáneos obtenidos durante un periodo t_{op} de entre 20 s y 25 s de operación.

Para medir el nivel de presión sonora hay propuestos dos métodos en la norma internacional: Usando un micrófono de referencia o usando un calibrador acústico de referencia para comparación. En este proyecto se utiliza el segundo, en el que el nivel del calibrador bajo prueba es determinado por comparación contra el nivel generado por un calibrador acústico calibrado cuya trazabilidad metrológica esté establecida. Como la señal a analizar es eléctrica, el nivel de presión se determina como una diferencia logarítmica:

$$L = L_{\text{ref}} + 20 \log \left(\frac{\bar{v}}{\bar{v}_{\text{ref}}} \right). \quad (2-2)$$

En que L es el nivel de presión sonora del calibrador acústico bajo calibración, L_{ref} es el nivel de presión certificado del calibrador acústico patrón, y \bar{v} y \bar{v}_{ref} son el voltaje medio medido con el calibrador del cliente y con el calibrador de referencia durante el tiempo t_{op} respectivamente.

El nivel de presión sonora debe ser medido al menos tres veces, cada vez acoplando el micrófono y el calibrador acústico antes de la medición y desacoplándolo después. En cada nuevo acoplamiento se debe rotar el micrófono sobre su eje. La diferencia absoluta entre el nivel medido medio y el nivel especificado no debe exceder los límites establecidos en la IEC 60942 (Tabla 2 2017), según la clase del calibrador y la frecuencia medida. La medición de nivel de presión sonora debe ser repetida para cada combinación de nivel y frecuencia que indique el manual de instrucciones que cumple con las especificaciones de la norma.

Frecuencia, debe ser medida con el calibrador acoplado al micrófono como un promedio de los valores instantáneos obtenidos durante el tiempo t_{op} , para cada frecuencia disponible en el calibrador, de la cual se indique en el manual que cumple con las especificaciones de la norma. El valor absoluto de la diferencia porcentual a cada frecuencia medida (ver ecuación 2-3) y la correspondiente frecuencia especificada no debe exceder los límites establecidos en la IEC 60942

(Tabla 4 2017), según la clase del calibrador.

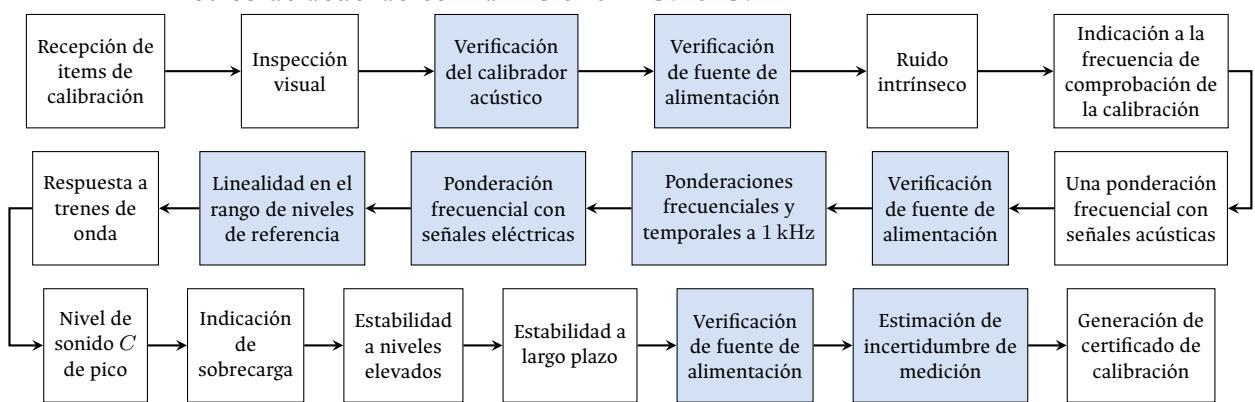
$$\%error = \left| \frac{\bar{f}}{f_{\text{spec}}} - 1 \right| \times 100. \quad (2-3)$$

En que \bar{f} es la frecuencia media medida durante el tiempo t_{op} y f_{spec} es la frecuencia especificada bajo calibración.

Distorsión armónica total más ruido (THD+N), la distorsión de la señal generada por el calibrador debe medirse con un ancho de banda de 22,4 Hz a 22,4 kHz, como un promedio de los valores instantáneos obtenidos durante el tiempo t_{op} , en los niveles máximo y mínimos disponibles a cada frecuencia de los que se indique en el manual que cumple con las especificaciones de la norma. La THD+N puede ser medida utilizando un filtro de rechazo (medidor de factor de distorsión) o un analizador FFT. La THD+N medida no debe exceder los límites establecidos en la IEC 60942 (Tabla 7 2017), según la clase del calibrador. Es obligatorio que la magnitud medida sea no sólo distorsión armónica total, sino distorsión armónica total más ruido, reportada en porcentaje (%).

2.2.2. Descripción general de las pruebas periódicas seleccionadas de acuerdo con la IEC 61672-3:2013

Figura 2-7.: Diagrama de bloques del proceso de medición en la calibración periódica de sonómetros de acuerdo con la IEC 61672-3:2013.



Fuente: Elaboración propia.

En el diagrama de bloques de la figura 2-7 se presenta de forma general el proceso de calibración periódica de sonómetros. Los bloques resaltados en azul son los procesos objeto de automatización en este proyecto¹. A continuación se describen en detalle las etapas en el proceso de calibración.

¹Aún con la automatización de estas actividades, hay tareas que deben ser realizadas manualmente por el usuario

En principio, de conformidad con la IEC 661672-3 (2013c), el sonómetro con todos sus accesorios necesarios (como preamplificador, micrófono, cable de extensión o adaptador de impedancia) debe ser entregado junto con el manual de instrucciones, si este es requerido por el laboratorio de calibración. Toda la información necesaria para los ensayos periódicos debe estar disponible, como correcciones de campo libre, rangos de medición, niveles de referencia, etc. Se debe contar con un calibrador acústico conforme con las especificaciones de la IEC 60942 (2017) según su clase, ya sea suministrado por el cliente o por el laboratorio.

Luego, se hace una inspección preliminar del sonómetro y todos sus accesorios, verificando que todos los controles están funcionando, que la pantalla está en buen estado, que no haya acumulación de material extraño en la rejilla o membrana del micrófono y que otros elementos esenciales estén en un funcionamiento adecuado. Después se verifica que la fuente de alimentación está operando dentro de los límites especificados en el manual de instrucciones. La fuente de alimentación será verificada nuevamente después de los ensayos con señales acústicas y después de los ensayos con señales eléctricas. A continuación, se detallan las pruebas que serán efectuadas. Para todas las pruebas eléctricas se emplea el dispositivo de entrada (acoplador de impedancia) recomendado por el fabricante del sonómetro o uno que tenga una capacitancia similar que emule adecuadamente la carga del micrófono en el preamplificador.

Indicación a la frecuencia de comprobación de la calibración

El calibrador acústico entregado por el cliente o proporcionado por el laboratorio se acopla al micrófono del sonómetro, y, si es necesario, se ajusta el sonómetro para indicar el nivel de presión acústica requerido en las condiciones ambientales en las que se realizan los ensayos. Las indicaciones antes y después del ajuste deben registrarse. Se debe tomar en cuenta el efecto de la presión estática sobre el calibrador acústico empleado. Este calibrador ya debió haber sido verificado previamente, según el procedimiento descrito en la sección 2.2.1.

Después de haber ajustado el sonómetro en respuesta al nivel generado por el calibrador, un paso necesario (antes de continuar con las otras pruebas) es determinar el voltaje que produce una indicación del nivel de referencia. La siguiente ecuación es empleada para determinar ese voltaje:

$$v_{\text{ref}} = 10^{\frac{(L_{v,l} + (L_{v,u} - L_{v,l})/2)}{20}}. \quad (2-4)$$

Donde v_{ref} es el voltaje medio en una escala logarítmica que produce una indicación del nivel de referencia, $L_{v,l}$ es el nivel de voltaje inferior del intervalo que produce una indicación del

dadas las limitaciones físicas o de la naturaleza misma de los equipos. Por ejemplo, el usuario debe ajustar la orientación del calibrador acústico, encenderlo o apagarlo, configurar en el sonómetro los indicadores en pantalla, etc.

nivel de referencia, y $L_{v,u}$ el nivel de voltaje superior. Los niveles de voltaje son referenciados a 1 V. En concreto, este voltaje de referencia es el voltaje en la mitad (en una escala logarítmica) de un intervalo de voltajes que producen todos una misma indicación del nivel de referencia. Con el voltaje de referencia se calculan los voltajes correspondientes a los niveles de señal en las demás pruebas.

Ponderaciones frecuenciales y temporales a 1 kHz

Se utiliza una señal eléctrica continua de 1 kHz con una amplitud tal que produzca una indicación del nivel de referencia en el sonómetro (i.e. v_{ref}) y se siguen los pasos a continuación:

- PFT-1** Registrar el nivel indicado en las ponderaciones frecuenciales A , C y Z (según estén disponibles) con el sonómetro ajustado en ponderación temporal F o nivel promediado en el tiempo²; i.e. L_{AF} , L_{CF} , L_{ZF} , L_{Aeq} , L_{Ceq} o L_{Zeq} .
- PFT-2** Registrar el nivel indicado en las ponderaciones temporales F y S , y el nivel promediado en el tiempo³ (según estén disponibles) con el sonómetro ajustado en ponderación frecuencial A ; i.e. L_{AF} , L_{AS} o L_{Aeq} .
- PFT-3** Calcular las desviaciones de los niveles ponderados en frecuencia C y Z respecto al ponderado en frecuencia A del paso 1. Estas desviaciones no deben superar los límites de aceptación de $\pm 0,2$ dB.
- PFT-4** Calcular las desviaciones del nivel promediado en el tiempo y del nivel con ponderación temporal S , respecto al nivel con ponderación temporal F del paso **PFT-2**. Estas desviaciones no deben superar los límites de aceptación de $\pm 0,1$ dB.

Ponderaciones frecuenciales con señales eléctricas

Se utilizan señales eléctricas sinusoidales continuas para todas las ponderaciones frecuenciales reguladas en la IEC 61672-1 ([2013a](#)) (que estén disponibles en el sonómetro). Y se siguen los pasos a continuación:

- PFSE-1** Se ajusta el sonómetro para mostrar niveles de sonido con ponderación temporal F , niveles promediados en el tiempo o niveles de exposición sonora⁴.

²Como en este trabajo se busca reconocer el resultado instantáneo mostrado en pantalla, el nivel elegido preferiblemente es el que tiene ponderación temporal F .

³El nivel promediado en el tiempo sólo sería posible registrarlo automáticamente si este es mostrado en pantalla.

⁴Como en este trabajo se busca reconocer el resultado instantáneo mostrado en pantalla, el nivel elegido es

PFSE-2 Se ajusta el sonómetro en el rango de niveles de referencia y se envía una señal de 1 kHz cuya amplitud produzca una indicación en el sonómetro que sea 45 dB menos que el límite superior indicado en el manual de instrucciones para el rango de funcionamiento lineal a 1 kHz.

Para automatizar este paso, se usa la siguiente ecuación:

$$v_{1\text{kHz}} = 10^{\hat{\left(\frac{20 \log(v_{\text{ref}}) + L_{\text{ref}} - (L_{u@1\text{kHz}} - 45)}{20}\right)}}. \quad (2-5)$$

En que $v_{1\text{kHz}}$ es el voltaje que produce una indicación de 45 dB menos que el límite superior del rango lineal a 1 kHz; v_{ref} es el voltaje que produce una indicación del nivel de referencia L_{ref} ; y, $L_{u@1\text{kHz}}$ es el límite superior del rango lineal a 1 kHz especificado en el manual de instrucciones.

PFSE-3 Se registran los niveles de las señales de entrada y las correspondientes indicaciones. Para sonómetros clase 1 en las nueve frecuencias nominales en intervalos de octava de 63 Hz a 16 kHz. Para sonómetros clase 2 en las ocho frecuencias nominales en intervalos de octava de 63 Hz a 8 kHz.

En frecuencias diferentes a 1 kHz el voltaje de la señal de entrada se determina mediante

$$v_f = 10^{\hat{\left(\frac{20 \log(v_{1\text{kHz}}) - W_{X,f}}{20}\right)}}. \quad (2-6)$$

En que v_f es el voltaje de la señal a la frecuencia f , $v_{1\text{kHz}}$ es el voltaje del paso anterior y $W_{X,f}$ es el factor de la ponderación frecuencial elegida X para la frecuencia f .

PFSE-4 Se calculan las ponderaciones frecuenciales relativas como $L_f - L_{1\text{kHz}}$, i.e. el nivel indicado a una frecuencia de ensayo menos el nivel indicado a 1 kHz.

PFSE-5 Aplicar factores de corrección a las ponderaciones frecuenciales relativas del paso anterior que den cuenta de:

PFSE-5.1 La desviación de la respuesta en frecuencia en campo libre o para incidencia aleatoria de un micrófono en la dirección de referencia respecto a una respuesta en frecuencia uniforme.

PFSE-5.2 Los efectos de las reflexiones en la carcasa del sonómetro y de la difracción del sonido alrededor del micrófono y del amplificador.

PFSE-5.3 Si aplica, la influencia de la pantalla antiviento y de cualquier accesorio que sea parte de la configuración normal del sonómetro.

preferiblemente el que tiene ponderación temporal F.

PFSE-6 Las ponderaciones frecuenciales relativas corregidas son las desviaciones respecto a los objetivos de diseño según la ponderación frecuencial bajo calibración y no deben exceder los límites de aceptación dados en la IEC 61672-1 (Tabla 3 [2013a](#)).

Linealidad de nivel en el rango de niveles de referencia

Se utilizan señales eléctricas sinusoidales continuas a una frecuencia de 8 kHz con el sonómetro ajustado en el rango de niveles de referencia, en ponderación frecuencial A, y con ponderación temporal F o un nivel promediado en el tiempo, i.e. L_{AF} o L_{Aeq} , y se siguen los pasos a continuación:

LNRR-1 Comenzar con una señal de entrada cuya amplitud produce el punto de partida para los ensayos de linealidad a 8 kHz especificado en el manual de instrucciones. Y registrar el nivel indicado.

LNRR-2 Aumentar el nivel de la señal de entrada en saltos de 5 dB desde el punto de partida hasta un nivel que se encuentre dentro de 5 dB por debajo del límite superior del rango de funcionamiento lineal a 8 kHz especificado en el manual. Luego, aumentar en saltos de 1 dB hasta, pero sin incluir, la primera indicación de sobrecarga. Se deben registrar las indicaciones del sonómetro en cada punto.

LNRR-3 Disminuir el nivel de la señal de entrada en saltos de 5 dB desde el punto de partida hasta un nivel que se encuentre dentro de 5 dB por encima del límite inferior del rango de funcionamiento lineal a 8 kHz especificado en el manual. Luego, disminuir en saltos de 1 dB hasta, pero sin incluir, la primera indicación de “por debajo del rango”. Se deben registrar las indicaciones del sonómetro en cada punto.

LNRR-4 Calcular las desviaciones de nivel como la diferencia entre el nivel indicado y el nivel previsto. Estas desviaciones no deben superar los límites de $\pm 0,8$ dB para la clase 1 o de $\pm 1,1$ dB para la clase 2.

Para automatizar esta prueba, el voltaje en el punto de partida se determina como

$$v_{L_{start}} = 10^{\left(\frac{20 \log(v_{ref}) + L_{start} - L_{ref} - W_{A,8\text{kHz}} - E_{A,8\text{kHz}}}{20} \right)}. \quad (2-7)$$

En que $v_{L_{start}}$ es el voltaje que causa una indicación del nivel en el punto de partida L_{start} ; v_{ref} es el voltaje que produce una indicación del nivel de referencia, $W_{A,8\text{kHz}}$ es el factor estandarizado de la ponderación A en la frecuencia de 8 kHz que tiene el valor de $-1,1$ dB y $E_{A,8\text{kHz}}$ es la ponderación relativa a 1 kHz (sin corregir), obtenida en la prueba de ponderaciones frecuenciales en la frecuencia de 8 kHz en la ponderación frecuencial A.

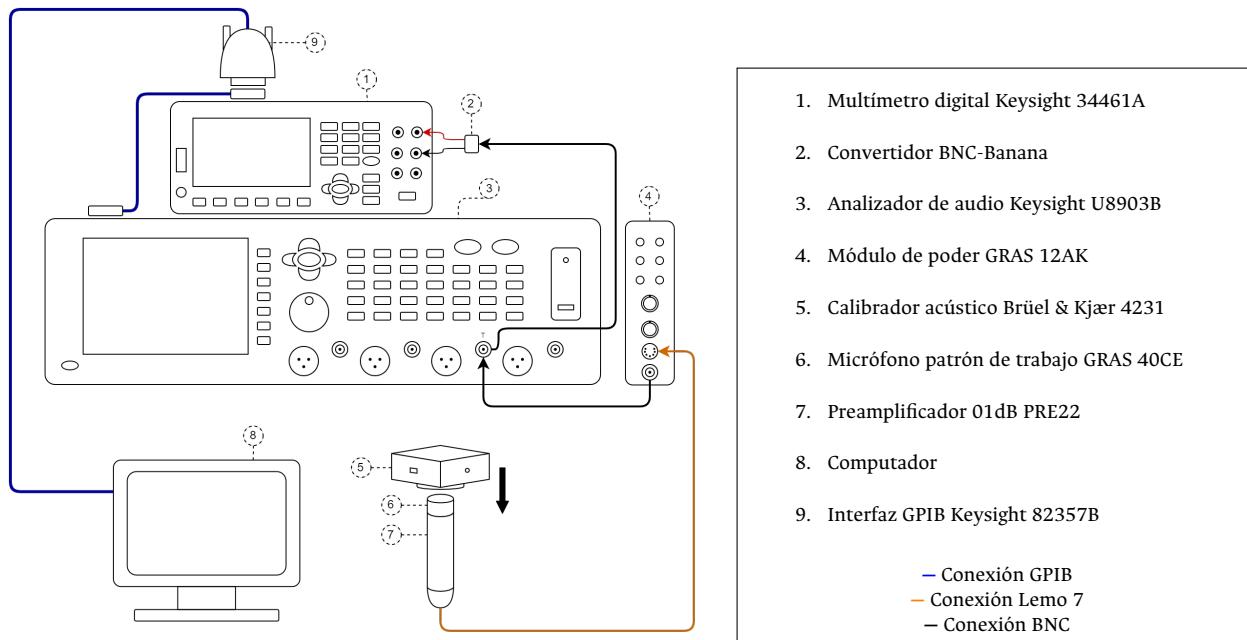
Luego, a partir de ese voltaje en el punto de partida, el voltaje $v_{L_{\text{prev}}}$ para cada punto de calibración o nivel previsto L_{prev} a lo largo del rango de niveles, se calcula como:

$$v_{L_{\text{prev}}} = 10^{\frac{20 \log(v_{L_{\text{start}}}) + L_{\text{prev}} - L_{\text{start}}}{20}}. \quad (2-8)$$

2.3. Instrumentación

Los instrumentos presentados a continuación fueron elegidos teniendo en cuenta los requisitos metrológicos para obtener resultados confiables y trazables, como también asegurando que tengan las prestaciones mínimas para implementar el control remoto desde un ordenador.

Figura 2-8.: Esquema de conexiones de los instrumentos para la calibración periódica de calibradores acústicos.



Fuente: Elaboración propia.

2.3.1. Patrones e instrumentos para la calibración periódica de calibradores acústicos

La interconexión propuesta de los instrumentos empleados en la calibración de calibradores acústicos se presenta en la figura 2-8. A continuación se describen las características de cada instrumento.

Figura 2-9.: Patrones acústicos para la calibración de calibradores acústicos.



(a) Calibrador acústico Brüel & Kjær 4231 usado como patrón de laboratorio.



(b) Micrófono patrón de trabajo GRAS 40CE.

Figura 2-10.: Instrumentos para adecuación de la señal eléctrica.



(a) Vista inferior del micrófono GRAS 40CE (izquierda abajo), preamplificador para micrófonos de 1/2" 01dB PRE22 (medio) y adaptador de impedancia 01dB ADP12 con su terminal de aterrizaje (derecha).



(b) Módulo de poder para preamplificadores y micrófonos GRAS 12AK.

Como bien indica la norma IEC 60942 (2017), uno de los posibles métodos para calibrar calibradores acústicos es por comparación contra un calibrador patrón. Ese es el método elegido en este trabajo. El calibrador acústico patrón elegido debe ser de las especificaciones más altas posibles, y su elección también determina el alcance de calibración del laboratorio. Para este trabajo se emplea el calibrador Brüel & Kjær 4231 (ver figura 2-9a), el cual es de clase LS y tiene disponibles dos niveles de presión sonora (94 dB y 114 dB) a 1 kHz. La trazabilidad de este calibrador se mantiene directamente con el fabricante.

El método requiere también un micrófono de referencia con el cuál se pueda transformar la señal acústica en una señal eléctrica para que pueda ser analizada posteriormente en amplitud,

frecuencia y distorsión armónica más ruido (THD+N). Se empleó el micrófono GRAS 40CE (ver figura 2-9b), el cual es un micrófono de campo libre con una sensibilidad típica de 40 mV/Pa y cuenta con su certificado de calibración de fábrica, en el que es posible determinar la diferencia entre las respuestas de campo libre y de campo de presión a 1 kHz.

La señal eléctrica del micrófono debe ser adecuada antes de medirla, por lo que se usa un preamplificador 01dB PRE22 (ver figura 2-10a). Para polarizar el preamplificador se usa un módulo de poder GRAS 12AK, el cual también puede darle mayor ganancia a la señal para mejorar la relación señal a ruido, aplicarle un filtro paso alto para eliminar la interferencia de baja frecuencia y permite hacer el acople de impedancias apropiado para conectar la señal a la entrada de los instrumentos de medición. Este módulo se muestra en la figura 2-10b.

Figura 2-11.: Instrumentos de medición para la calibración periódica de calibradores acústicos.



(a) Multímetro digital Keysight 34461A.



(b) Analizador de audio Keysight U8903B.

Para medir el voltaje AC y la frecuencia se requiere un multímetro digital con suficientes dígitos de resolución que aporten la precisión requerida y no afecte negativamente la incertidumbre de medición. El multímetro empleado es el Keysight 34461A de $6\frac{1}{2}$ dígitos (mostrado en la figura 2-11a), que, aunque su impacto es proporcional con la escala de medición, en dB resulta ser despreciable. En Hz, debido a la escala lineal, tendrá un impacto mayor, pero sigue siendo despreciable. Cabe resaltar que, dependiendo de la escala, no todos los dígitos están disponibles en la pantalla del multímetro, pero sí pueden adquirirse todos siempre por la interfaz remota. Este multímetro mantiene su trazabilidad a los patrones nacionales.

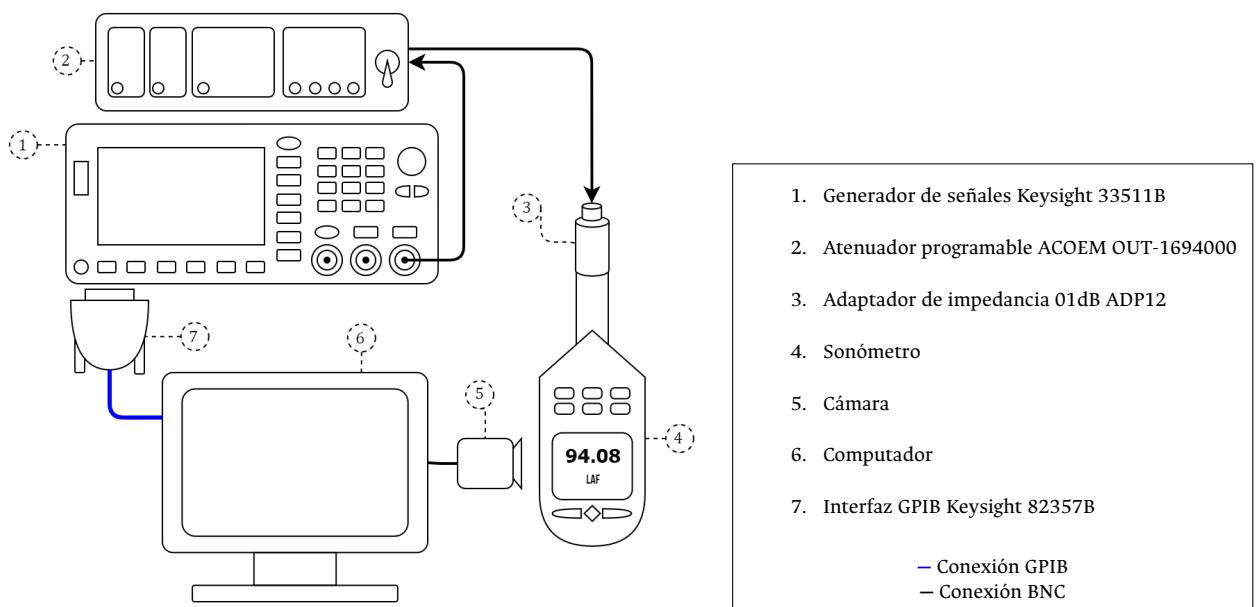
En cuanto a la THD+N, podría usarse una interfaz de sonido con un software de análisis en frecuencia, pero establecer su trazabilidad metrológica es poco factible. Se requiere un instrumento que igualmente pueda ser calibrado por un laboratorio acreditado para esta magnitud inusual. Tal es el analizador de audio Keysight U8903B, que cuenta con una resolución de 7 dígitos, disponibles completamente sólo mediante la interfaz remota. Este instrumento cuenta con bastantes prestaciones especializadas para el análisis de audio. Entre estas, unas importan-

tes para los propósitos de este trabajo son: Establecer la impedancia de entrada, tipo de entrada (balanceada o no balanceada), desacople DC de la señal de entrada, filtros paso alto o paso bajo para la entrada, frecuencia de muestreo variable y cálculo de estadísticas en tiempo real. Este analizador se muestra en la figura 2-11b.

Ambos instrumentos de Keysight cuentan con la interfaz de comunicación GPIB, mediante la cual estos pueden conectarse a un sólo puerto USB del computador para su control con instrucciones SCPI.

2.3.2. Patrones e instrumentos para la calibración periódica de sonómetros

Figura 2-12.: Esquema de conexiones de los instrumentos para la calibración periódica de sonómetros.



Fuente: Elaboración propia.

La interconexión propuesta para la calibración de sonómetros se presenta en la figura 2-12. A continuación se describe cada instrumento.

Figura 2-13.: Instrumentos utilizados en la calibración periódica de sonómetros.



(a) Generador de funciones arbitrarias Keysight 33511B.



(b) Atenuador programable ACOEM OUT-1694000.

El flujo de señal inicia en el generador de señales. En este trabajo se empleó el generador de funciones arbitrarias Keysight 33511B (véase figura 2-13a), que tiene excelentes prestaciones como la definición personalizada de formas de onda y un desempeño superior dada su baja distorsión armónica (típicamente 0,04 %), amplio ancho de banda e intervalo de voltaje, bajo efecto de jitter, su filtro anti-alias, su resolución de amplitud de 16 bit y de frecuencia de 1 μ Hz, respuesta en frecuencia plana ($\pm 0,10$ dB en todo el rango inferior a 100 kHz), alta precisión en amplitud (± 1 % del valor establecido ± 1 mV) y en frecuencia (± 2 ppm del valor establecido ± 15 pHz). El generador 33511B también cuenta con la interfaz de comunicación GPIB para su control remoto. Este generador cumple la función de patrón de medición, generando señales eléctricas para simular los niveles de presión sonora, y mantiene su trazabilidad a los patrones nacionales.

A pesar de que el generador tiene un rango de voltaje AC amplio (1 mVpp a 10 Vpp), para la mayoría de aplicaciones en sonómetros (cuyos micrófonos tienen sensibilidades típicas entre 40 mV a 50 mV), con el fin de alcanzar los niveles más altos (cercaos a los 140 dB), se requieren voltajes del orden de 13 Vrms aproximadamente, y para los niveles más bajos (cercaos a los 23 dB), se requieren voltajes del orden de 7 μ Vrms. Por tal motivo se hace necesario un dispositivo adicional que amplifique la señal hasta al menos 6 dB más y que sea capaz de atenuarla hasta al menos 50 dB. Para esto se usó un Decade Box o atenuador programable fabricado por ACOEM, el cual se muestra en la figura 2-13b.

Finalmente, el flujo de señal termina en el adaptador de impedancias. Este debe ser preferiblemente el recomendado en el manual de instrucciones del sonómetro, o en su defecto debe usarse uno cuya capacitancia se equipare a la capacitancia del micrófono del sonómetro y que por supuesto tenga el mismo diámetro y rosca. Como ejemplo, para sonómetros marca 01dB, se utiliza el adaptador 01dB ADP12, que se muestra en la figura 2-10a.

Adicionalmente, para capturar el valor de medición indicado en la pantalla del sonómetro, se usa una cámara web conectada al computador.

2.3.3. Comandos SCPI

En esta sección se explica de forma general el protocolo de comandos estándar para instrumentos programables (SCPI), tomando como guía de referencia el manual del generador Keysight 33511B (2015).

Los comandos SCPI son un lenguaje basado en ASCII para instrumentos de medición y de pruebas. Estos comandos están basados en una estructura jerárquica conocida como sistema de árbol, en el que los comandos asociados están agrupados bajo un nodo o raíz común, formando así los subsistemas. Por ejemplo, una parte de la estructura del sistema OUTPut es la siguiente:

```
OUTPut:  
    SYNC {OFF|0|ON|1}  
    SYNC:  
        MODE {NORMal|CARRier}  
        POLarity {NORMal|INVerted}
```

Las líneas sin sangría son los sistemas raíces y cada nivel de sangría corresponde al nivel del subsistema en la jerarquía. El ":" separa una palabra clave de otra en un nivel más bajo. Las letras en mayúsculas son abreviaciones de las palabras clave de los comandos, que también pueden ser usadas opcionalmente, quitando las letras en minúsculas de la palabra clave. Las llaves {}, en realidad indican que se esperan los parámetros para un comando dado, los cuales pueden tomar valores numéricos, booleanos, cadenas de texto o palabras clave que denotan valores preestablecidos. Si un comando espera más de un parámetro, estos son separados por comas. Por ejemplo, para habilitar la salida del generador ajustándolo en una forma de onda senoidal de 1 kHz, con una amplitud de 50 mV y un offset DC de 0 V, se enviaría el siguiente comando: APPL:SIN 1E3,50E-3,0.0.

También se puede reducir la extensión de los códigos usando ";" para separar instrucciones de un mismo sistema de mayor nivel. Por ejemplo, la instrucción TRIG:SOUR BUS; COUNT 30 logra el mismo efecto que las instrucciones TRIG:SOUR BUS y TRIG:COUNT 30 enviadas una tras otra.

Se puede consultar el valor actual de la mayoría de parámetros de sistemas o subsistemas usando "?". Por ejemplo, con el comando :CALC:STAT:DATA1? se obtiene el primer valor estadístico calculado por el analizador de audio, según se haya configurado previamente.

Cada instrumento de Keysight usado en este trabajo cuenta con un conjunto específico de siste-

mas y subsistemas para realizar las funciones particulares según su naturaleza, los cuales pueden ser consultados en las guías de referencia de comandos SCPI de los respectivos manuales o, de una forma mucho más interactiva, en la aplicación *Command Expert* de Keysight. También hay comandos comunes a la mayoría de instrumentos como los siguientes: *IDN? (consulta la información de identificación del instrumento) y *TST? (ejecuta la secuencia de autoverificación del instrumento).

El control remoto de los instrumentos con comandos SCPI se implementó en Python con la librería PyVisa ([2022](#)), la cual requiere que en el computador esté instalada por lo menos la librería VISA de National Instruments o, como en este desarrollo, la Keysight IO Library Suite ([Keysight, 2022](#)), las cuales son totalmente gratuitas.

3. Sistema de reconocimiento de imágenes para el valor de medición

En esta sección se discute el desarrollo del sistema de reconocimiento de caracteres que será empleado para adquirir automáticamente un valor de medición que sea indicado en la pantalla del sonómetro bajo calibración. Primero se introduce un algoritmo general con los pasos de procesamiento y clasificación de las imágenes; luego, se presenta el fundamento teórico de cada uno de esos pasos. Finalmente, se muestran y discuten los resultados de procesamiento de imagen sobre una muestra de un dígito, como también los resultados del clasificador implementado.

Algoritmo de reconocimiento de caracteres

De manera general, la solución propuesta, para el reconocimiento del valor de medición indicado en la pantalla del sonómetro, consta de varios pasos que se presentan en el siguiente algoritmo.

Algoritmo 3.1: Algoritmo del sistema de reconocimiento de imágenes.

Data: `images` \leftarrow Imágenes de entrenamiento si va a entrenar o fotos de la pantalla si va reconocer.
output: Clases estimadas.

```
1 training  $\leftarrow$  True | False
2 foreach image  $\in$  images do
3   \\\Las operaciones sobre image son realizadas in place.
4   Paso 1: Filtrar image con filtro gaussiano.
5   Paso 2: Escalar y hacer padding a image para hacerla de  $31 \times 32$  píxeles.
6   Paso 3: Segmentar image determinando el umbral con el método de Otsu (1979).
7   if training = False then
8     Detectar contornos y extraer dígitos.
9   Paso 4: Calcular las características de image con el descriptor SIFT (Lowe, 2004).
10  Paso 5: Reducir dimensionalidad de las características por KPCA (Schölkopf et al., 1997).
11  Agregar las características a la matriz features.
12 Paso 6:
13 if training then
14   Entrenar clasificador bayesiano normal con features y las correspondientes etiquetas de clase.
15 else
16   Estimar las clases de las características en features con el clasificador bayesiano normal.
```

Concerniente al procesamiento y reconocimiento de imágenes, a continuación se presenta un breve marco de referencia teórico de cada paso del algoritmo 3.1.

Paso 1: Filtro gaussiano

Como se explica en el libro de Robert Szeliski (2011), el filtro gaussiano, también llamado filtro de suavizado o de desenfoque, es una operación local en imágenes bidimensionales, pues se efectúa en vecindarios con un tamaño determinado en píxeles; el valor final de un píxel depende de los valores de los píxeles que pertenecen a su correspondiente vecindario y, como en todos los casos de filtros lineales, de una función de ponderación. Esta operación local viene a ser la de correlación ($g = f \otimes h$), que básicamente es la suma ponderada de los píxeles de entrada, que se define como

$$g(i, j) = \sum_{k,l} f(i + k, j + l) h(k, l). \quad (3-9)$$

En que g es la imagen de salida, f es la imagen de entrada y h la máscara o kernel, que contiene los coeficientes del filtro.

La operación contraparte de la correlación sería la convolución ($g = f * h$), en la que se usa el kernel invertido y se define como

$$g(i, j) = \sum_{k,l} f(k, l) h(i - k, j - l). \quad (3-10)$$

En que h es la respuesta al impulso, ya que si se convoluciona la máscara h con una señal impulsiva $\delta(i, j)$, se obtiene la misma máscara ($h * \delta = h$).

Para el caso del filtro gaussiano, el kernel se obtiene a partir de la típica función exponencial de Gauss. Particularmente, considerando la implementación de OpenCV que se ejecuta con la instrucción `GaussianBlur()`, la función sería la bivariada no correlacionada definida como

$$h(x, y) = \frac{1}{2\pi\sigma_x\sigma_y} \exp\left(-\frac{(x - \mu_x)^2}{2\sigma_x^2} - \frac{(y - \mu_y)^2}{2\sigma_y^2}\right). \quad (3-11)$$

La función de OpenCV también permite especificar un tamaño definido de ventana y esta calculará automáticamente las varianzas como

$$\sigma_x = \left(\frac{n_x - 1}{2}\right) 0.3 + 0.8, \quad \text{en que } n_x = \text{ancho} - 1; \quad (3-12a)$$

$$\sigma_y = \left(\frac{n_y - 1}{2}\right) 0.3 + 0.8, \quad \text{en que } n_y = \text{alto} - 1. \quad (3-12b)$$

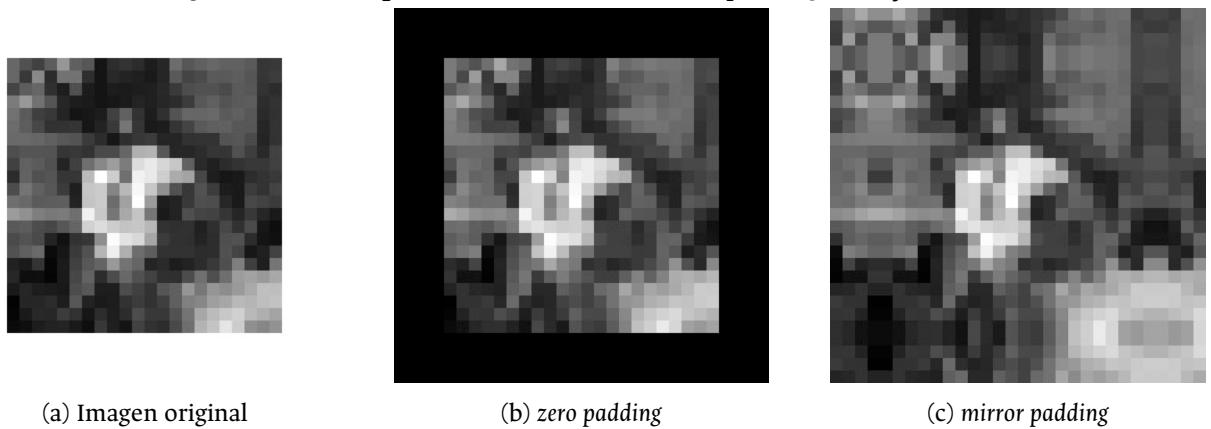
Paso 2: Escalización y padding

Por supuesto, en la práctica, el filtrado requiere que se agreguen píxeles en los bordes de la imagen original, según el tamaño determinado de la ventana; a esto se le conoce como *padding* y es una operación que realiza por defecto OpenCV, con la que es posible elegir el modo del *padding*. Existen diferentes modos de *padding*, de los cuales se describen los siguientes:

- *zero*: Todos los píxeles añadidos se establecen en 0.
- *mirror*: Refleja los últimos píxeles del borde.

En la siguiente figura se muestra el resultado de ambos modos de *padding*.

Figura 3-1.: Comparación de los modos de *padding*: *zero* y *mirror*.



Tomado de ([Richard, 2011](#)).

El modo *mirror* es utilizado para el filtro gaussiano y el *zero* para adecuar la imagen antes del [paso 3](#) con el fin de completar el tamaño de 32×32 píxeles requerido para el [paso 4](#).

Como la imagen que contiene el dígito tendrá un tamaño diferente a 32×32 , antes de efectuar el *zero padding*, es necesario escalarla haciendo que el eje de mayor dimensión se ajuste a 32 píxeles y el otro eje se ajuste proporcionalmente; esta operación se lleva a cabo con la función `resize()` de OpenCV. Luego sí se añaden los píxeles faltantes al eje de menor dimensión para completar los 32 píxeles.

Paso 3: Segmentación

Existen diferentes técnicas de segmentación: basada en umbrales, en bordes, en regiones, por agrupación o por *matching*. Para los propósitos de este trabajo, es suficiente con una umbralización para discriminar los segmentos de la imagen, que corresponderían a los dígitos indicados en la pantalla del sonómetro. Sin embargo, el umbral no puede ser el mismo para todas las imágenes, pues cada una puede estar influenciada por los efectos de iluminación, áreas o colores de los segmentos. Una forma sistemática de determinar el umbral es empleando el algoritmo de Otsu (1979). Este algoritmo busca maximizar la separación entre las clases de niveles de grises del histograma de la imagen usando los momentos de cero y primer orden.

La formulación de Otsu es un método *no supervisado*¹ basado en el análisis discriminante para evaluar la bondad del umbral y seleccionar automáticamente un límite óptimo. En primer lugar, el método normaliza el histograma de niveles de grises y lo considera como una distribución de probabilidad.

Si hay L niveles de grises, entonces el número de píxeles en la imagen es $N = n_1 + n_2 + \dots + n_L$; n_i es el número de píxeles que tienen un nivel i . Luego, la distribución de probabilidad queda expresada como

$$p_i = \frac{n_i}{N}, \quad \text{en que } p_i \geq 0, \sum_{i=1}^L p_i = 1. \quad (3-13)$$

Ahora, se buscan dos clases C_0 y C_1 , que corresponden a los píxeles que pertenecen al fondo y a los que pertenecen a los objetos, separados por el nivel de gris de valor k . Las probabilidades de cada clase se definen de acuerdo con

$$\omega_0 = \Pr(C_0) = \sum_{i=1}^k p_i = \omega(k); \quad (3-14a)$$

$$\omega_1 = \Pr(C_1) = 1 - \omega(k). \quad (3-14b)$$

Luego, los valores esperados condicionales de cada clase son:

$$\mu_0 = \sum_{i=1}^k i \Pr(i|C_0) = \sum_{i=1}^k i \frac{p_i}{\omega_0} = \frac{\mu(k)}{\omega(k)}; \quad (3-15a)$$

$$\mu_1 = \sum_{i=k+1}^L i \Pr(i|C_1) = \sum_{i=k+1}^L i \frac{p_i}{\omega_1} = \frac{\mu_T - \mu(k)}{1 - \omega(k)}. \quad (3-15b)$$

¹Los métodos no supervisados son aquellos que no requieren que las muestras de entrenamiento estén etiquetadas previamente según su clase, sino que a partir de los datos identifican patrones que permiten agruparlos.

En que $\omega(k)$ y $\mu(k)$ son los momentos acumulados de cero y primer orden del histograma hasta el k -ésimo nivel. Estos momentos acumulados se definen como

$$\omega(k) = \sum_{i=1}^k p_i; \quad (3-16a)$$

$$\mu(k) = \sum_{i=1}^k i p_i. \quad (3-16b)$$

Similarmente, los momentos de primer y segundo orden de la imagen se definen como

$$\mu_T = \sum_{i=1}^L i p_i; \quad (3-17a)$$

$$\sigma_T^2 = \sum_{i=1}^L (i - \mu_T)^2 p_i. \quad (3-17b)$$

En que μ_T es la media total de los niveles de grises de la imagen original y σ_T^2 la varianza.

En principio, si las clases están separadas en sus niveles de grises entonces hay una umbralización adecuada. Consecuentemente, un umbral que resulte en la mejor separación de clases según sus niveles de grises será un umbral óptimo. Hay por lo menos tres medidas de separación entre clases que se pueden maximizar. Sin embargo, por simplicidad (dado que depende de los momentos de orden cero y uno), conviene usar la medida definida en la siguiente ecuación como criterio para el análisis discriminante.

$$\eta = \frac{\sigma_B^2}{\sigma_T^2}. \quad (3-18)$$

Donde el coeficiente σ_B^2 se define como

$$\sigma_B^2 = \omega_0 \omega_1 (\mu_1 - \mu_0)^2. \quad (3-19)$$

Finalmente, condensando las ecuaciones (3-15) a (3-19), el umbral óptimo k^* que maximiza η y, proporcionalmente, σ_B^2 se encuentra por medio de la siguiente expresión:

$$\sigma_B^2(k^*) = \max_{1 \leq k < L} \sigma_B^2(k). \quad (3-20)$$

En la cual,

$$\sigma_B^2(k) = \frac{[\mu_T \omega(k) - \mu(k)]^2}{\omega(k) [1 - \omega(k)]}. \quad (3-21)$$

Esta optimización se puede realizar de forma iterativa con unos valores iniciales de $\omega(0)$ y $\mu(0)$,

luego iterando con todos los posibles valores de $k = 0, 1, \dots, L$, y calculando $\sigma_B^2(k)$. El umbral óptimo k^* será el máximo valor obtenido de $\sigma_B^2(k)$.

Paso 4: Descriptor local SIFT

En esta aplicación particular (cuyo funcionamiento se pretende en tiempo real), el objeto de reconocimiento es simple, por lo que no hace falta el sofisticado algoritmo de detección, localización y orientación de puntos característicos de la presentación original del descriptor SIFT propuesto por [Lowe \(2004\)](#). No obstante, la implementación del algoritmo aquí presentada sí tiene en cuenta su propuesta de descriptor local basada en la magnitud y dirección de los gradientes de cada píxel perteneciente a la región alrededor de cada punto característico.

En primer lugar, se calcula la magnitud y dirección del gradiente de cada píxel. Esto finalmente es una valoración del cambio direccional en la intensidad de la imagen. La dirección final del gradiente en un píxel es aquella en la que ocurre el máximo cambio de intensidad, y la magnitud sería el máximo cambio de intensidad. Para lo cual se emplean las siguientes ecuaciones:

$$\delta_x = I(x+1, y) - I(x-1, y); \quad (3-22a)$$

$$\delta_y = I(x, y+1) - I(x, y-1); \quad (3-22b)$$

$$\theta(x, y) = \tan^{-1} \left(\frac{\delta_y}{\delta_x} \right); \quad (3-22c)$$

$$|\nabla f(x, y)| = \sqrt{\delta_x^2 + \delta_y^2}. \quad (3-22d)$$

Las diferencias de intensidad en x y en y se determinan con las ecuaciones (3-22a) y (3-22b), luego, la dirección con (3-22c) y la magnitud con (3-22d).

Después de obtener todas las magnitudes y direcciones de los gradientes, se conforma un histograma de orientaciones en 8 intervalos por cada ventana de $n \times n = 4 \times 4$ píxeles; es decir, según la dirección de cada vector, su magnitud se suma en el respectivo intervalo del histograma de la ventana al que pertenece. Finalmente, queda un vector de características de 128 valores que es la concatenación de todos los histogramas, cada uno de 8 valores. Pero la contribución de esta magnitud a su intervalo de orientación correspondiente es ponderada por la función gaussiana de la ecuación (3-23) con σ igual a la mitad del ancho de la ventana del descriptor, con el propósito de dar menor peso a los gradientes que están más lejos del centro del descriptor.

$$G(x, y) = \frac{1}{2\pi\sigma^2} \exp \left(-\frac{x^2 + y^2}{2\sigma^2} \right). \quad (3-23)$$

El objetivo del histograma es permitir que haya cambios locales más grandes en las direcciones de los gradientes, pero que contribuyan al mismo intervalo en el histograma. Ahora bien, pueden ocurrir cambios abruptos en el histograma cuando en realidad hay cambios suaves en las direcciones de las muestras de gradientes, esto debido a los efectos de los límites en los intervalos. Para mitigar este efecto, se aplica una interpolación trilineal² para distribuir la magnitud de cada muestra de gradiente en intervalos de histograma adyacentes, en función de la “distancia” de la dirección de la muestra desde el valor central del intervalo. Esto queda reflejado en las siguientes funciones de ponderación:

$$w_k(x, y) = \begin{cases} \nabla\theta(x, y), & \text{si } k = i\theta(x, y) \\ 1 - \nabla\theta(x, y), & \text{si } k = i\theta \text{ mód } 8 + 1 \\ 0, & \text{en caso contrario} \end{cases} \quad (3-24a)$$

$$w_i(x, y) = \begin{cases} \nabla x(x, y), & \text{si } i = ix(x, y) \\ 1 - \nabla x(x, y), & \text{si } i = ix(x, y) + 1 \\ 0, & \text{en caso contrario} \end{cases} \quad (3-24b)$$

$$w_j(x, y) = \begin{cases} \nabla y(x, y), & \text{si } j = iy(x, y) \\ 1 - \nabla y(x, y), & \text{si } j = iy(x, y) + 1 \\ 0, & \text{en caso contrario} \end{cases} \quad (3-24c)$$

Con las siguientes definiciones:

$$\nabla\theta(x, y) = i\theta(x, y) - \frac{\theta(x, y)}{\delta\theta}, \quad \text{en que } i\theta(x, y) = \left\lceil \frac{\theta(x, y)}{\delta\theta} \right\rceil \text{ y } \delta\theta = 360/n; \quad (3-25a)$$

$$\nabla x(x, y) = ix(x, y) - \frac{x}{\delta x}, \quad \text{en que } ix(x, y) = \left\lceil \frac{x}{\delta x} \right\rceil; \quad (3-25b)$$

$$\nabla y(x, y) = iy(x, y) - \frac{y}{\delta x}, \quad \text{en que } iy(x, y) = \left\lceil \frac{y}{\delta x} \right\rceil. \quad (3-25c)$$

En seguida, se conforma el histograma como se presenta a continuación:

$$H = (H_{11}, H_{12}, \dots, H_{nn});$$

$$H_j = (h_1, h_2, \dots, h_n);$$

$$h_k(x, y) = \sum_{(x,y)} w_k(x, y) w_i(x, y) w_j(x, y) |\nabla f(x, y)| G(x, y). \quad (3-26)$$

Finalmente el arreglo resultante se normaliza para hacerlo invariante a los efectos de contrastes o cambios en la iluminación, y para reducir los efectos de cambios no lineales en iluminación

²La interpolación trilineal es la extensión de la interpolación lineal a un espacio tridimensional ($D = 3$) usando polinomios de primer orden. En la práctica resulta ser la interpolación lineal de dos interpolaciones bilineales. Con esta operación se encuentra un valor intermedio teniendo en cuenta los 2^D valores adyacentes.

debidos a la saturación de la cámara, se limitan los valores con un umbral experimental de 0,2, de manera que los valores inferiores a 0,2 son remplazados con 0,2, y se normaliza nuevamente. La normalización se efectúa empleando la norma L_2 , como se muestra a continuación:

$$H = (H_{11}, H_{12}, \dots, H_{nn}) \Rightarrow v = (v_1, v_2, \dots, v_m).$$

$$\|v\|_2 = \sqrt{\sum_{i=1}^m v_i^2}.$$

$$v' = \left(\frac{v_1}{\|v\|_2}, \frac{v_2}{\|v\|_2}, \dots, \frac{v_m}{\|v\|_2} \right);$$

$$v'' = (\max(v_1, 0.2), \max(v_2, 0.2), \dots, \max(v_m, 0.2));$$

$$v''' = \frac{v''}{\|v''\|_2}.$$

Paso 5: Reducción de dimensionalidad por análisis de componentes principales (KPCA)

Una vez se obtienen los vectores de características de las muestras, conviene un proceso adicional para simplificar el análisis posterior de los datos, mejorar el desempeño en la clasificación, eliminar información redundante o incluso poder obtener representaciones gráficas de los vectores. Generalmente, los vectores de características resultan ser de grandes dimensiones, lo que provoca ciertas desventajas como que al aumentar las dimensiones de los vectores el volumen del espacio aumenta exponencialmente y los datos tienden a volverse dispersos, y esto afecta negativamente la clasificación, pues los datos se organizan en áreas correspondientes a grupos con características similares, y finalmente las estrategias comunes de clasificación no son eficaces. Ese efecto llamado "la maldición de la dimensión" puede ser abordado con diferentes métodos, entre estos la reducción de dimensionalidad tomando las componentes principales del grupo de datos usando el truco del kernel (KPCA) originalmente propuesto por [Schölkopf et al. \(1997\)](#).

En principio se toma el método de análisis de componentes principales (PCA), en el que básicamente se hace una transformación euclídea al rotar y trasladar los ejes para alcanzar la mayor variabilidad descendente en todas las dimensiones. En la práctica, se trazan planos de modo que las distancias de los puntos a estos sean las mínimas posibles. Las componentes principales corresponden a las primeras dimensiones del hiperplano resultante, en las que se encuentra la mayor variabilidad. Para lograr esto se diagonaliza la matriz de covarianza de los

datos $\mathbf{x}_k \in \mathbf{R}^N$, con $k = 1, \dots, \ell$ definida en (3-28). Los datos están centrados en el origen, de modo que $\sum_{k=1}^{\ell} \mathbf{x}_k = 0$.

$$\mathbf{C} = \frac{1}{\ell} \sum_{j=1}^{\ell} \mathbf{x}_j \mathbf{x}_j^\top. \quad (3-28)$$

La diagonalización, en otras palabras, es una descomposición en valores y vectores propios de la matriz \mathbf{C} , y las proyecciones ortogonales de los puntos en los eigenvectores son las componentes principales.

Ahora, suele ocurrir que la separación entre los datos no es del todo lineal y entonces es necesario hacer una transformación no lineal de los datos a un nuevo espacio de características \mathcal{F} , como se describe a continuación:

$$\Phi : \mathbf{R}^N \rightarrow \mathcal{F}, \quad \mathbf{x} \mapsto \mathbf{X}. \quad (3-29)$$

En ese nuevo espacio \mathcal{F} también es posible hacer el análisis PCA. La transformación se realiza usando *kernels*, que son funciones continuas conocidas del método de las máquinas de vectores de soporte (SVM), que además mejoran el costo computacional, porque el cálculo depende del producto interno de los vectores en el nuevo espacio, i.e $\mathbf{k}(\mathbf{x}, \mathbf{x}') = \Phi(\mathbf{x})^\top \cdot \Phi(\mathbf{x}')$.

Luego, si en el espacio original el análisis PCA se hacía con la descomposición de $\lambda \mathbf{x}_k \mathbf{V} = \mathbf{x}_k \mathbf{C} \mathbf{V}$, en el nuevo espacio de características, equivalentemente se hace la descomposición del sistema

$$\lambda (\Phi(\mathbf{x}_k) \cdot \mathbf{V}) = (\Phi(\mathbf{x}_k) \cdot \bar{\mathbf{C}} \mathbf{V}), \quad \forall k = 1, \dots, \ell. \quad (3-30)$$

$$\text{Con } \bar{\mathbf{C}} = \frac{1}{\ell} \sum_{j=1}^{\ell} \Phi(\mathbf{x}_j) \Phi(\mathbf{x}_j)^\top.$$

Luego, el vector propio puede ser expresado como una combinación lineal de los datos transformados:

$$\mathbf{V} = \frac{1}{\ell \lambda} \sum_{i=1}^{\ell} (\Phi(\mathbf{x}_i) \cdot \mathbf{V}) \Phi(\mathbf{x}_i); \quad (3-31a)$$

$$\mathbf{V} = \sum_{i=1}^{\ell} \alpha_i \Phi(\mathbf{x}_i). \quad (3-31b)$$

Ahora, para generar el producto interno de los vectores, se multiplica a ambos lados de (3-31b) por $\Phi(\mathbf{x}_j)$, y se obtiene

$$\mathbf{V} \cdot \Phi(\mathbf{x}_j) = \lambda \ell \alpha_j = \sum_{i=1}^{\ell} \alpha_i (\Phi(\mathbf{x}_i) \cdot \Phi(\mathbf{x}_j)) = \sum_{i=1}^{\ell} \alpha_i \mathbf{K}_j. \quad (3-32)$$

Recordando que $\mathbf{K}_j := \Phi(\mathbf{x}_i \cdot \Phi(\mathbf{x}_j))$.

Finalmente, expresando (3-32) de forma vectorial y matricial se llega a que el problema de eigenvalores a resolver es:

$$\ell \lambda \boldsymbol{\alpha} = \mathbf{K} \boldsymbol{\alpha}. \quad (3-33)$$

De este modo, los valores propios de \mathbf{K} son proporcionales a los valores propios de $\bar{\mathbf{C}}$ y la extracción de características se haría tomando los eigenvalores más grandes.

Como funciones de *kernel* pueden usarse diferentes funciones (e.g. polinomial, sigmoide, etc). En este caso, se utilizó uno de base radial como el *kernel* gaussiano que se presenta en la siguiente ecuación:

$$k(\mathbf{x}, \mathbf{y}) = e^{\left(-\frac{\|\mathbf{x}-\mathbf{y}\|^2}{2\sigma^2}\right)}. \quad (3-34)$$

Paso 6: Clasificador bayesiano normal

En la última etapa de un sistema de visión de máquina se encuentra el reconocimiento e interpretación, en la cual se utilizan diversas técnicas. Una de las más clásicas es el clasificador paramétrico supervisado basado en la teoría de decisión de Bayes formulada de forma general a continuación.

$$P(A|B) = \frac{P(A) P(B|A)}{P(B)}. \quad (3-35)$$

En la que se toma A como hipótesis y B como la evidencia.

Generalmente, se hacen simplificaciones en el modelo asumiendo que hay independencia entre las características de entrada, de manera tal que se asume que la presencia o ausencia de una característica no afecta a las otras, entonces cada característica contribuye independientemente a la probabilidad del evento A . A este caso se le llama *clasificador ingenuo*.

Ahora, en términos de clases (y_i) y características (\mathbf{X}), la ecuación (3-35) puede ser expresada como

$$P(y_i|\mathbf{X}) = \frac{P(y_i) P(\mathbf{X}|y_i)}{P(\mathbf{X})}; \quad (3-36a)$$

$$P(y_i|\mathbf{x}_1, \dots, \mathbf{x}_n) = \frac{P(y_i) P(\mathbf{x}_1, \dots, \mathbf{x}_n|y_i)}{P(\mathbf{x}_1, \dots, \mathbf{x}_n)}. \quad (3-36b)$$

Al asumir la independencia entre las características de entrada, es posible reescribir (3-36b) usando la regla de la cadena, y queda que

$$P(y_i|\mathbf{x}_1, \dots, \mathbf{x}_n) = \frac{P(y_i) \prod_{j=1}^n P(\mathbf{x}_j|y_i)}{P(\mathbf{x}_1, \dots, \mathbf{x}_n)}. \quad (3-37)$$

En la práctica, el denominador de (3-37) permanece constante, y como además no depende de la clase, puede omitirse y queda que la probabilidad de una clase y_i dadas las características \mathbf{X} es proporcional a la productoria, es decir,

$$P(y_i|\mathbf{x}_1, \dots, \mathbf{x}_n) \propto P(y_i) \prod_{j=1}^n P(\mathbf{x}_j|y_i). \quad (3-38)$$

Finalmente, la clase por la que se decide el clasificador es aquella que tiene mayor probabilidad, como se define en la siguiente expresión:

$$\hat{y} = \arg \max_{y_i} P(y_i) \prod_{j=1}^n P(\mathbf{x}_j|y_i). \quad (3-39)$$

Ahora, tanto los parámetros del modelo, como las clases a priori y las características de las distribuciones de probabilidad, se determinan sobre el conjunto de datos de entrenamiento. Los parámetros del modelo se determinan haciendo estimaciones de máxima verosimilitud, maximizando la función de distribución de probabilidad, i.e. derivando respecto a cada parámetro e igualando a 0.

Cuando los datos pueden tomar valores de una función continua, generalmente se asume que siguen una distribución normal, la cual se presenta su versión multivariada en la siguiente expresión:

$$\begin{aligned} p(\mathbf{x}_k) &\sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma}); \\ &\sim \frac{1}{(2\pi)^{d/2} |\boldsymbol{\Sigma}|^{1/2}} \exp\left(-\frac{1}{2} (\mathbf{x}_k - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x}_k - \boldsymbol{\mu})\right). \end{aligned} \quad (3-40)$$

En la estimación de máxima verosimilitud (MLE), con el fin de maximizar la función y encontrar los parámetros de la distribución, conviene operar (3-40) expresada en funciones monótonamente crecientes como el logaritmo natural y la suma, lo que se denomina *log-verosimilitud*, como se muestra a continuación.

$$\ell(\boldsymbol{\theta}) = \sum_{k=1}^n -\frac{1}{2} (\mathbf{x}_k - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x}_k - \boldsymbol{\mu}) - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln |\boldsymbol{\Sigma}|. \quad (3-41)$$

Los parámetros a encontrar son $\theta_1 = \boldsymbol{\mu}$ y $\theta_2 = \Sigma$, que al hacer la maximización de (3-41) quedan definidos como

$$\hat{\theta}_1 = \hat{\boldsymbol{\mu}} = \frac{1}{n} \sum_{k=1}^n \mathbf{x}_k; \quad (3-42a)$$

$$\hat{\theta}_2 = \hat{\Sigma} = \frac{1}{n} \sum_{k=1}^n (\mathbf{x}_k - \hat{\boldsymbol{\mu}})(\mathbf{x}_k - \hat{\boldsymbol{\mu}})^\top. \quad (3-42b)$$

Para conformar el clasificador normal bayesiano, en primer lugar se asume que cada clase tiene una distribución normal de la misma forma que la ecuación (3-40), y sus parámetros $\boldsymbol{\mu}$ y Σ dependen de los datos que, en la etapa de entrenamiento, se ha determinado que describen la distribución normal de cada clase. Y entonces la ecuación (3-40) pasa a ser la probabilidad de \mathbf{x}_j dada una clase y_i , cuyos parámetros de distribución de probabilidad están dados por:

$$\boldsymbol{\mu}_i = \frac{1}{n_i} \sum_{j=1}^n z_{ij} \mathbf{x}_j, \quad \text{en que } z_{ij} = \begin{cases} 1, & \text{si } \mathbf{x}_j \in y_i \\ 0, & \text{si no} \end{cases}; \quad (3-43a)$$

$$\Sigma_i = \frac{1}{n_i} \sum_{j=1}^n z_{ij} (\mathbf{x}_j - \boldsymbol{\mu}_i)(\mathbf{x}_j - \boldsymbol{\mu}_i)^\top, \quad \text{en que } z_{ij} = \begin{cases} 1, & \text{si } \mathbf{x}_j \in y_i \\ 0, & \text{si no} \end{cases}. \quad (3-43b)$$

Con estas probabilidades condicionales se combina (3-40) con (3-39); primero definiendo las funciones discriminantes con log-verosimilitud como

$$\begin{aligned} g_i(\mathbf{x}) &= \ln p(\mathbf{x}|y_i) + \ln P(y_i); \\ &= -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_i)^\top \Sigma_i^{-1} (\mathbf{x} - \boldsymbol{\mu}_i) - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln |\Sigma_i| + \ln P(y_i). \end{aligned} \quad (3-44)$$

Finalmente, la función (3-44) se utiliza para decidir la clase a la que pertenecen las características $\mathbf{x} = x_1, \dots, x_d$ de una muestra dada. La clase de salida nuevamente es la que tenga la mayor probabilidad, es decir:

$$\hat{y} = \arg \max_{y_i} g_i(\mathbf{x}). \quad (3-45)$$

Resultados

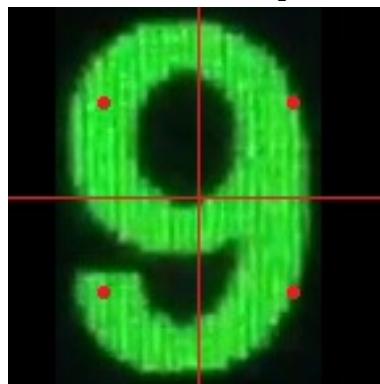
A continuación se presentarán algunos detalles en la implementación de los procesamientos presentados en las secciones anteriores y ejemplos de los resultados. Las imágenes del conjunto de entrenamiento y de prueba fueron obtenidas fotografiando la pantalla de un sonómetro marca 01dB, modelo CUBE. Un ejemplo se muestra en la siguiente figura.

Figura 3-2.: Ejemplo de una fotografía de la pantalla de un sonómetro 01dB CUBE.



Para el filtro gaussiano se empleó $\sigma_x = \sigma_y = 1,5$. Luego, con el fin de simplificar el cálculo del descriptor SIFT, se escala la imagen de un dígito y se rellenan los píxeles faltantes para conformar una imagen de 32×32 . Después, se eligen cuatro puntos clave que corresponden a los centros de cada cuadrante como se presenta en la siguiente figura.

Figura 3-3.: Puntos clave para el cálculo del descriptor SIFT de una imagen de un dígito.

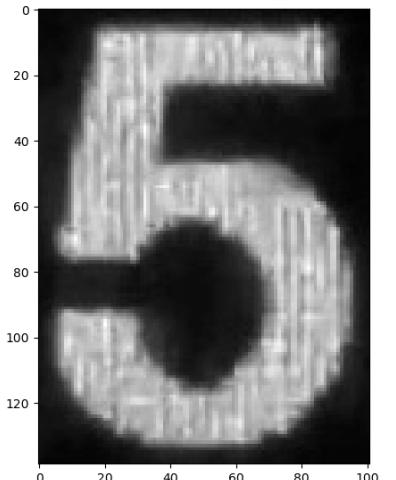


En esos puntos se calcula el descriptor SIFT, no sin previamente haber umbralizado la imagen redimensionada con el método de Otsu. De forma tal que queda un vector de características con 512 valores para cada muestra.

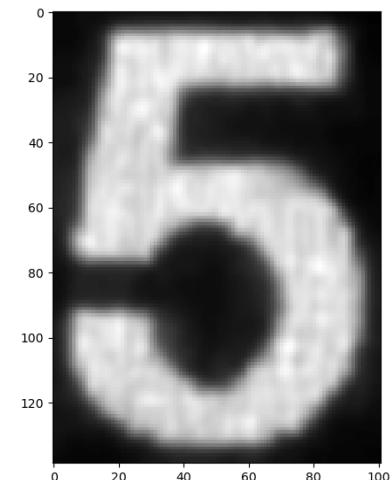
Una breve implementación de este procesamiento se presenta en el código [A.1](#), que posteriormente será usado en la aplicación desarrollada para automatizar la calibración de sonómetros.

En la siguiente figura se muestran los resultados de los pasos 1 al 3 del algoritmo [3.1](#) para una muestra de entrenamiento del número 5.

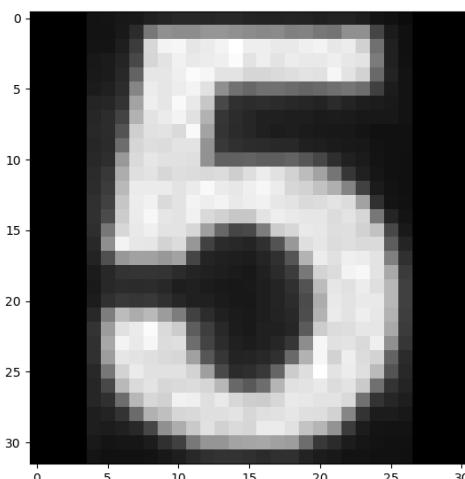
Figura 3-4.: Resultados de procesamiento de una muestra de entrenamiento del número 5.



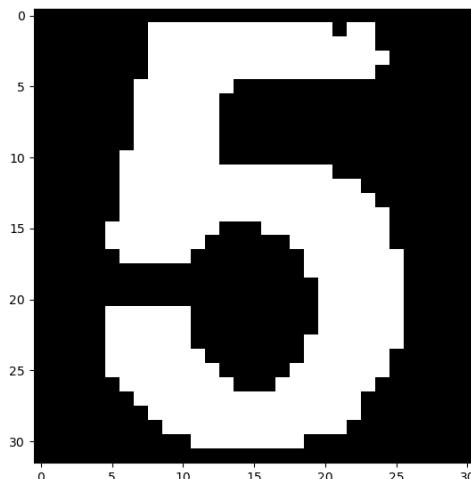
(a) Imagen original en escala de grises.



(b) Imagen filtrada con filtro gausiano (paso 1).



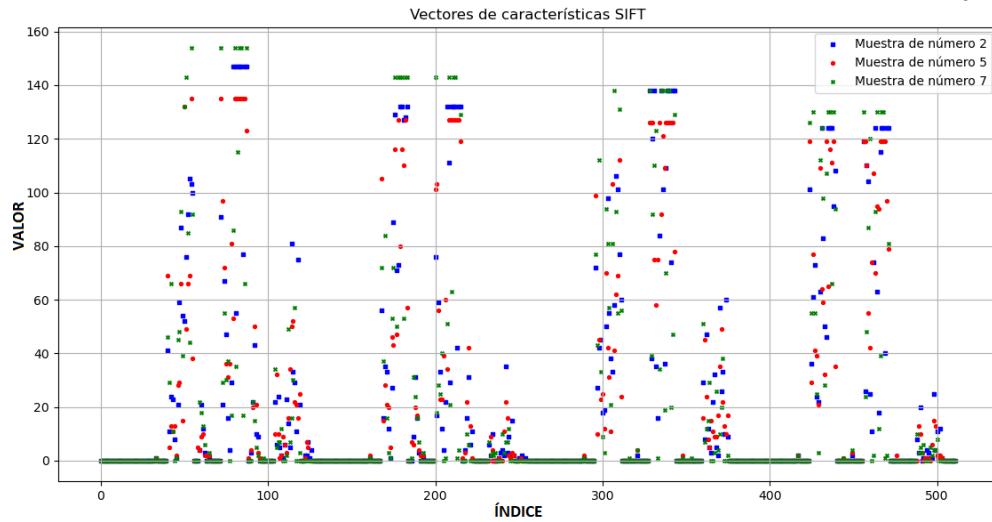
(c) Imagen escalada y con padding (paso 2).



(d) Imagen binarizada con el método de Otsu (paso 3)

Para el [paso 4](#), con las últimas líneas del código [A.1](#) también se grafican los vectores de características. En la figura [3-5](#) se muestran los resultados de una muestra de cada clase 2, 5 y 7.

Figura 3-5.: Vectores de características de una muestra de cada clase 2, 5 y 7.



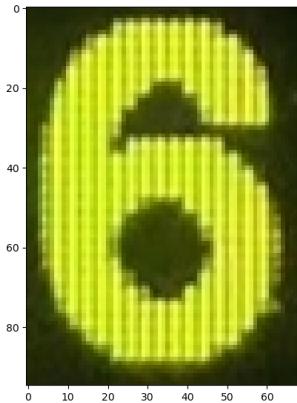
Ahora, el código A.1 se puede ejecutar iterativamente para leer todas las imágenes de un conjunto de entrenamiento con entre 10 y 20 muestras por cada clase. Luego, para los pasos 5 y 6, complementando con el código A.2, se efectúa la extracción de características y se entrena el clasificador bayesiano normal. La reducción de dimensionalidad se hizo hasta un valor de $d = 16$, empíricamente seleccionado según los resultados de clasificación obtenidos.

Finalmente, para una muestra dada de prueba, se efectúa el mismo procesamiento de la imagen con el código A.1, y la extracción y clasificación se efectúa con el código A.3.

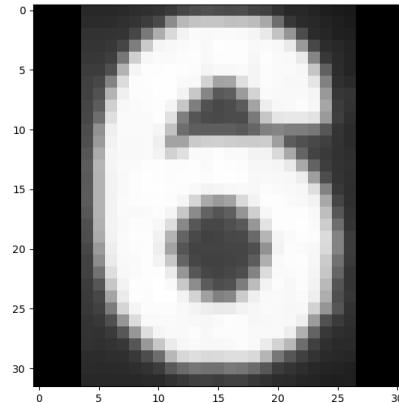
Durante los primeros ensayos del algoritmo se pudo notar que si las condiciones de captura de la imagen no son controladas, factores como el desenfoque de la cámara, la alta exposición controlada por el diafragma de la cámara, reflejos, destellos de luz o bajo contraste, pueden afectar significativamente la clasificación. Por ejemplo, en la figura 3-6 se presenta una comparación entre dos números fotografiados en condiciones controladas y no controladas, y el respectivo resultado de procesamiento.

La precisión del clasificador se puede medir fácilmente con una matriz de confusión, en la que directamente se identifican los falsos y verdaderos positivos. La matriz de confusión se genera rápidamente con el código A.4. Se armaron dos conjuntos de prueba, uno en condiciones no controladas y otro en que sí, y se probó el clasificador en ambos. En la figura 3-7 se muestra la matriz de confusión para el primer conjunto (condiciones no controladas) y en la figura 3-8 la del segundo (condiciones controladas).

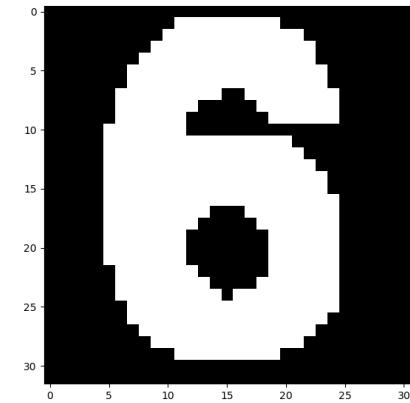
Figura 3-6.: Comparación del procesamiento de imágenes tomadas en condiciones controladas y no controladas.



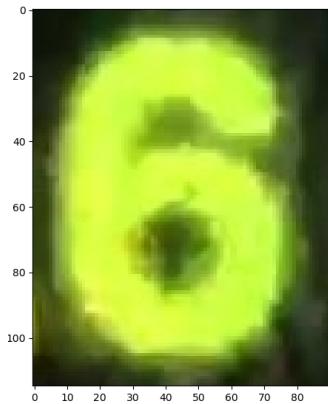
(a) Imagen original en condiciones controladas.



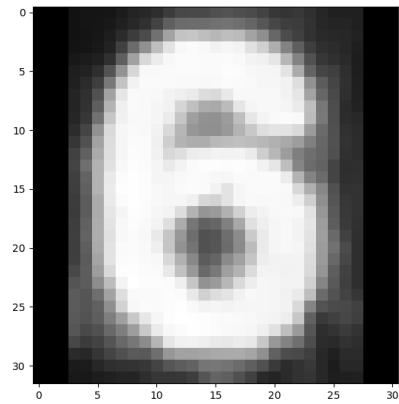
(b) Imagen hasta el paso 2 en condiciones controladas.



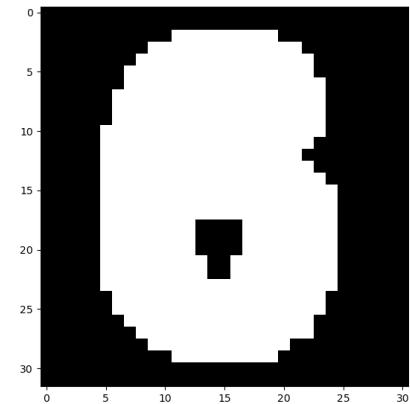
(c) Imagen hasta el paso 3 en condiciones controladas.



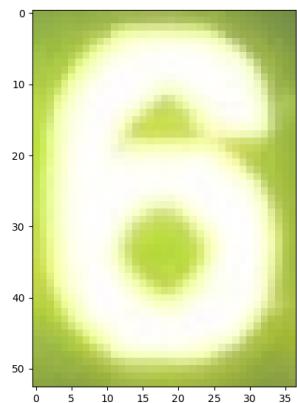
(d) Imagen original en condiciones no controladas.



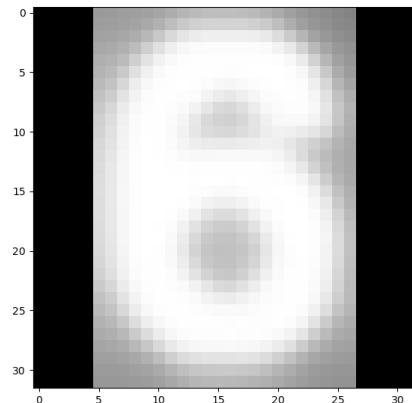
(e) Imagen hasta el paso 2 en condiciones no controladas.



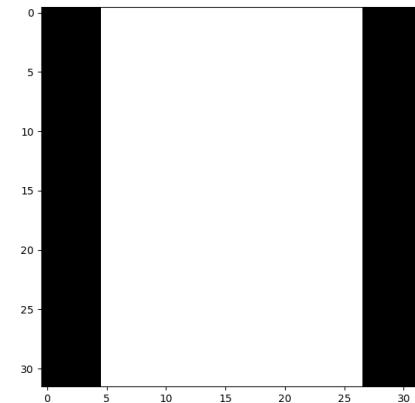
(f) Imagen hasta el paso 3 en condiciones no controladas.



(g) Imagen original en condiciones no controladas.



(h) Imagen hasta el paso 2 en condiciones no controladas.



(i) Imagen hasta el paso 3 en condiciones no controladas.

Figura 3-7.: Matriz de confusión del clasificador bayesiano propuesto para el conjunto de imágenes tomadas en condiciones no controladas.

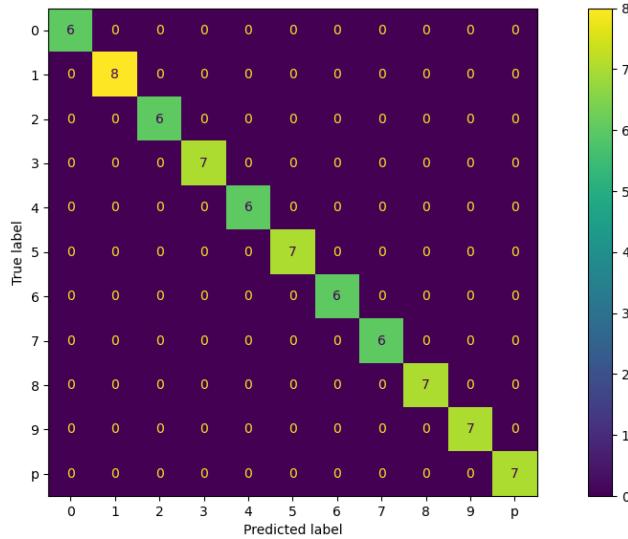
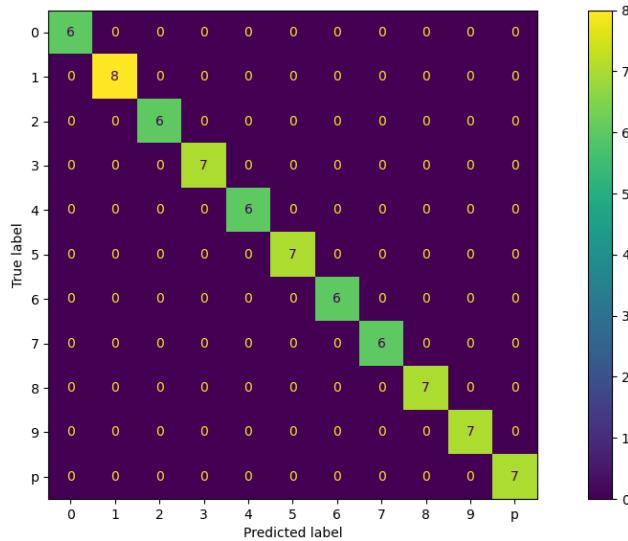


Figura 3-8.: Matriz de confusión del clasificador bayesiano propuesto para el conjunto de imágenes tomadas en condiciones controladas.



Discusión

Los resultados obtenidos demuestran un funcionamiento satisfactorio en general, tanto del procesamiento de las imágenes como del clasificador. Aunque evidentemente es un método simplificado, resulta ser eficaz y eficiente, pues cumple con el objetivo de reconocimiento de caracteres empleando pocos recursos computacionales y cortos tiempos de entrenamiento del clasificador y del procesamiento de las imágenes, lo que permite que el método sea emplea-

do en ordenadores con baja capacidad de procesamiento y en aplicaciones de funcionamiento en tiempo real, como se pretende en este proyecto. Aunque el clasificador bayesiano es de las técnicas más sencillas de aprendizaje de máquina, tiene un desempeño aceptable en muchas aplicaciones reales y no requiere una base de datos de entrenamiento demasiado extensa ([sci-kit Developers, 2022](#)).

Particularmente, cada una de las etapas de procesamiento resulta ser crucial en el resultado. Por ejemplo la etapa de suavizado permite eliminar variaciones de intensidad de alta frecuencia como las irregularidades en el relleno de los dígitos debidas a la construcción de la pantalla del sonómetro, como en pantallas led, por ejemplo (cf. [3-6a](#) y [3-6b](#)). Sin este suavizado es posible que en la umbralización no se obtengan segmentos homogéneos que representen correctamente un dígito. La binarización de la imagen, buscando el umbral con el método de Otsu, garantiza que se haga una discriminación correcta entre el fondo de la pantalla y el dígito, en función de la distribución de las intensidades de píxeles, esto aporta confiabilidad en la segmentación independientemente de la forma y color de los números. Y el descriptor SIFT es bien conocido por su robustez frente a transformaciones afines o cambios en el punto de vista 3D, lo que contribuye a asegurar la eficacia en la medición de características aun cuando hay variaciones en la posición de la cámara respecto a la pantalla del sonómetro; además, que esté basado en la dirección de los gradientes, lo hace adecuado para cuantizar de algún modo las formas de los contornos de los dígitos.

No obstante, a pesar de la eficiencia y simplicidad del clasificador bayesiano normal, lo cierto es que el resultado de clasificación es bastante sensible si se obtienen resultados erróneos en el procesamiento anterior. Por ejemplo, por efectos de bajo contraste o desenfoques que deforman los segmentos, podría haber confusiones en la clasificación, principalmente en clases que son muy similares en sus características, como entre el 6 y el 8 o entre el 9 y el 8, pues al deformarse el segmento a causa de esos ruidos, el 6 o el 9 cierran el trazo faltante y se asemejan a un 8, o alguno de los huecos se rellena y se asemejan a un 0. Sin embargo, en los ensayos del sistema de reconocimiento se pudo comprobar que esto ocurre cuando la posición o configuración de la cámara no es la adecuada y los efectos del desenfoque o la iluminación son más pronunciados. Cuando las condiciones de captura de la imagen son controladas (por ejemplo, ajustando en la cámara la distancia focal y la apertura del diafragma adecuadas, limpiando la pantalla del equipo para evitar borrosidad e incluso buscando una posición apropiada del sonómetro y la cámara para mitigar las reflexiones de las fuentes de luz del lugar), la eficacia del clasificador es de un 100 %, como se puede notar en la matriz de confusión de la figura [3-8](#).

4. Implementación de los procedimientos de calibración

En este capítulo se describe el desarrollo y arquitectura de software de las aplicaciones diseñadas para la calibración periódica de calibradores acústicos de acuerdo con la IEC 60942 (2017) (tomando como base un modelamiento en GRAFCET) y de sonómetros de acuerdo con la norma IEC 61672-3 (2013a) (usando el sistema de reconocimiento de caracteres del capítulo 3). El desarrollo del *software* está publicado en el siguiente repositorio de GitHub:

<https://github.com/jfBranch/unal-acoustic-metrology.git>

4.1. Automatización de la calibración periódica de calibradores acústicos

Siguiendo el método normalizado descrito en la sección 2.2.1 y el algoritmo de la figura 2-6, se modeló la secuencia de calibración en un gráfico de etapas y transiciones explicado en la siguiente sección.

4.1.1. GRAFCET descriptivo del proceso

Para dar mayor claridad, en la figura 4-1 se presenta la secuencia principal en la que se hacen llamadas a subrutinas mediante las etapas macro. Los GRAFCET de las subrutinas se muestran en las figuras 4-2a a la 4-2f.

Figura 4-1.: GRAFCET de la rutina principal de la calibración periódica de calibradores acústicos.

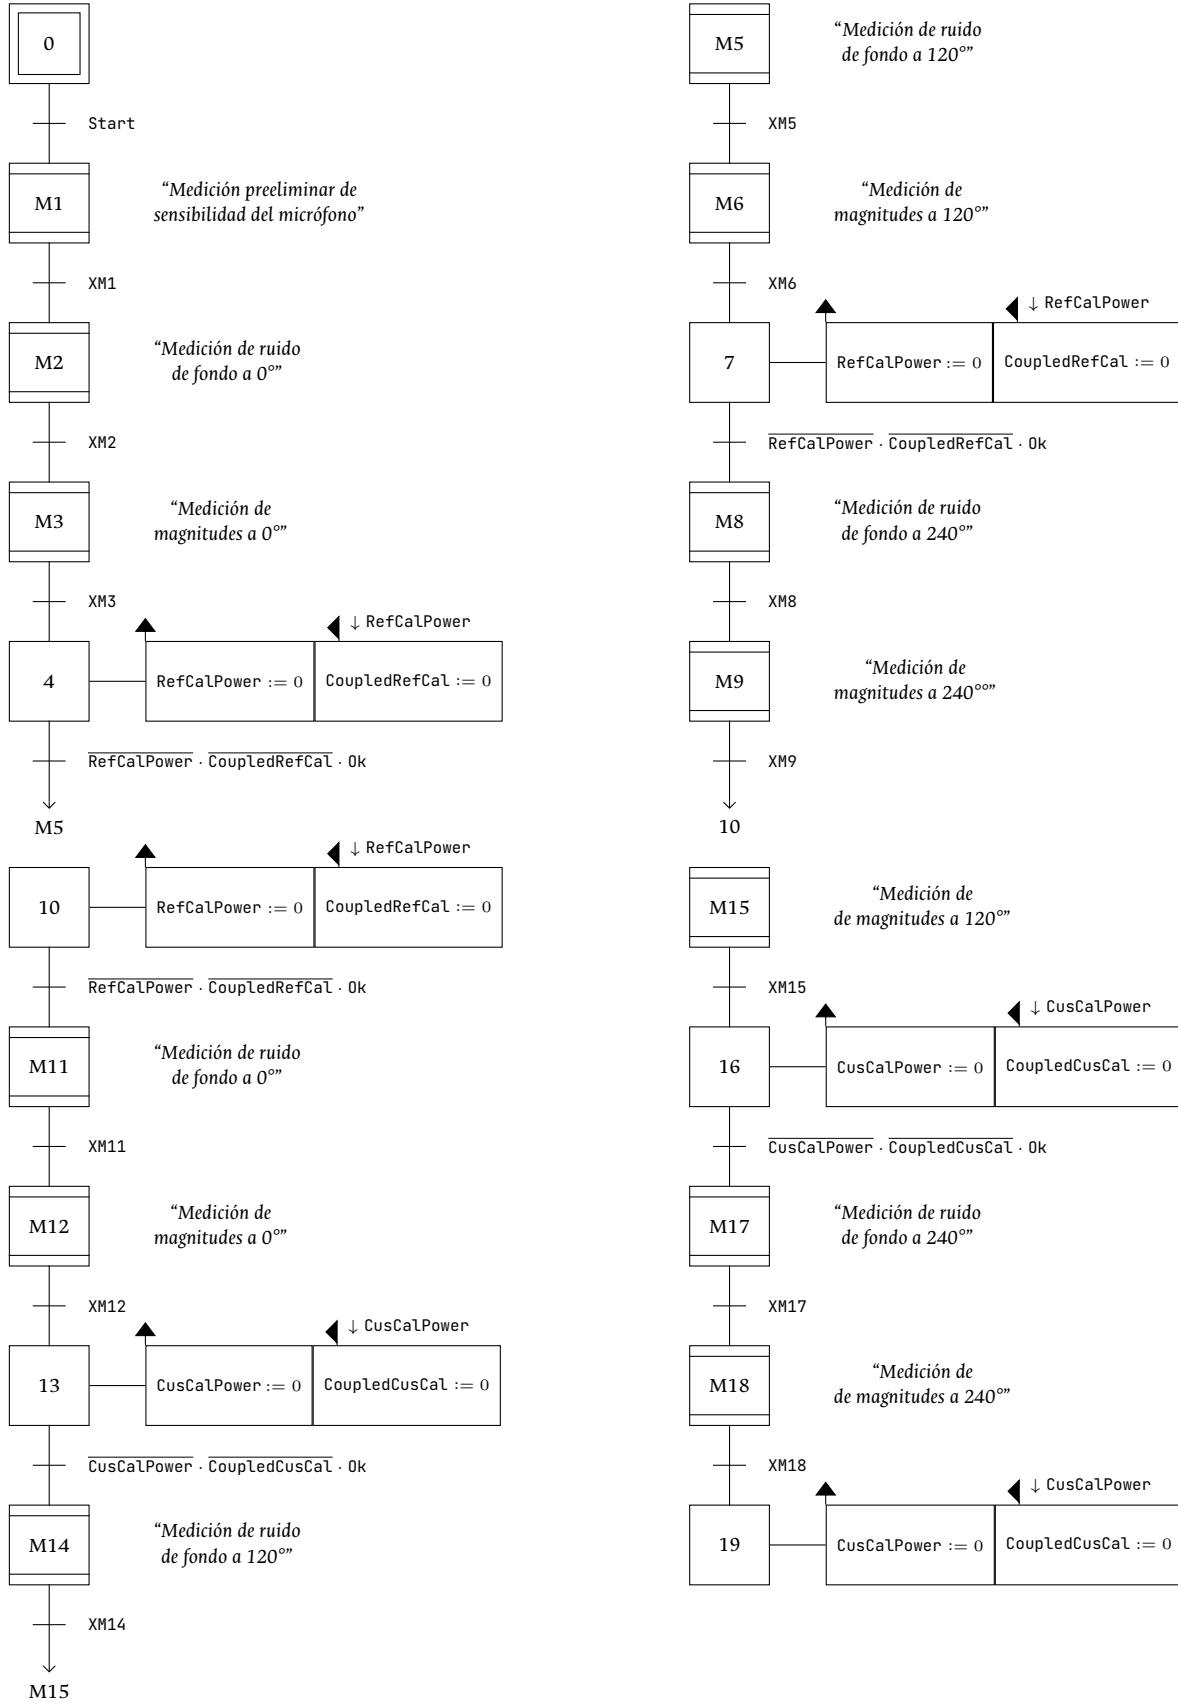
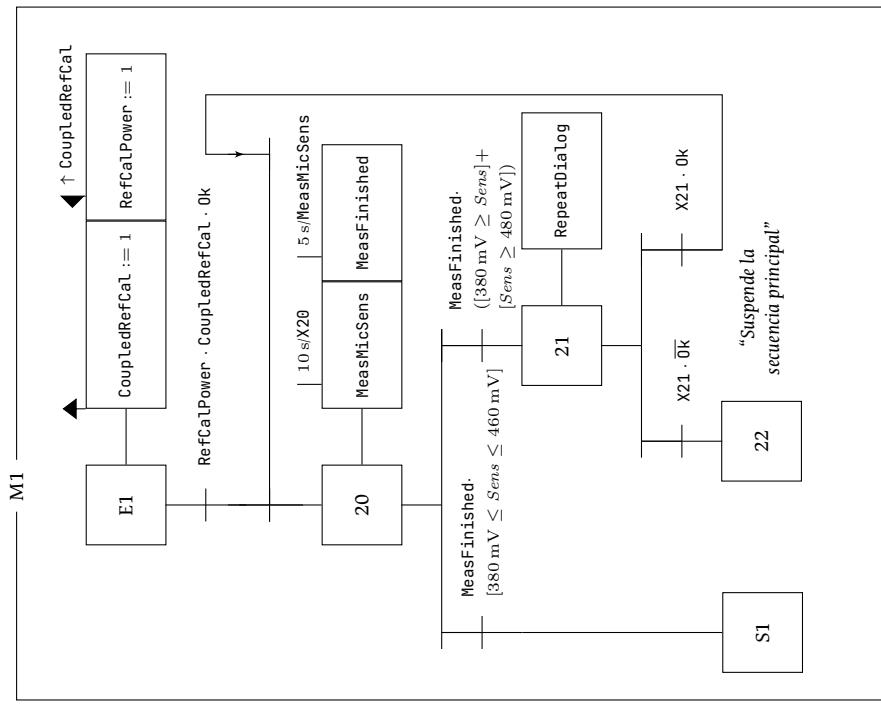
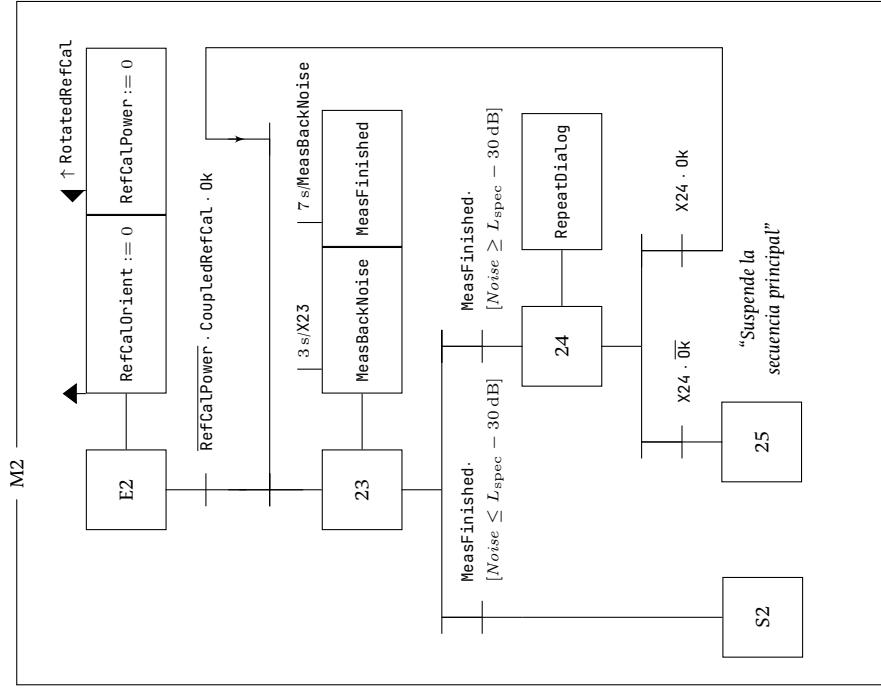


Figura 4-2.: GRAFCET's de las subrutinas para la calibración periódica de calibradores acústicos.

(a) Subrutina para la etapa macro 1: Medición preliminar de sensibilidad del micrófono.



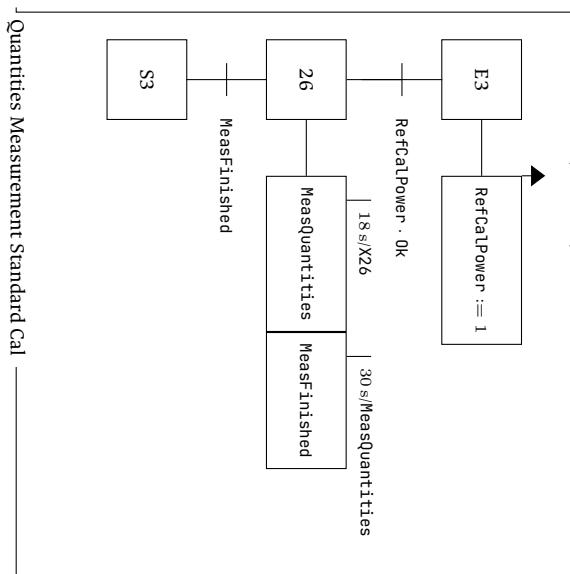
(b) Subrutina para la etapa macro 2: Medición de ruido de fondo a 5° con el calibrador patrón.



4 Implementación de los procedimientos de calibración

Figura 4-2.: GRAFCET's de las subrutinas para la calibración periódica de calibradores acústicos (continuación).

(c) Subrutina para las etapas macro 3, 6 y 9: Medición de magnitudes con el calibrador patrón.



(d) Subrutina para las etapas macro 5 y 8: Medición de ruido de fondo a 120° y 240° con el calibrador patrón.

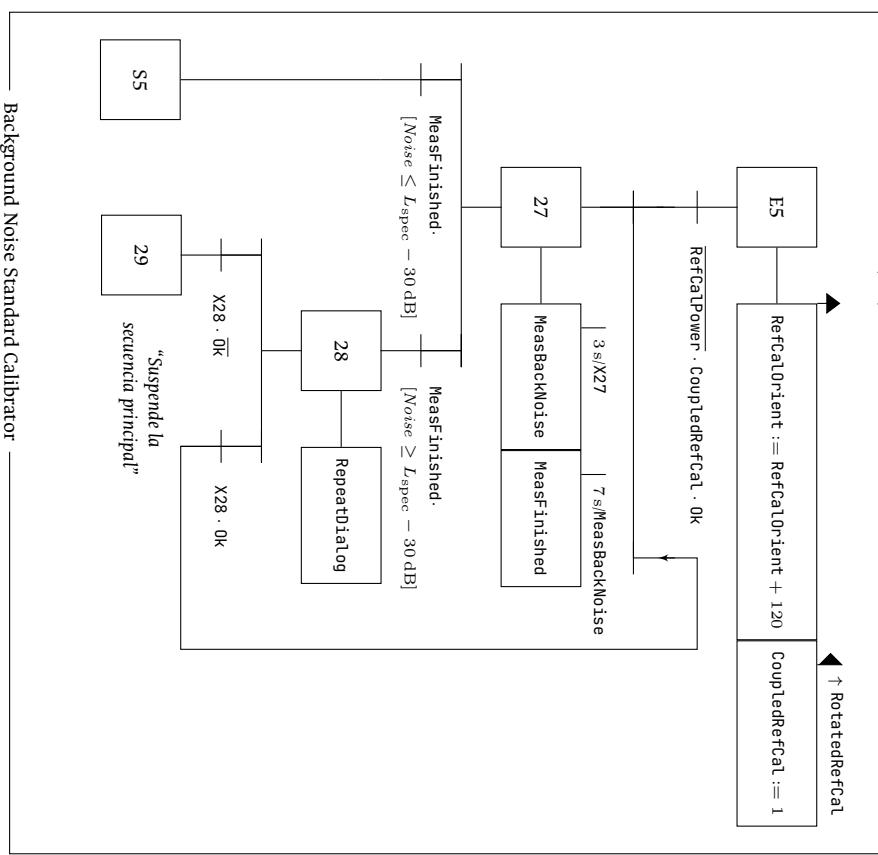
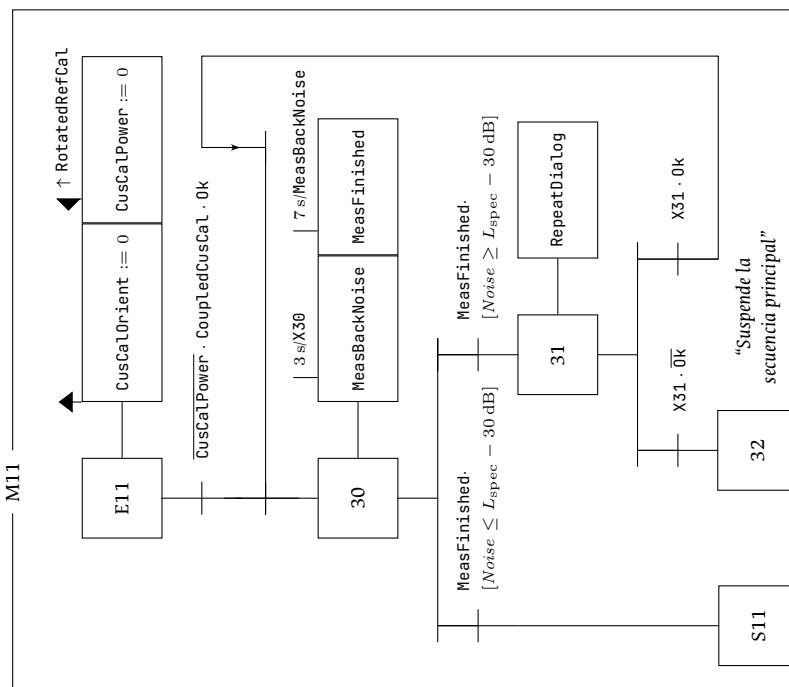
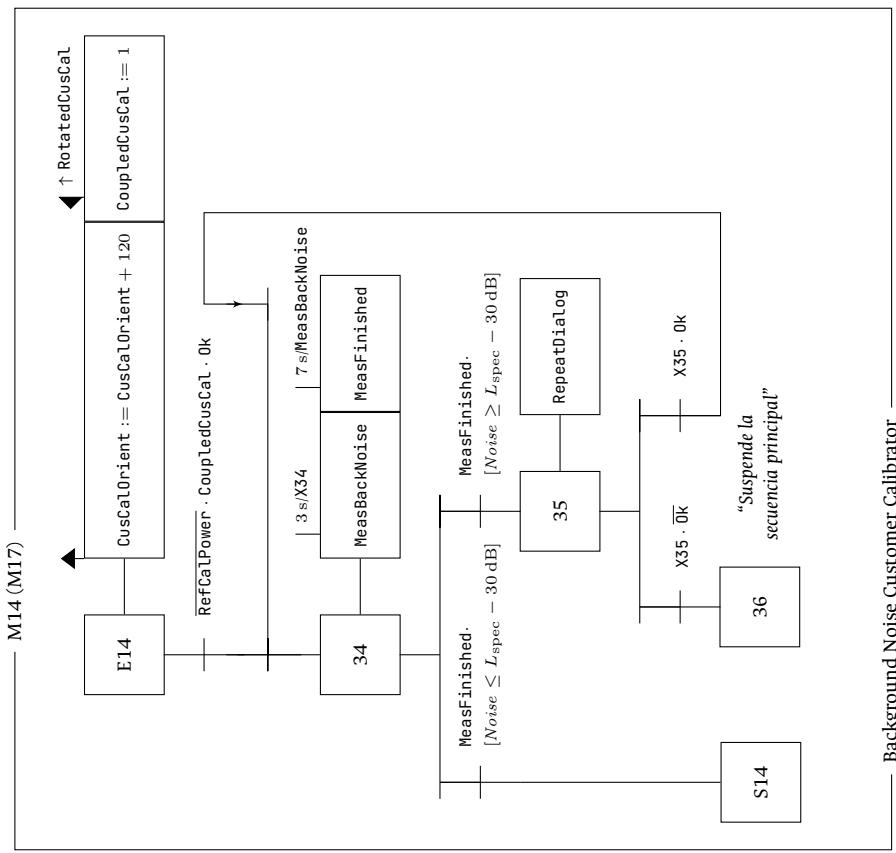


Figura 4-2.: GRAFCET's de las subrutinas para la calibración periódica de calibradores acústicos (continuación).

(e) Subrutina para la etapa macro 11: Medición de ruido de fondo a 0° con el calibrador bajo prueba.



(f) Subrutina para las etapas macro 14 y 17: Medición de ruido de fondo a 120° y 240° con el calibrador bajo prueba.

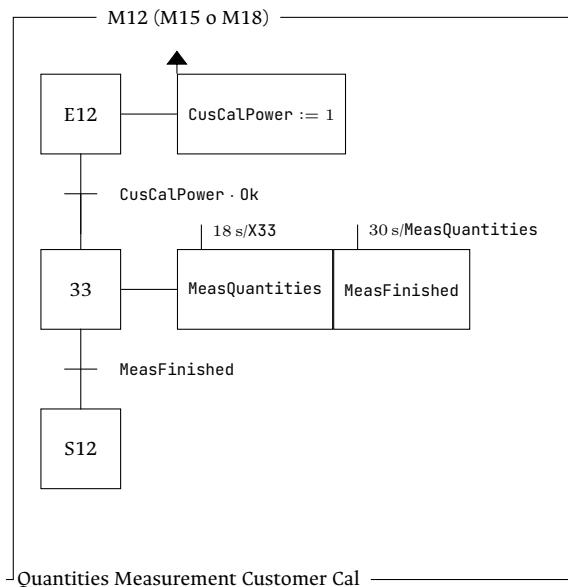


Background Noise Customer Calibrator

Background Noise Customer Calibrator

Figura 4-2.: GRAFCET's de las subrutinas para la calibración periódica de calibradores acústicos (continuación).

(g) Subrutina para las etapas macro 12, 15 y 18: Medición de magnitudes con el calibrador bajo prueba.



En todos los GRAFCET, además de los operandos de cada etapa ($x\#$), se emplean los del siguiente cuadro:

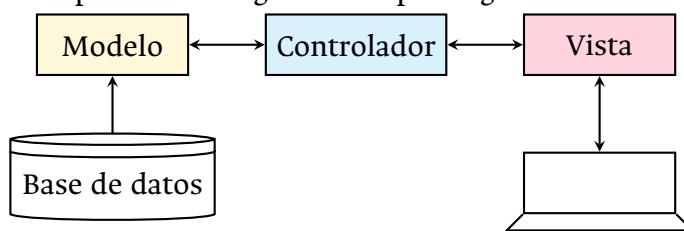
Cuadro 4-1.: Descripción de los operandos del GRAFCET de la secuencia principal.

Operando	Descripción
RefCalOrient	Orientación del calibrador acústico patrón.
RotatedRefCal	True si el calibrador patrón ya fue rotado o False si aún no ha sido rotado.
RefCalPower	Estado del calibrador acústico patrón. True significa encender y False es apagar. Esta acción es realizada manualmente por el operador.
CoupledRefCal	Estado de acoplamiento del calibrador acústico patrón. True significa acoplar el calibrador al micrófono, False es desacoplar el calibrador. Esta acción es realizada manualmente por el operador.
CusCalOrient	Orientación del calibrador acústico bajo prueba.
RotatedCusCal	True si el calibrador bajo prueba ya fue rotado o False si aún no ha sido rotado.
CusCalPower	Estado del calibrador acústico bajo calibración. True significa encender y False es apagar. Esta acción es realizada manualmente por el operador.
CoupledCusCal	Estado de acoplamiento del calibrador acústico bajo calibración. True significa acoplar el calibrador al micrófono, False es desacoplar el calibrador. Esta acción es realizada manualmente por el operador.
RepeatDialog	Mostrar ventana emergente de diálogo con los botones “Aceptar” y “Abortar”.
Ok	Respuesta del usuario a un mensaje de diálogo con los botones “Aceptar” (True) o “Abortar” (False).
MeasMicSens	Medir sensibilidad. Esta acción es automática.
MeasFinished	Señal que indica que la medición en curso ha finalizado.
MeasBackNoise	Medir ruido de fondo. Esta acción es automática.
MeasQuantities	Medir magnitudes. Esta acción es automática.

4.1.2. Implementación en Python

Si bien los GRAFCET's son empleados principalmente en aplicaciones mecánicas o eléctricas, es un lenguaje común que tiene el potencial para usarse como base para el desarrollo de software, dada su simplicidad y practicidad ([MHJ-Software, 2020](#)); a lo que se suma la facilidad en aprenderlo, lo cual es una ventaja a la hora de integrar grupos de trabajo en los que participan personas de diferentes disciplinas.

Figura 4-3.: Representación gráfica del paradigma Model-View-Controller.

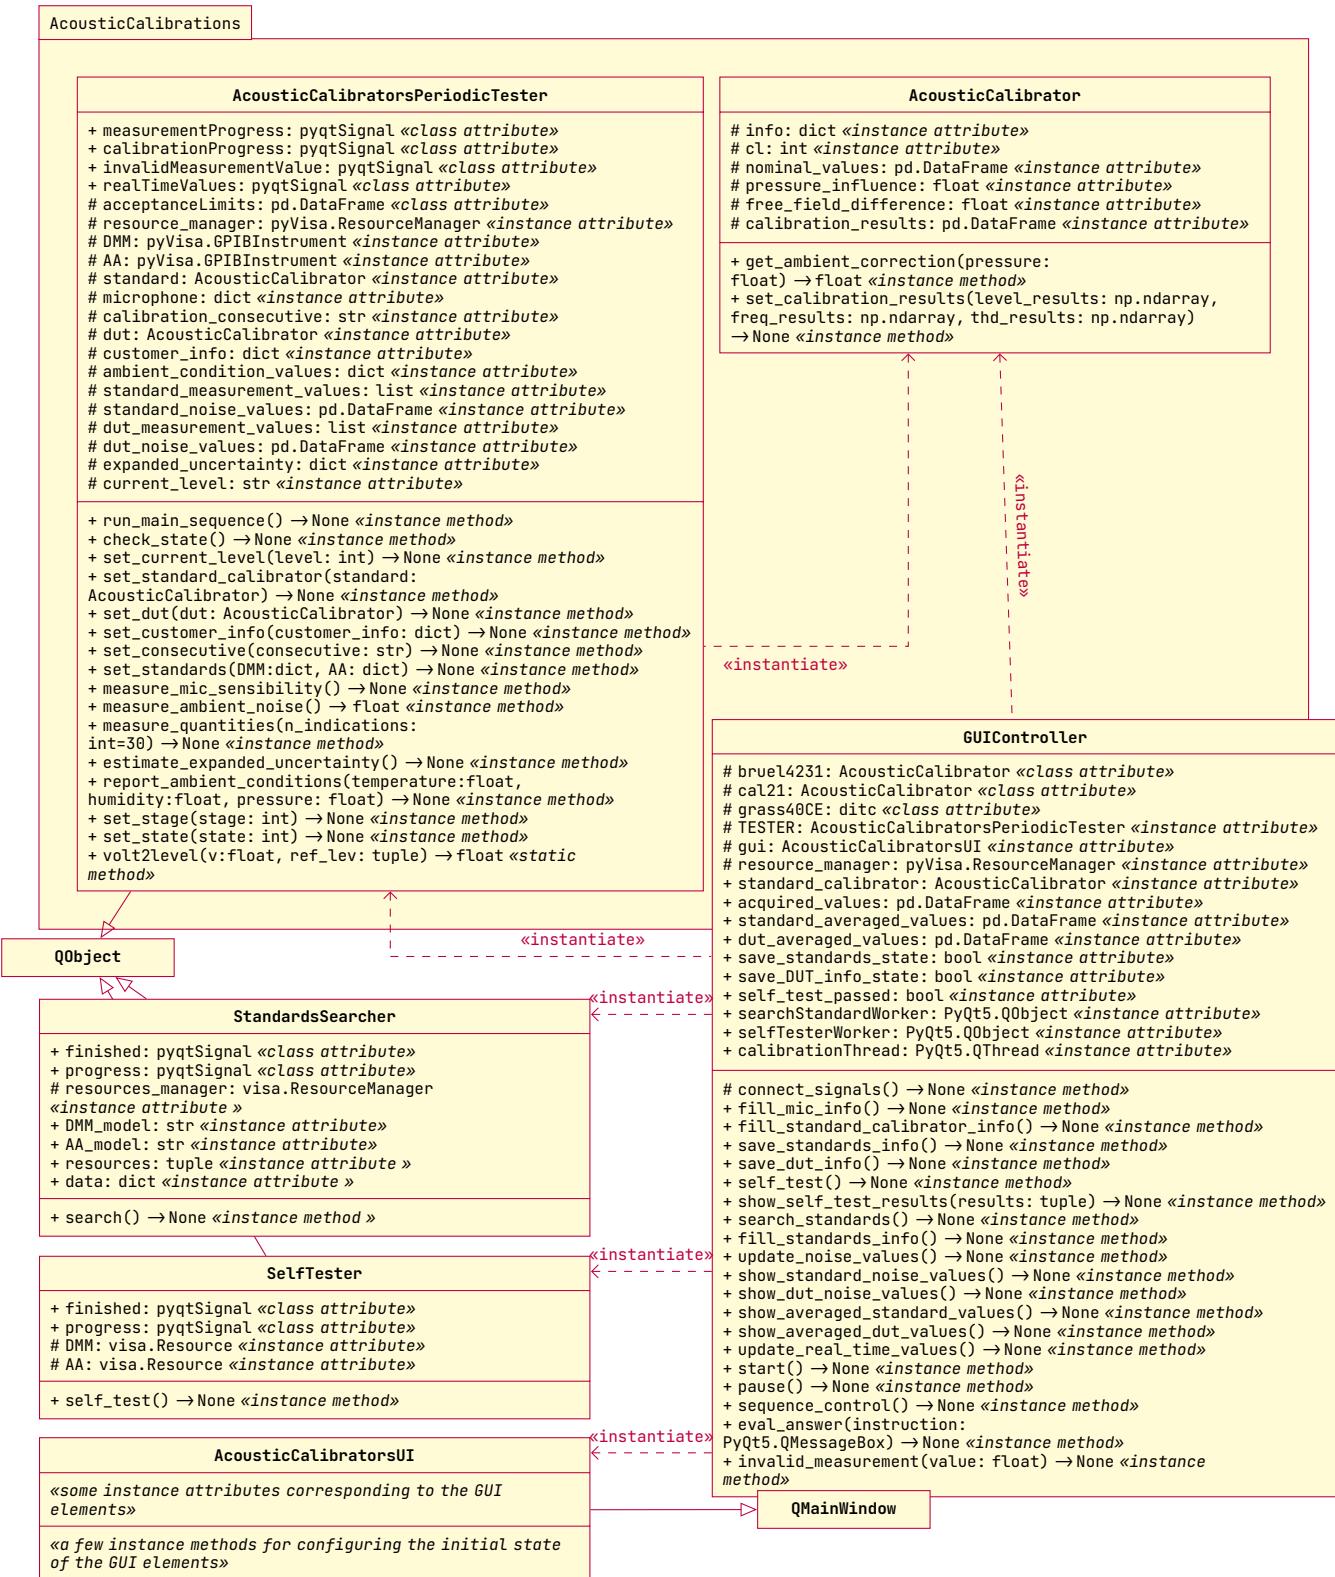


Fuente: Elaboración propia.

Normalmente, el diseño de un GRAFCET es llevado a la realidad en los sistemas empleando controladores lógicos programables (PLC), a los que están conectados los sensores y actuadores presentes en el sistema. Sin embargo, en este desarrollo (siguiendo el paradigma de la programación orientada a objetos) la función del PLC es desempeñada virtualmente por dos objetos cuyas clases están diseñadas para ser el controlador y el modelo en el patrón Model-View-Controller (MVC), comúnmente utilizado en el desarrollo de aplicaciones web con interfaz gráfica (véase la figura 4-3). Para crear un entorno en el que estas interacciones virtuales puedan ocurrir, las clases de los objetos fueron diseñadas heredando de las clases `QObject` y `QThread` de la librería PyQt5, que permiten emplear la tecnología multi-hilos. De manera que las señales y acciones ocurren en hilos paralelos según sea adecuado, sin congelar el funcionamiento de la interfaz gráfica y permitiendo también el procesamiento en “segundo plano”. Las señales conectadas a los slots son valores de progreso de la medición general o de la prueba en ejecución, y los valores de medición obtenidos en tiempo real.

La principal ventaja que se obtiene al usar un GRAFCET como base en el desarrollo de un software que automatice las rutinas de un sistema, es que al final la programación queda encapsulada, ordenada e incluso etiquetada según las etapas del GRAFCET. De modo que esto facilita el diseño de la arquitectura de software y permite que en la práctica se pueda ir a etapas específicas reutilizando las subrutinas, lo cual hace de esta una aplicación versátil e intuitiva para la calibración de calibradores acústicos.

Figura 4-4.: Diagrama de clases de la aplicación desarrollada para la calibración periódica de calibradores acústicos.



Fuente: Elaboración propia.

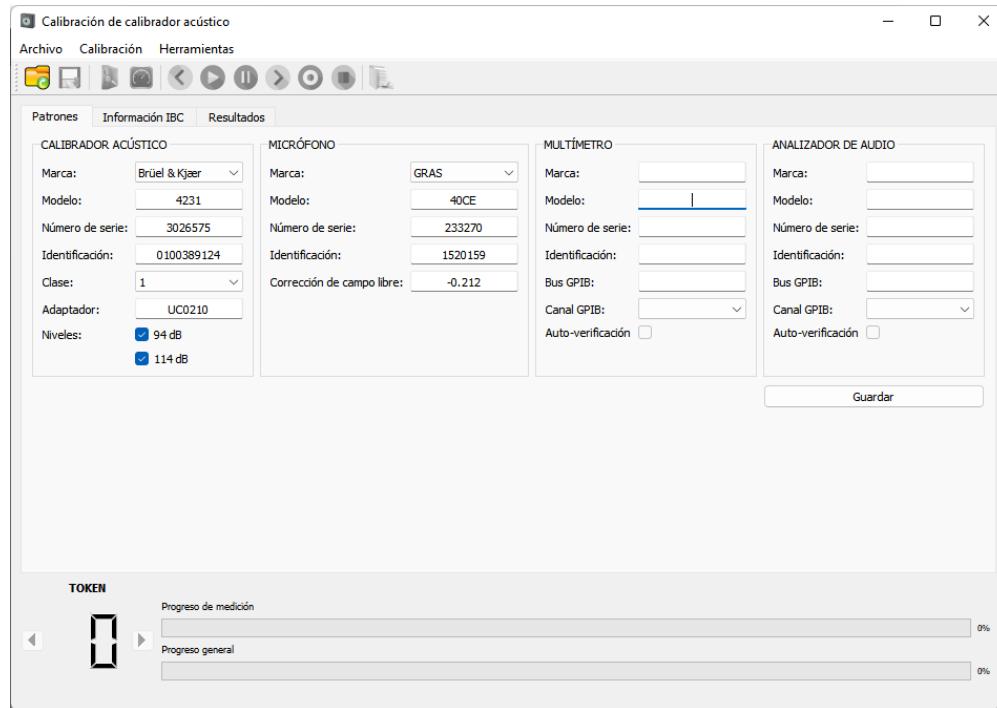
Arquitectura de software

El diagrama de clases de la figura 4-4 es un resumen de las clases principales (con sus atributos y métodos) diseñadas para el desarrollo de la aplicación para la calibración de calibradores acústicos. También se presentan las clases heredadas y el instanciamiento entre clases.

La escritura del código se hizo aplicando las buenas prácticas de programación como: Documentación de clases, métodos e instrucciones relevantes, uso de atributos o métodos protegidos y las directrices de la guía PEP 8. La interfaz gráfica se diseñó en Qt Designer de tal forma que se logre un manejo intuitivo de las funciones de la aplicación usando diferentes recursos como íconos, barras de progreso, menús desplegables, barra de herramientas, etc. Con Qt Designer fue posible generar el código base de Python para el view que lanza la aplicación y muestra la interfaz tal como fue diseñada.

Descripción de funcionamiento

Figura 4-5.: Interfaz gráfica de usuario de la aplicación para calibradores acústicos. Se muestra la pestaña de Patrones.



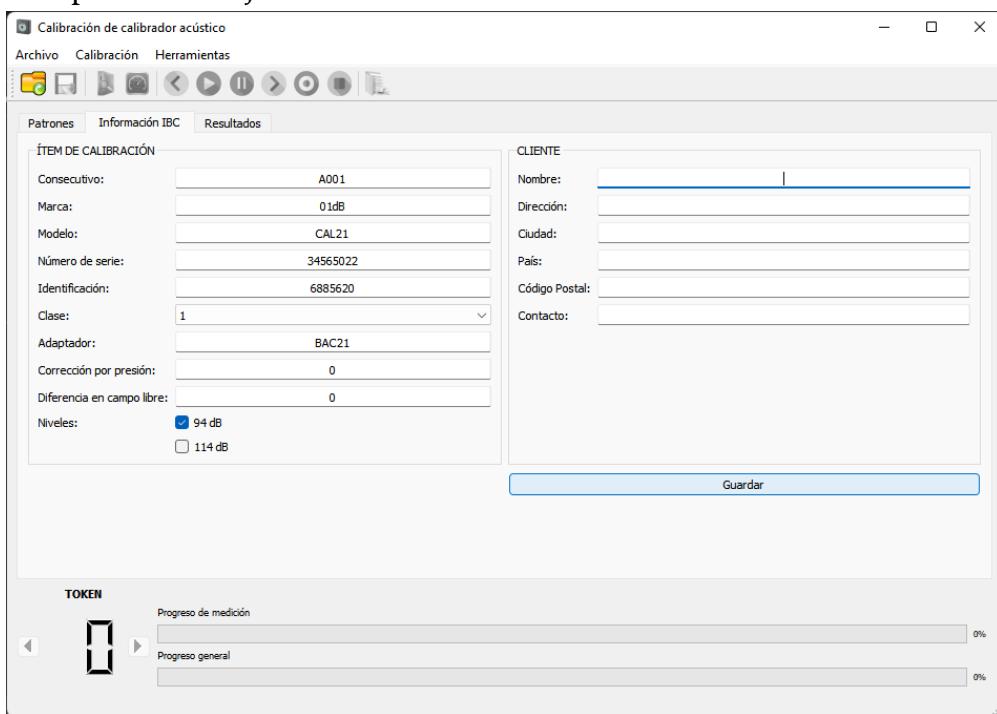
Fuente: Elaboración propia.

En la figura 4-5 se muestra la interfaz de usuario diseñada. La pestaña de Patrones es la mostrada

en la vista inicial. En esta, el usuario ingresa la información básica de los patrones empleados en la calibración. Para el multímetro y el analizador de audio, si el usuario digita información en los campos de modelo, se habilita la herramienta , la cual busca automáticamente los modelos indicados entre todos los equipos disponibles conectados por GPIB al computador, extrae la información de estos y rellena los campos faltantes.

Una vez la información de los patrones está completa, el usuario puede hacer clic en *Guardar*. Se habilita la herramienta , con la que se ejecuta la secuencia de auto-verificación de los patrones conectados por GPIB, si está disponible. El resultado de la verificación se muestra en el *check box* correspondiente.

Figura 4-6.: Interfaz gráfica de usuario de la aplicación para calibradores acústicos. Se muestra la pestaña de Información IBC.

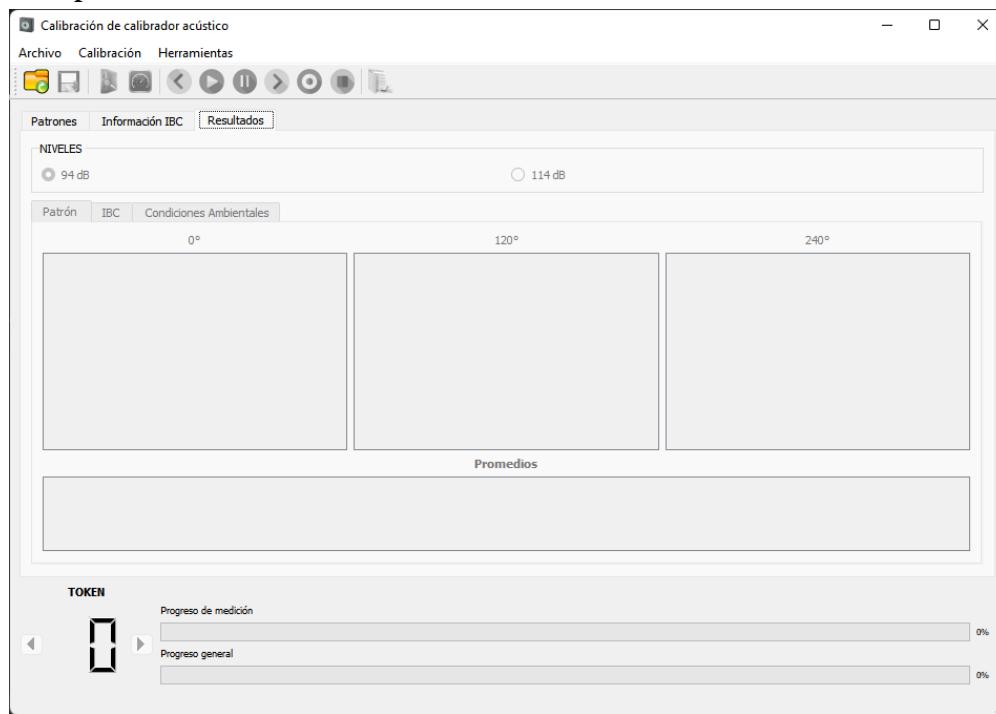


Fuente: Elaboración propia.

A continuación, en la pestaña *Información IBC* (ver figura 4-6), el usuario ingresa toda la información del calibrador bajo verificación y del cliente, necesaria para la calibración y para el certificado de calibración. Cuando la información esté completa, el usuario puede hacer clic en *Guardar* y, si el resultado de auto-verificación de los patrones fue correcto, entonces se habilita el botón . Al hacer clic en este se cumple la condición para la transición desde la etapa 0 a la 1 de la rutina principal del GRAFCET (figura 4-1). En seguida se llevan a cabo todas las acciones de las demás etapas y, en la medida que avanza la secuencia, se van mostrando instrucciones al usuario para las acciones manuales y los resultados se presentan en tiempo real en la pestaña

Resultados (ver figura 4-7).

Figura 4-7.: Interfaz gráfica de usuario de la aplicación para calibradores acústicos. Se muestra la pestaña de Resultados.



Fuente: Elaboración propia.

En la parte inferior de la ventana se incluye una barra de estado que indica la etapa actual (que tiene el token), y dos barras de progreso, una para el progreso general de la calibración y otra para la medición en la etapa actual. En cualquier momento de la calibración se puede hacer clic en para suspender temporalmente la secuencia y luego reanudarla haciendo clic nuevamente en . También se incluyeron en la interfaz otros botones y herramientas proyectando la aplicación a un desarrollo posterior que permita abrir y guardar sesiones de calibración, avanzar, retroceder etapas o ir a alguna específica del GRAFCET, y hasta generar automáticamente el certificado de calibración.

4.2. Automatización de la calibración periódica de sonómetros

De acuerdo con el método descrito en la sección 2.2.2 y el diagrama de bloques de la figura 2-7, la aplicación se desarrolló con una metodología similar a la implementada para calibradores acústicos, como se explica en la siguiente sección.

4.2.1. Implementación en Python

El funcionamiento de la aplicación para calibradores acústicos asentó las bases para diseñar la aplicación para sonómetros. Para aprovechar esas interacciones de los paradigmas *model-view-controller* y GRAFCET que ocurren en el ambiente multihilos, se establecieron los siguientes pasos para la automatización de las pruebas realizadas en sonómetros; estos pasos serían análogos a las etapas de un GRAFCET.

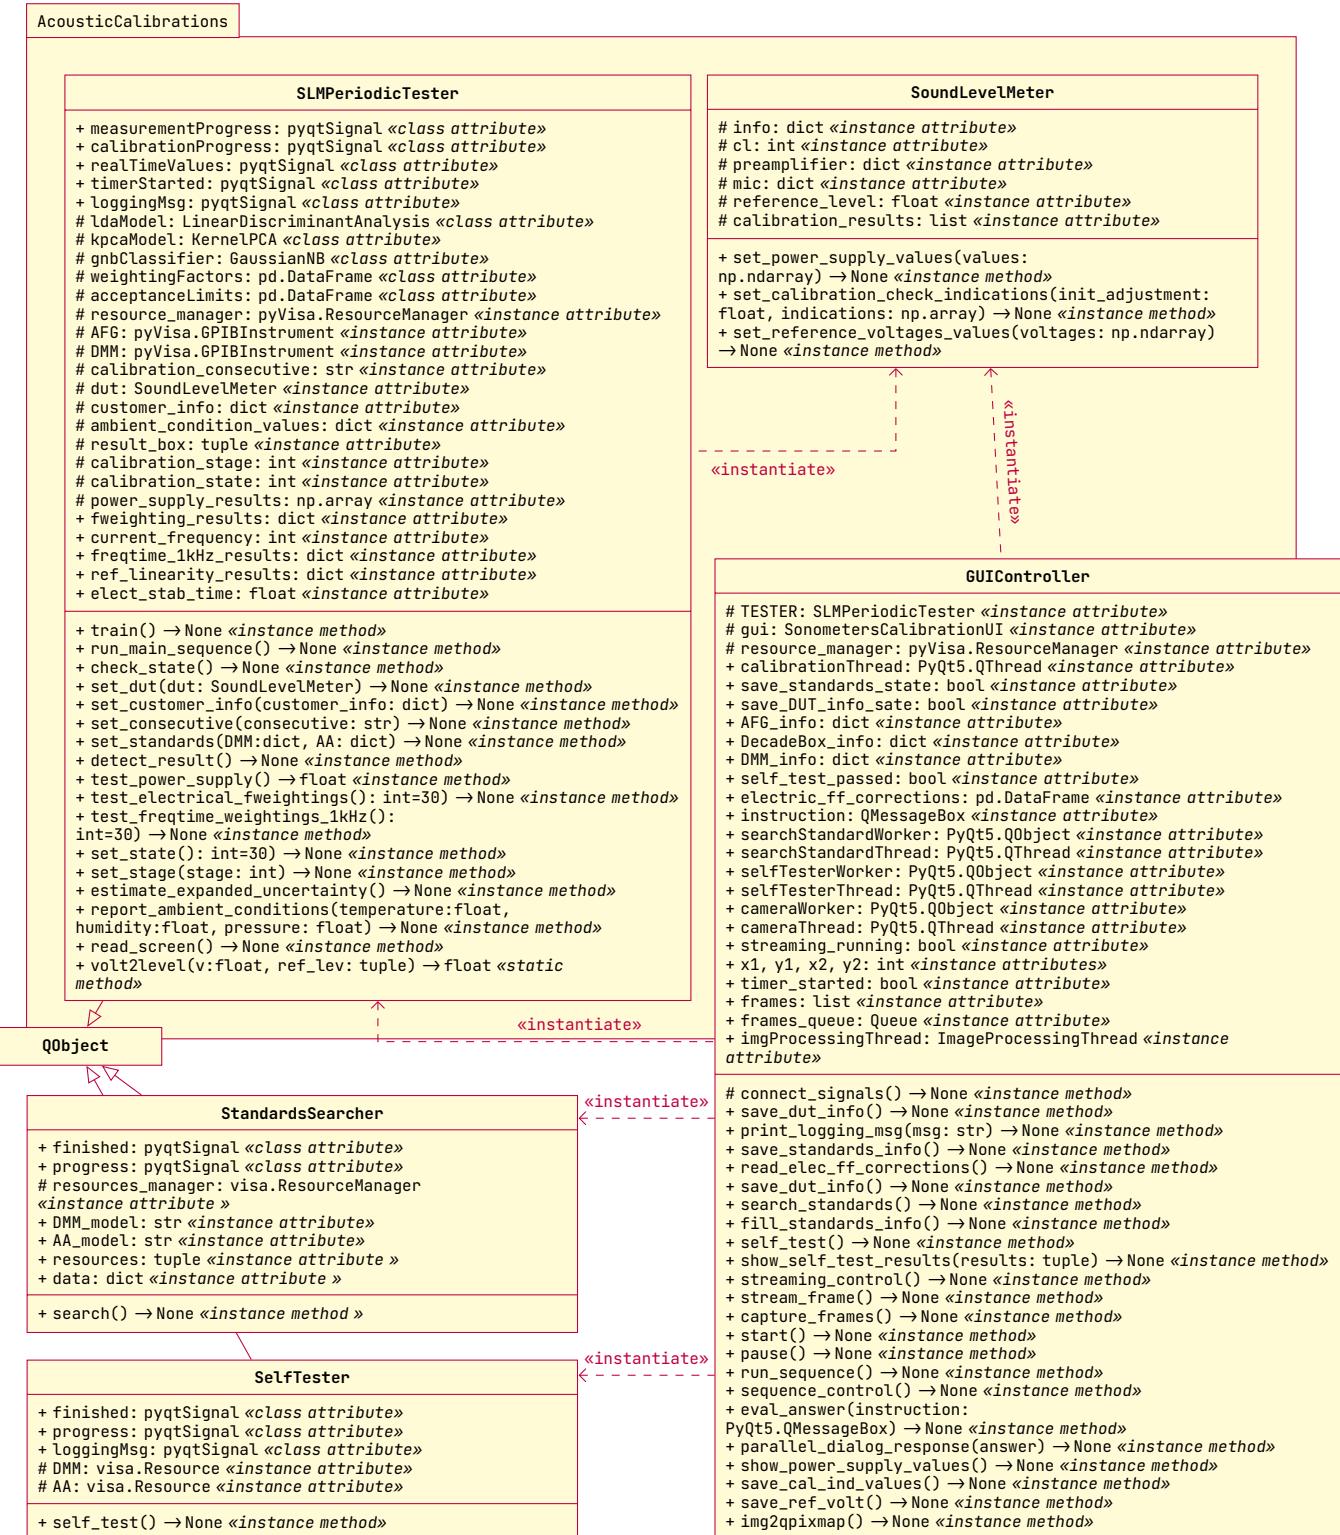
Algoritmo 4.1: Pasos para la calibración periódica de sonómetros implementados en la aplicación desarrollada.

- 1 **Paso 0.** Inicio, entrenar clasificador bayesiano.
 - 2 **Paso 1.** Verificar fuente de alimentación.
 - 3 **Paso 2.** Realizar prueba de indicación a la frecuencia de comprobación de la calibración.
 - 4 **Paso 3.** Verificar fuente de alimentación.
 - 5 **Paso 4.** Determinar el voltaje que produce una indicación del nivel de referencia.
 - 6 **Paso 5.** Realizar prueba de ponderación frecuencial *A* con señales eléctricas.
 - 7 **Paso 6.** Realizar prueba de ponderación frecuencial *C* con señales eléctricas.
 - 8 **Paso 7.** Realizar prueba de ponderación frecuencial *Z* con señales eléctricas.
 - 9 **Paso 8.** Realizar prueba de ponderaciones frecuenciales a 1 kHz.
 - 10 **Paso 9.** Realizar prueba de ponderaciones temporales a 1 kHz.
 - 11 **Paso 10.** Realizar prueba de linealidad en el rango de niveles de referencia.
 - 12 **Paso 11.** Verificar fuente de alimentación.
 - 13 **Paso 12.** Fin
-

Además de los hilos en los que el modelo hace sus operaciones y la vista envía y recibe las instrucciones del controlador, para esta aplicación fueron necesarios dos hilos más: uno que captura y muestra las imágenes del objeto de vídeo y otro que en segundo plano procesa, reconoce y guarda en disco en formato binario las imágenes de cada punto de calibración. Todo esto a la vez que el modelo está corriendo temporizadores, enviando instrucciones a los instrumentos patrones y haciendo cálculos. También se agregan otras señales Qt para indicar el arranque y parada de temporizadores, entregar el cuadro de vídeo capturado, indicar la liberación del objeto de vídeo y la finalización de guardado del vídeo, y enviar los mensajes de logging.

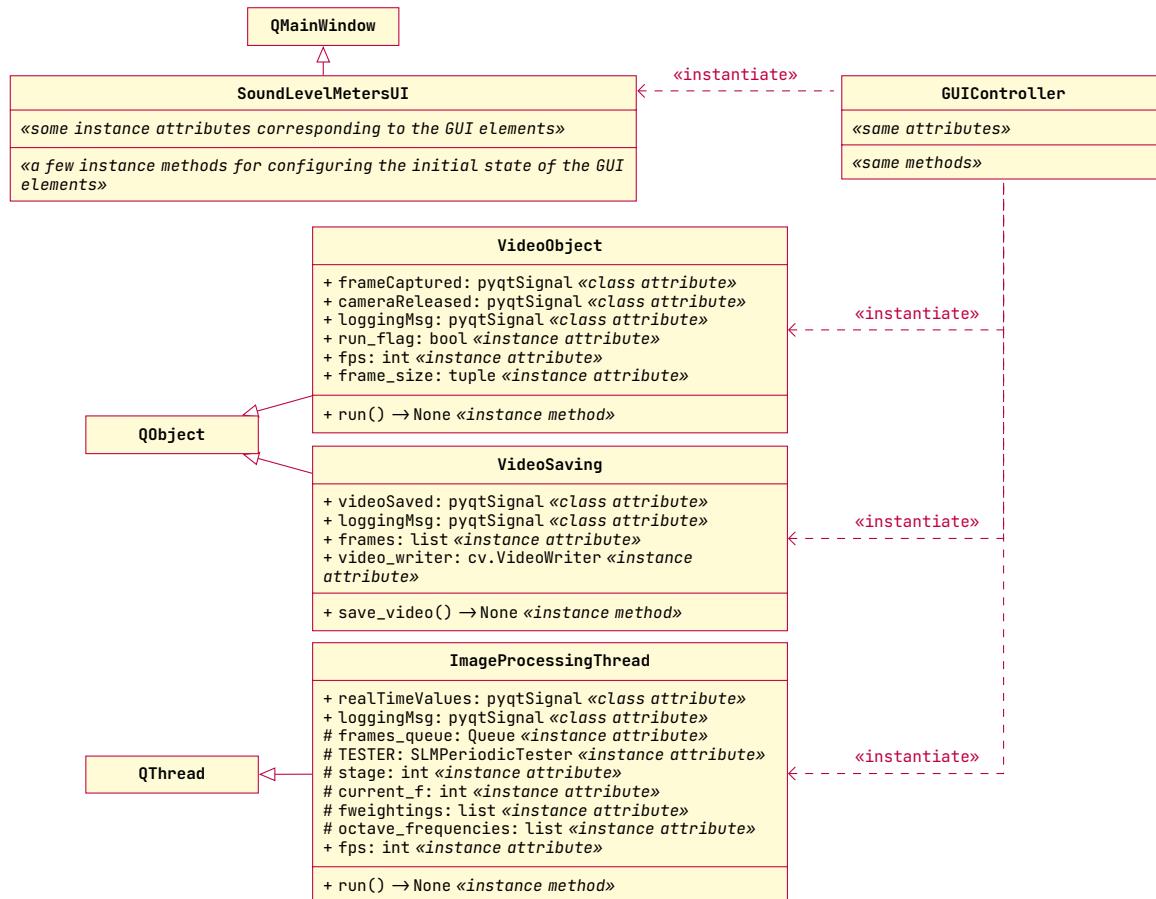
Asignar los procesos de cálculo de los voltajes de prueba y temporizadores que se realizan en el modelo, y los procesos de reconocimiento de imágenes a hilos separados es un beneficio para el mantenimiento del software y el desempeño de la aplicación. Por ejemplo, el último objetivo de este proyecto, que consiste en el modelamiento de las cadenas de Markov, se puede implementar como un proceso adicional en el hilo de reconocimiento de imágenes, sin afectar los otros procesos.

Figura 4-8.: Diagrama de clases de la aplicación desarrollada para la calibración periódica de sonómetros.



Fuente: Elaboración propia.

Figura 4-8.: Diagrama de clases de la aplicación desarrollada para la calibración periódica de sonómetros. (Continuación)



Fuente: Elaboración propia.

Arquitectura de software

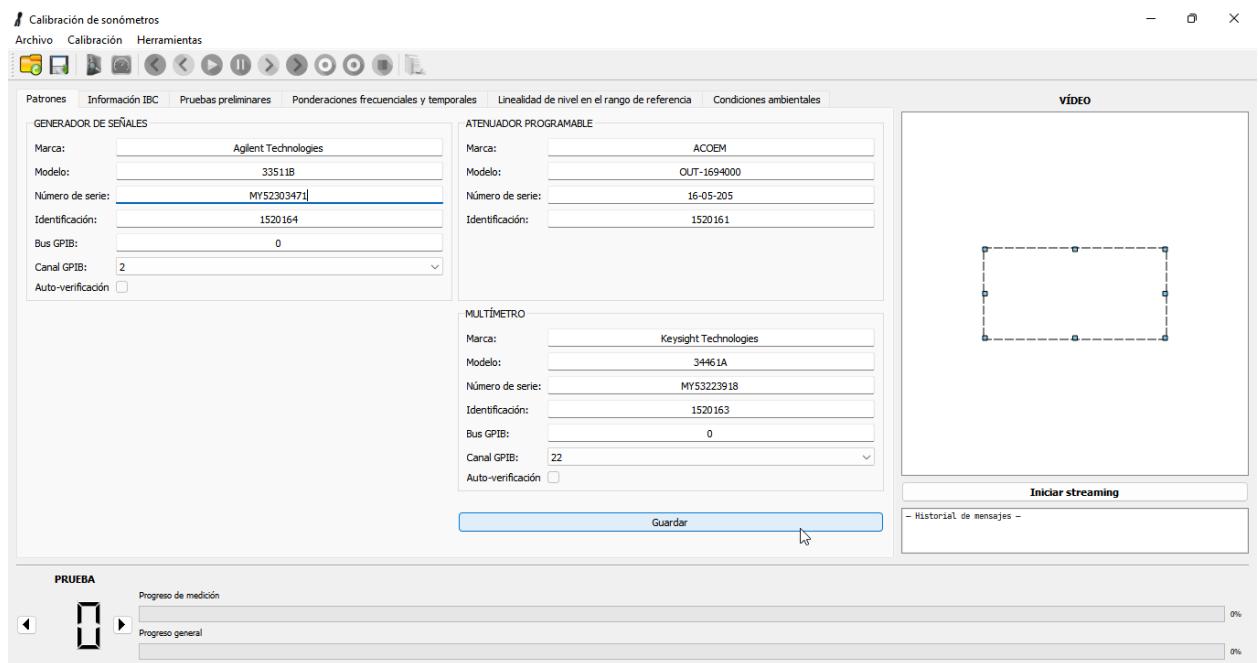
El diagrama de clases de la figura 4-8 es un resumen de las clases principales (con sus atributos y métodos) diseñadas para el desarrollo de la aplicación para la calibración de sonómetros. También se presentan las clases heredadas y el instanciamiento entre clases.

La escritura del código se hizo aplicando las buenas prácticas de programación como: Documentación de clases, métodos e instrucciones relevantes, uso de atributos o métodos protegidos, aseguramiento de recursos para evitar condiciones de carrera entre hilos, colas para el procesamiento en segundo plano y las directrices de la guía PEP 8. La interfaz gráfica se diseñó en Qt Designer de tal forma que se logre un manejo intuitivo de las funciones de la aplicación usando diferentes recursos como íconos, barras de progreso, menús desplegables, barra de herramientas, etc. Con Qt Designer fue posible generar el código base de Python para el view que lanza la

aplicación y muestra la interfaz tal como fue diseñada.

Descripción de funcionamiento

Figura 4-9.: Interfaz gráfica de usuario de la aplicación para sonómetros. Se muestra la pestaña de Patrones.



Fuente: Elaboración propia.

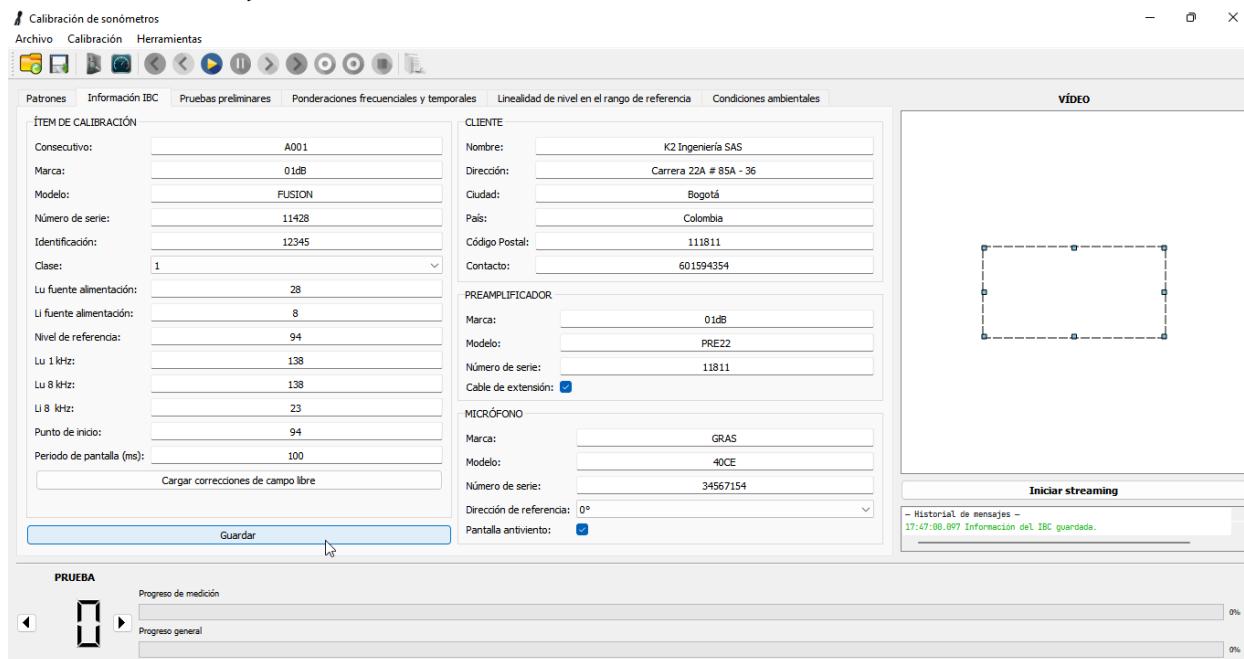
La aplicación para la calibración de sonómetros tiene un flujo de trabajo similar a la de calibradores acústicos. En la figura 4-9 se muestra la interfaz gráfica de usuario diseñada. En la vista inicial, la pestaña de Patrones es la primera en mostrarse. En esta, el usuario ingresa la información básica de los patrones empleados en la calibración. Para el generador de señales y el multímetro digital, si el usuario digita información en los campos de modelo, se habilita la herramienta , la cual busca automáticamente los modelos indicados entre todos los equipos disponibles conectados por GPIB al computador, extrae la información de estos y rellena los campos faltantes.

Una vez la información de los patrones está completa, el usuario puede hacer clic en Guardar. Se habilita la herramienta , con la que se ejecuta la secuencia de auto-verificación de los patrones conectados por GPIB, si está disponible. El resultado de la verificación se muestra en el check box correspondiente.

Dado que en esta aplicación se realizan más tareas y hay mayor interacción de los hilos de pro-

gramación, fue conveniente incluir un `QListWidget` en el que se indexan registros de eventos con su correspondiente marca de tiempo, usando un código de colores (negro: mensaje informativo, verde: acción importante realizada y rojo: error o acción finalizada incorrectamente). Este registro de eventos está siempre visible debajo del recuadro al que se transmiten los cuadros de vídeo.

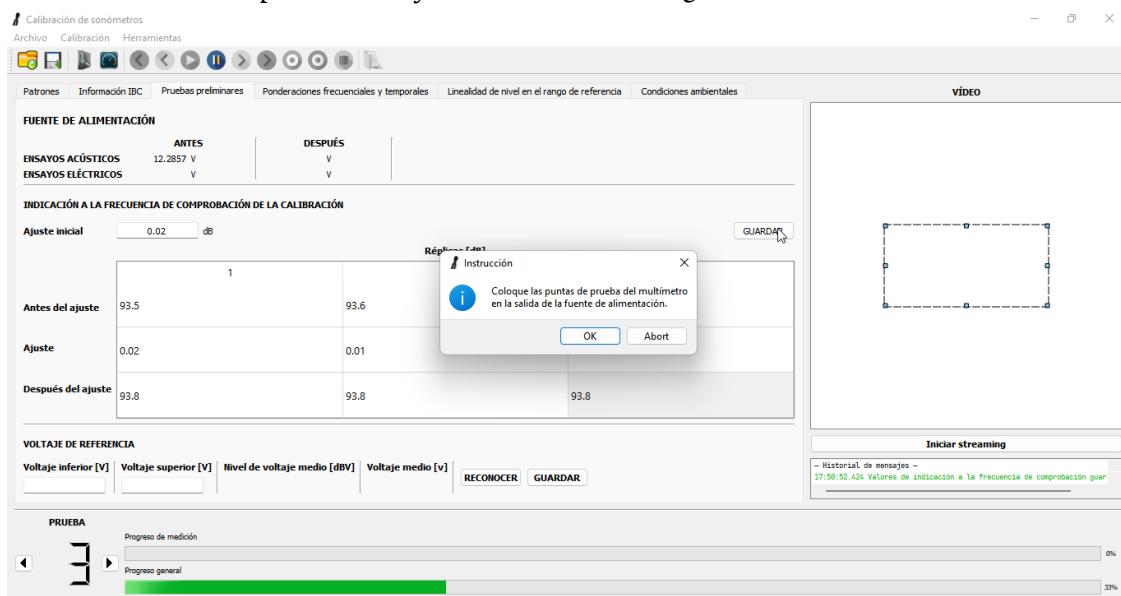
Figura 4-10.: Interfaz gráfica de usuario de la aplicación para sonómetros. Se muestra la pestaña de Información del IBC.



Fuente: Elaboración propia.

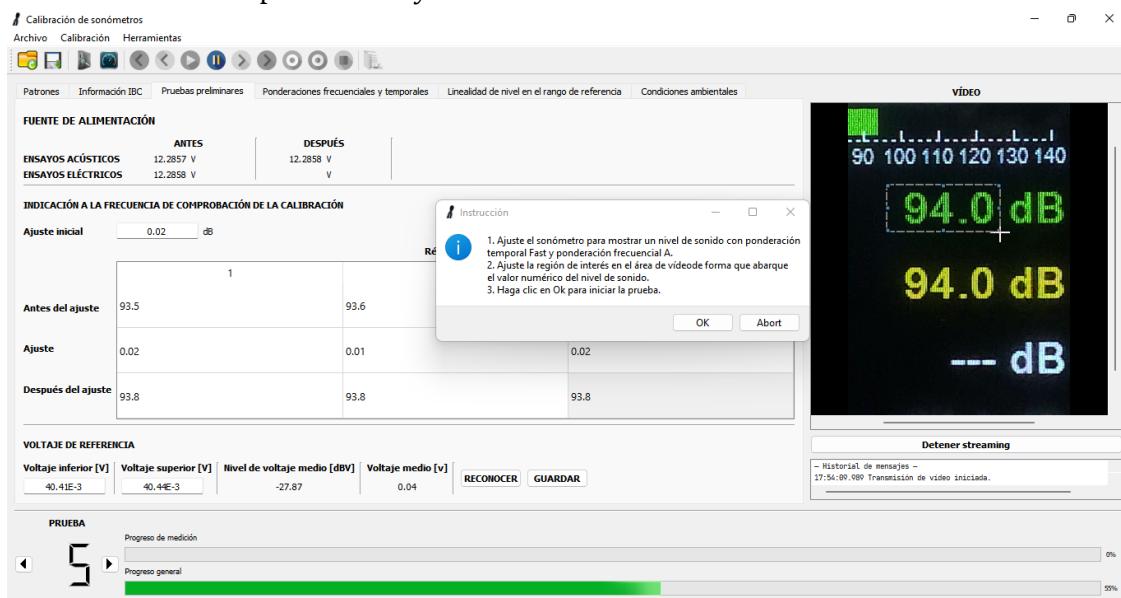
A continuación, en la pestaña **Información IBC** (véase figura 4-10), el usuario ingresa toda la información del sonómetro bajo verificación y del cliente, necesaria para la calibración y para el certificado de calibración. Cuando la información esté completa, el usuario puede hacer clic en **Guardar**. Según la configuración indicada para el sonómetro, el programa buscará en una base de datos los factores de corrección de campo libre; si estos no están disponibles, entonces el usuario puede crear un archivo separado por comas con los factores de corrección y cargarlos manualmente. Luego, si el resultado de auto-verificación de los patrones fue correcto, entonces se habilita el botón . Al hacer clic en este se ejecuta el paso 0 del algoritmo 4.1. En seguida se llevan a cabo todas las acciones de los demás pasos y, en la medida que avanza la secuencia, se van mostrando instrucciones al usuario para las acciones manuales (ver figura 4-11).

Figura 4-11.: Interfaz gráfica de usuario de la aplicación para sonómetros. Se muestra la pestaña de Pruebas preliminares y un cuadro de diálogo con una instrucción.



Fuente: Elaboración propia.

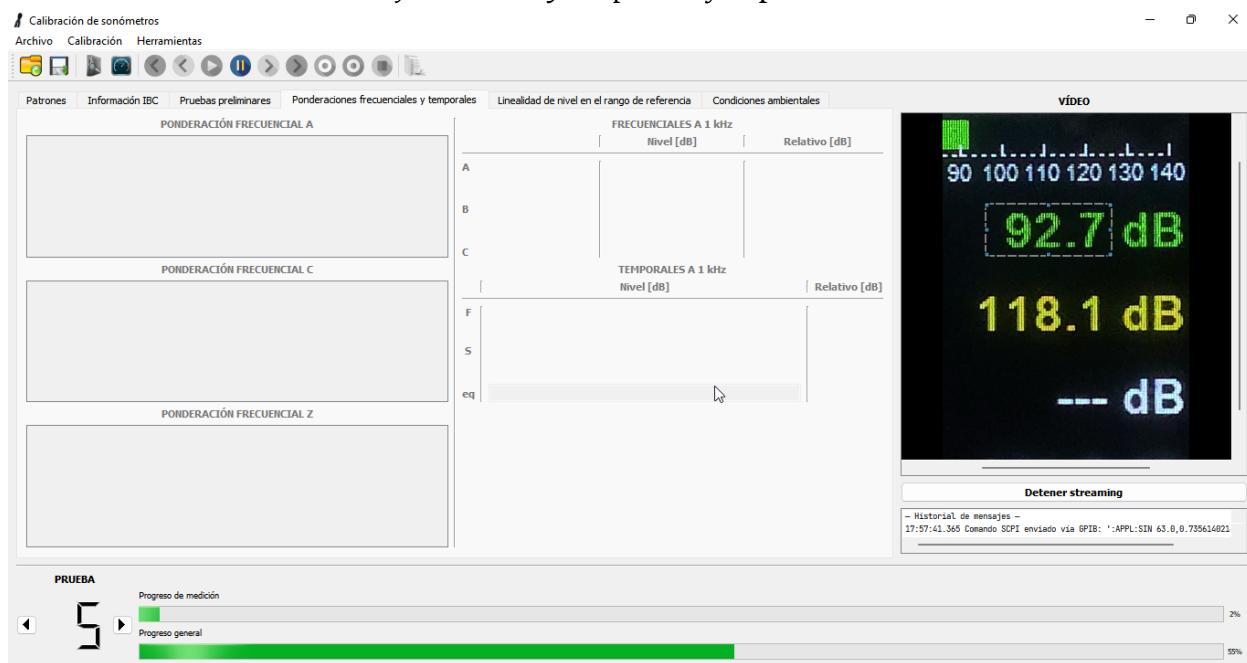
Figura 4-12.: Interfaz gráfica de usuario de la aplicación para sonómetros. Se muestra la pestaña de Pruebas preliminares y la selección del área de interés sobre el vídeo.



Fuente: Elaboración propia.

Al llegar al paso 5 (ponderación frecuencial A con señales eléctricas), si no se ha activado la transmisión de vídeo, entonces esta iniciará y el usuario puede seleccionar el área de interés donde se encuentra el valor de medición que se desea reconocer (véase figura 4-12). Igualmente con las siguientes pruebas hasta el paso 10. En la medida que avanzan las pruebas, los voltajes y frecuencias de las señales eléctricas se van ajustando automáticamente y se muestran en el historial los comandos SCPI enviados; los resultados se presentan en tiempo real en sus campos correspondientes según la prueba en curso como se muestra en la siguiente figura.

Figura 4-13.: Interfaz gráfica de usuario de la aplicación para sonómetros. Se muestra la pestaña de Ponderaciones frecuenciales y temporales y la presentación de resultados.



Fuente: Elaboración propia.

5. Caracterización de la variabilidad del valor de medición usando modelos de Markov

En esta sección se explica el diseño e implementación del método propuesto para tener en cuenta la variabilidad del nivel indicado en la pantalla del sonómetro bajo calibración en el resultado de medición, expresado como el valor de medición junto con la incertidumbre expandida de medición. En primer lugar, se describen las consideraciones previas que dan validez al método propuesto y se introduce el algoritmo que resume la ejecución del método en una serie de pasos. Luego, se presenta el fundamento teórico suficiente de los procesos estocásticos modelados con cadenas de Markov y se describen brevemente los detalles de la implementación del método. Finalmente, se muestra y discute un ejemplo de un valor de medición obtenido con el método implementado y su correspondiente incertidumbre de medida tipo A.

Consideraciones previas

El nivel instantáneo ponderado en tiempo y en frecuencia definido en la ecuación (2-1) no es un indicador representativo del nivel de sonidos cuya presión tiene bastante variabilidad, ya que es muy susceptible a las variaciones instantáneas en la presión acústica, por lo que normalmente en mediciones acústicas se evalúa el nivel de sonido promediado en el tiempo o nivel de sonido continuo equivalente, definido en la IEC 61672-1 ([2013a](#)) como

$$L_{X_{eq},T} = 10 \log \left(\frac{\frac{1}{t_1-t_2} \int_{t_2}^{t_1} p_X^2(\xi) d\xi}{p_0^2} \right), \quad (5-46)$$

En que t_1 y t_2 son el instante de tiempo final e inicial de integración correspondientemente. El nivel continuo equivalente es un indicador mucho más confiable, ya que se trata de un nivel constante que, durante todo el tiempo de integración, tiene la misma energía acústica que la señal de presión con sus variaciones instantáneas.

Ahora, medir el nivel equivalente requiere una intervención manual del usuario para ajustar en el sonómetro el tiempo de integración y ver el resultado final, por lo que este indicador no

es el más adecuado para la automatización empleando reconocimiento de imágenes. No obstante, la IEC 61672-3 (2013c) permite seleccionar entre un nivel ponderado en el tiempo o un nivel promediado en el tiempo, como valor de medición en cada punto de calibración. Para no comprometer la automatización y obtener un resultado de medición válido y representativo de todas las posibles variaciones que pueda tener el nivel instantáneo ponderado en el tiempo, se propone tener en cuenta todas las muestras del nivel ponderado en el tiempo y luego, el nivel presente en la mayor cantidad de muestras viene a ser una estimación apropiada del nivel promediado en el tiempo (esto en condiciones controladas, como es el caso en laboratorios de calibración). Este efecto se puede comprobar analizando las expresiones matemáticas de cada indicador. En primer lugar, de la ecuación (2-1) se extrae que la presión acústica con ponderación temporal, expresada como una función del tiempo es

$$p_{XY}^2(t) = \frac{1}{\tau_Y} \int_{-\infty}^t p_X^2(\xi) e^{-(t-\xi)/\tau_Y} d\xi. \quad (5-47)$$

Esta presión instantánea ponderada en el tiempo no es la misma de la ecuación (5-46). Para calcular un nivel continuo equivalente con ponderación temporal y frecuencial se requiere modificar la ecuación (5-46) remplazando $p_X^2(\xi)$ por $p_{XY}^2(t)$; en efecto, queda

$$\begin{aligned} L_{AFeq,T} &= 10 \log \left(\frac{\frac{1}{t_1-t_2} \int_{t_2}^{t_1} p_{XY}^2(t) dt}{p_0^2} \right); \\ &= 10 \log \left(\frac{\frac{1}{\tau_Y(t_1-t_2)} \int_{t_2}^{t_1} \int_{-\infty}^t p_X^2(\xi) e^{-(t-\xi)/\tau_Y} d\xi dt}{p_0^2} \right). \end{aligned} \quad (5-48)$$

En la ecuación (5-48) se puede concluir que cuanto más tiempo permanezca estable una presión acústica instantánea ponderada en tiempo, el nivel equivalente más se acercará al correspondiente nivel instantáneo ponderado en tiempo, pues tiene mayor efecto en el resultado de la integral.

Algoritmo para la creación del modelo de Markov

El método propuesto consiste en tomar cada uno de los niveles instantáneos obtenidos como un estado en una cadena de Markov. Esta cadena caracteriza los cambios de un nivel a otro, considerando la variabilidad del nivel instantáneo como un proceso estocástico. Luego, con la distribución de probabilidad estacionaria se estima el valor esperado en el largo plazo, que lógicamente corresponde al estado (nivel instantáneo) con mayor probabilidad de ocurrir. Las probabilidades de transición de un estado a otro se determinan a partir de una serie de muestras de

niveles instantáneos obtenidas durante un tiempo de 25 segundos aproximadamente, y la cantidad de muestras depende del periodo de actualización del nivel instantáneo en la pantalla del sonómetro. Por tanto, el valor esperado calculado con la cadena de Markov será probablemente el nivel instantáneo que más muestras tuvo y será el valor de medición. Este es un proceso que se realiza en cada punto de calibración y se resume en el siguiente algoritmo, y las operaciones realizadas en cada paso, se describen en las siguientes secciones.

Algoritmo 5.1: Algoritmo para el cálculo del valor esperado usando cadenas de Markov.

Data: frames \leftarrow Vídeo de 25 s del nivel instantáneo indicado en pantalla.

output: Valor esperado

- 1 **Paso 1:** Submuestrear y reconocer cuadros después del tiempo de estabilización.
 - 2 **Paso 2:** Conformar matriz de transición de estados.
 - 3 **Paso 3:** Calcular distribución de probabilidad estacionaria.
 - 4 **Paso 4:** Completar valores faltantes usando la matriz de transición.
 - 5 Repetir paso 2.
 - 6 Repetir paso 3.
 - 7 **Paso 5:** Calcular valor esperado.
-

Paso 1: Submuestreo y reconocimiento de cuadros después de la estabilización

Como el nivel con ponderación temporal Fast, que tiene una constante de tiempo $\tau_F = 125$ ms, requiere un tiempo transitorio hasta que el nivel se estabilice después de enviar la señal eléctrica. Se determinó experimentalmente un tiempo de 2 s. Los cuadros obtenidos durante este tiempo de estabilización no se tienen en cuenta para la matriz de transición, pero sí para determinar el cuadro 0 para sincronizar la actualización del nivel instantáneo en pantalla con los cuadros del vídeo.

Para determinar el cuadro 0 primero se efectúa el algoritmo 3.1 en los cuadros del tiempo de estabilización. Con el vector de los valores numéricos reconocidos se encuentra el índice del primer cambio de valor. Luego, a los cuadros después de ese índice se les hace un submuestreo según la relación entre la tasa de cuadros por segundo de la cámara y la tasa de actualización de la pantalla del sonómetro. Los cuadros que quedan corresponden al instante exacto en el que hay una nueva muestra en pantalla. Sin embargo, dado que puede presentarse en la pantalla LCD un efecto de solapamiento entre la muestra anterior y la nueva, que afecta negativamente el reconocimiento de imágenes, se determinó experimentalmente tomar 4 cuadros después del cuadro en el que ocurre el cambio, para permitir la estabilización de la pantalla.

En seguida, en el nuevo vector de cuadros submuestreado se busca el índice del cuadro inmediatamente después al tiempo de estabilización, que corresponde al producto del tiempo de estabilización y la tasa de actualización de la pantalla del sonómetro. Finalmente, se efectúa el

reconocimiento de los cuadros submuestreados a partir del índice del cuadro de estabilización con el algoritmo 3.1. El vector de valores numéricos reconocidos es el arreglo de muestras a partir del cual se conforma la matriz de transición de estados en el paso a continuación.

5.1. Cadenas de Markov de tiempo discreto

Paso 2: Matriz de probabilidades de transición

Tomando como guía el libro de Robert Dobrow (2016) y el de John Gubner (2006), una cadena de Markov es un proceso aleatorio con la propiedad particular de que, dados unos valores del proceso desde el tiempo cero hasta el tiempo actual, la probabilidad condicional del valor del proceso en algún tiempo futuro depende solo del valor actual, es decir, el futuro y el pasado son condicionalmente independientes dado el presente. Analíticamente, una cadena de Markov es una secuencia de variables aleatorias X_0, X_1, \dots que toman valores del espacio discreto de estados \mathcal{S} con la propiedad de que

$$P(X_{n+1} = j | X_0 = x_0, \dots, X_{n-1} = x_{n-1}, X_n = i) = P(X_{n+1} = j | X_n = i), \quad (5-49)$$

Para todo $x_0, \dots, x_{n-1}, i, j \in \mathcal{S}$ y $n \geq 0$. Normalmente, se asume que todas las cadenas de Markov son homogéneas, en las que la probabilidad no dependen de n .

En la ecuación (5-49) las probabilidades solamente dependen de i y j , por lo que estas se pueden organizar de forma matricial en \mathbf{P} , cuya ji -ésima entrada es $p_{ij} = P(X_{n+1} = j | X_n = i)$, la probabilidad de transición de un estado a otro en un paso. La matriz de transición es una matriz cuadrada de $k \times k$ para los k estados en el espacio \mathcal{S} .

Código 5.1: Método estático para la construcción de una matriz de transición de estados a partir de una serie de muestras dada.

```

1  @staticmethod
2  def build_transition_matrix(samples: np.ndarray) → np.ndarray:
3      """
4          Method for construction of the states transition matrix from a sequence of samples
5          :param samples: A numpy one dimensional ndarray with the sequence of samples.
6          :return: A numpy array that represents the transition matrix of the Markov model.
7      """
8      states = np.unique(samples) # Remove repeated samples
9      P = pd.DataFrame(data=np.zeros((states.shape[0], states.shape[0])), index=states, columns=states) # Empty P
10     for i in range(1, samples.shape[0]): # Counts transitions from state to state
11         P.loc[samples[i - 1], samples[i]] += 1
12     P = P.div(P.sum(axis=1), axis=0) # Computes probabilities
13     return P

```

La matriz de transición o matriz estocástica debe cumplir que $p_{ij} \geq 0 \quad \forall i, j$ y que

$$\sum_j p_{ij} = \sum_j P(X_{n+1} = j | X_n = i) = \sum_j \frac{P(X_{n+1} = j, X_n = i)}{P(X_n = i)} = \frac{P(X_n = i)}{P(X_n = i)} = 1.$$

Lo que indica que las transiciones en las cadenas de Markov son exhaustivas.

Teniendo en cuenta este fundamento conceptual, para cada punto de calibración se conforma una matriz de transición en la que cada nivel diferente indicado en pantalla es un estado en la cadena de Markov. Para este efecto se escribió el método estático del código [5.1](#).

Paso 3: Distribución de probabilidad estacionaria

Una vez se conforma una matriz con las probabilidades de transición se puede usar álgebra matricial para hacer cálculos con las probabilidades. Uno de los más elementales es el cálculo de las probabilidades de transición del estado i al j en $n \geq 1$ pasos, es decir $p_{ij}^{(n)} = P(X_n = j | X_0 = i)$, la probabilidad de que en n pasos el proceso visite el estado j dado que ahora está en el estado i . Cuando $n = 1$ las probabilidades son las mismas de \mathbf{P} , pero cuando $n \geq 1$ las probabilidades de transición son los ij -ésimos elementos de la potencia n de \mathbf{P} , denotado como \mathbf{P}^n .

Es de especial interés conocer el comportamiento del sistema en el largo plazo, lo cual está caracterizado por las potencias de mayor orden de \mathbf{P} . En la medida en que n incrementa, el proceso alcanza un comportamiento límite y las probabilidades de transición convergen a una distribución de equilibrio, conocida como distribución límite, la cual no depende de la distribución de probabilidad inicial de los estados. Para una cadena de Markov la distribución límite es la distribución de probabilidad λ con la propiedad de que para todo i y j

$$\lim_{n \rightarrow \infty} P_{ij}^n = \lambda_j. \tag{5-50}$$

Si una cadena de Markov tiene una distribución límite, entonces esta es única. Se puede encontrar la distribución límite simplemente tomando las potencias de mayor orden hasta obtener una matriz Λ en la cual todas las filas son iguales a λ , o también se pueden encontrar soluciones exactas de forma analítica y teórica. Cabe mencionar que la distribución límite también puede ser interpretada como la proporción de tiempo que el proceso visita cada estado en el largo plazo

Ahora, si se asigna la distribución límite como la distribución inicial de la cadena de Markov, luego se encuentran las probabilidades marginales $\lambda \mathbf{P}$, y el resultado es el mismo vector λ , entonces esta distribución límite es llamada distribución estacionaria. Es decir, una distribución

estacionaria es una distribución de probabilidad π que satisface $\pi = \pi P$, o lo que es igual

$$\pi_j = \sum_i \pi_i P_{ij}, \quad \forall j. \quad (5-51)$$

Aunque la distribución límite y la estacionaria están relacionadas, una cadena de Markov puede tener más de una distribución estacionaria o ninguna, y esta no necesariamente es la distribución límite. Pero si la cadena tiene una distribución límite, entonces esa distribución es estacionaria. Esto depende directamente de la topología de la cadena; si la cadena es regular entonces su matriz de transición P es regular (todos los valores de alguna de sus potencias son positivos), y la distribución límite es igual a la estacionaria.

Para encontrar la distribución estacionaria cuando la matriz es regular, la forma más directa es resolver el sistema lineal de ecuaciones que resulta de combinar la ecuación (5-51) y la restricción $\sum_i \pi_i = 1$. La ecuación (5-51) puede escribirse matricialmente como $\pi (P - I) = 0$, o, para operar con vectores columna, como $(P^\top - I) \pi = 0$. Finalmente, se puede escribir el sistema de ecuaciones matricialmente como

$$A \pi = b \quad (5-52)$$

$$\begin{bmatrix} (P^\top - I) \\ 1 \\ \vdots \\ 1; \end{bmatrix} \pi = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 1 \end{bmatrix}. \quad (5-53)$$

Para encontrar soluciones para π se resuelve el sistema

$$(A^\top A) \pi = A^\top b. \quad (5-54)$$

Para implementar lo anterior y calcular la distribución límite dada una matriz de transición P se escribió el método estático del código 5.2.

Paso 5: Valor esperado

En un sistema discreto, el valor esperado calculado a partir de la distribución estacionaria es

$$E[X] = \sum_n x_n \pi_n, \quad (5-55)$$

Que puede implementarse simplemente como `expected_value = np.round(np.sum(np.array(P.index) * PI.T), 1)`.

Código 5.2: Método estático para el cálculo de la distribución límite de una cadena de Markov dada una matriz de transición.

```

1 def limit_dist(P: np.ndarray) → float:
2     """
3         Method to calculate the limit distribution with linear algebra solution using a given transition matrix P if
4         the given matrix is a regular matrix, else, the calculation is performed with the high matrix powers of the
5         transition matrix.
6         :param P: The numpy array that represents de transition matrix.
7         :return: The stationary distribution as a float number.
8     """
9     for n in range(2, 1001):
10         if np.all(np.linalg.matrix_power(P, n) > 0): # Check if it is a regular transition matrix
11             # The matrix is regular, so limiting distribution exists and is the unique stationary distribution
12             A = np.append(np.transpose(P) - np.identity(P.shape[0]), np.ones((1, P.shape[0])), axis=0) # Augmented A
13             b = np.zeros((A.shape[0], 1))
14             b[-1] = 1 # Augmented b
15             PI = np.linalg.solve(np.transpose(A).dot(A), np.transpose(A).dot(b)) # Stationary distribution
16             break
17     else:
18         PI = np.linalg.matrix_power(P, 1000)
19
20     return PI

```

Paso 4: Completar valores faltantes

Aún cuando el clasificador tiene un buen desempeño y el submuestreo se ha realizado evitando el efecto de solapamiento de valores en la pantalla del sonómetro, puede ocurrir que eventualmente un cuadro capturado coincide con la actualización del valor en pantalla y consecuentemente el clasificador devuelve un resultado incorrecto. Para estos casos poco recurrentes, se determinó que el clasificador devolviera un valor `np.nan`. Esta es una muestra faltante que debe ser completada para continuar con el proceso.

Para remplazar la muestra faltante conviene utilizar la matriz inicial de transición de un paso construida en el [Paso 1](#) para ubicar el valor más probable a partir del valor anterior. En el caso en el que la primera muestra sea un estado faltante, esta se completa con la distribución estacionaria de la matriz de transición inicial. Esto es razonable porque los valores ubicados obedecen a la dinámica del proceso estocástico que fue caracterizada en la matriz de transición inicial. En efecto, este paso se realiza con el siguiente código.

Código 5.3: Ciclo para completar muestras faltantes a partir del modelo inicial de Markov.

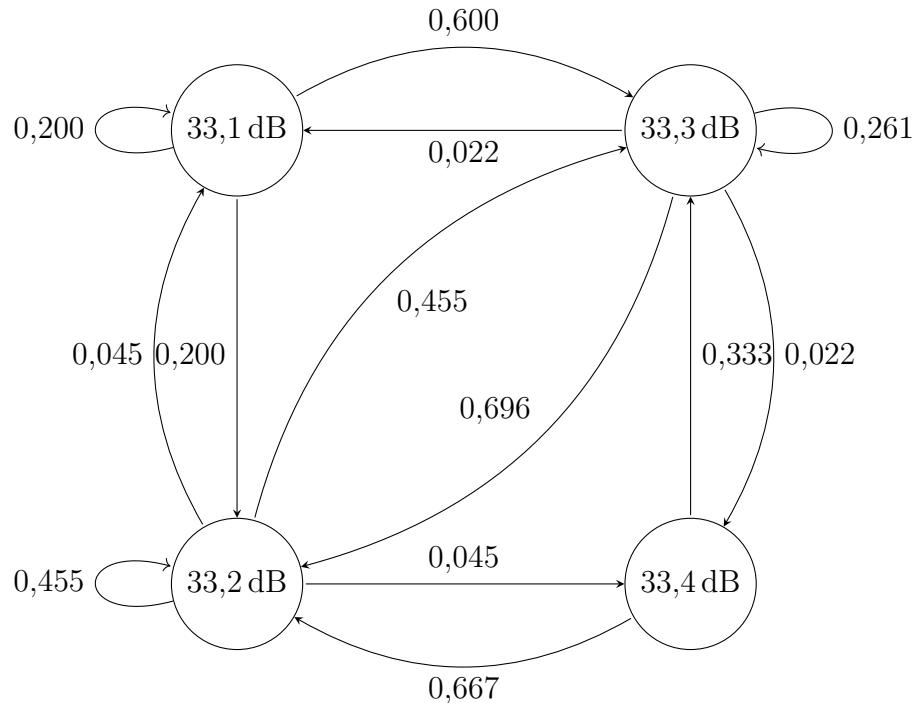
```

1 samples[0] = P.index[PI.argmax()] if np.isnan(samples[0]) else samples[0] # If initial state is missing
2 for i in np.where(np.isnan(samples))[0]: # Filling based on the previous state and the Markov model
3     samples[i] = P.index[P.loc[samples[i - 1]].argmax()]

```

Una vez el vector de muestras está completo, se construye una segunda matriz de transición y nuevamente se calcula la distribución estacionaria que se empleará en el cálculo del valor esperado.

Figura 5-1.: Grafo de estados y probabilidades de transición que representa la matriz de transición (5-56).



Fuente propia.

5.2. Ejemplo de resultado de ejecución del método

Habiendo incluido apropiadamente este método en el desarrollo previo de la aplicación, se obtuvieron los resultados esperados. Un ejemplo de una matriz de transición obtenida en la prueba de ponderación frecuencial Z con señales eléctricas a 63 Hz se muestra a continuación.

$$\mathbf{P} = \begin{bmatrix} 33,1 & 33,2 & 33,3 & 33,4 \\ 33,1 & 0,200 & 0,200 & 0,600 & 0,000 \\ 33,2 & 0,045 & 0,455 & 0,455 & 0,045 \\ 33,3 & 0,022 & 0,696 & 0,261 & 0,022 \\ 33,4 & 0,000 & 0,667 & 0,333 & 0,000 \end{bmatrix} \quad (5-56)$$

Y el grafo correspondiente se representa en la figura 5-1.

Resolviendo el sistema de la ecuación (5-54), la distribución estacionaria es

$$\boldsymbol{\pi} = \begin{bmatrix} 33,1 & 33,2 & 33,3 & 33,4 \\ 0,041 & 0,543 & 0,382 & 0,033 \end{bmatrix}$$

Y finalmente, el valor esperado, redondeado a la misma cantidad de dígitos decimales de la

precisión del sonómetro es 33,2 dB.

5.3. Evaluación tipo A de la incertidumbre típica

De acuerdo con la guía para la expresión de la incertidumbre de medida ([ISO Technical Advisory Group 4, 2008](#)), los valores de las observaciones individuales q_k difieren en razón de las variaciones aleatorias de las magnitudes de influencia o de efectos aleatorios. La varianza experimental de dichas n observaciones está dada por:

$$s^2(q_k) = \frac{1}{n-1} \sum_{j=1}^n (q_j - \bar{q})^2, \quad (5-57)$$

Que, junto con su raíz cuadrada positiva $s(q_k)$ (denominada desviación típica experimental), representan la variabilidad de los valores q_k , es decir, su dispersión alrededor del valor esperado \bar{q} . Luego, la mejor estimación de la varianza experimental de la media $\sigma^2(\bar{q}) = \sigma^2/n$ es

$$s^2(\bar{q}) = \frac{s^2(q_k)}{n}, \quad (5-58)$$

Que, junto con desviación típica experimental de la media $s(\bar{q}) = \sqrt{s^2(\bar{q})}$ pueden ser utilizadas como medida de la incertidumbre de \bar{q} .

En concreto, en un modelo matemático de un mesurando y , para una magnitud de entrada X_i obtenida a partir de n observaciones repetidas e independientes $X_{i,k}$, la incertidumbre típica $u(x_i)$ de su estimación $x_i = \bar{X}_i$ es $u(x_i) = s(\bar{X}_i)$, con $s^2(\bar{X}_i)$ calculada con la ecuación (5-58). Esta incertidumbre típica $u(x_i)$ es llamada incertidumbre típica tipo A.

El número de observaciones n debe ser lo suficientemente grande para garantizar que $s^2(\bar{q})$ proporcione una estimación fiable de la varianza $\sigma^2(\bar{q})$. La aplicación desarrollada permite cumplir esta consideración, puesto que en un tiempo de 25 s, con un periodo de actualización de pantalla típico de 100 ms, se capturan 250 muestras. Ahora, en un cálculo posterior, cuando se determinan intervalos de confianza para la incertidumbre expandida, se debe tomar en cuenta la diferencia entre $\sigma^2(\bar{q})$ y $s^2(\bar{q})$, ya que en muchos casos puede ser que la distribución de probabilidad del mesurando (en este caso equivale a la distribución estacionaria) sea muy distinta de una distribución normal.

La estimación de la incertidumbre típica tipo A puede hacerse rápidamente con la instrucción `samples.std() / math.sqrt(samples.shape[0])`. Para las muestras del ejemplo anterior se obtiene $s(\bar{q}) \approx 0,0057$ dB.

6. Conclusiones y recomendaciones

6.1. Conclusiones

Las conclusiones constituyen un capítulo independiente y presentan, en forma lógica, los resultados de la tesis o trabajo de investigación. Las conclusiones deben ser la respuesta a los objetivos o propósitos planteados. Se deben titular con la palabra conclusiones en el mismo formato de los títulos de los capítulos anteriores (Títulos primer nivel), precedida por el numérico correspondiente (según la presente plantilla).

6.2. Recomendaciones

Se presentan como una serie de aspectos que se podrían realizar en un futuro para emprender investigaciones similares o fortalecer la investigación realizada. Deben contemplar las perspectivas de la investigación, las cuales son sugerencias, proyecciones o alternativas que se presentan para modificar, cambiar o incidir sobre una situación específica o una problemática encontrada. Pueden presentarse como un texto con características argumentativas, resultado de una reflexión acerca de la tesis o trabajo de investigación.

A. Anexo: Códigos de Python

Código A.1: Código para presentar resultados del procesamiento de una muestra del número 5 del conjunto de imágenes entrenamiento.

```
1 import cv2 as cv
2 import matplotlib.pyplot as plt
3 import numpy as np
4
5 """
6 Programed by Felipe Maldonado,
7 Universidad Nacional de Colombia, Faculty of Engineering,
8 Department of Electrical and Electronic Engineering.
9 Created on 2022/03.
10 """
11 __autor__ = 'Juan Felipe Maldonado'
12 __version__ = '1.0 Beta'
13
14 path = "Images/Test1"
15 img_name = "5(1).jpg" # Sample just for showing results of processing
16 descriptor = cv.SIFT_create(contrastThreshold=0.02, edgeThreshold=1, sigma=0.01) # Creates a SIFT descriptor
17 # Four key points for computing SIFT descriptor
18 key_points = [cv.KeyPoint(7, 7, 16), cv.KeyPoint(7, 13, 16),
19                 cv.KeyPoint(13, 7, 16), cv.KeyPoint(13, 13, 16)]
20
21 X = []
22 y = []
23 img = cv.imread(path + "/" + img_name, cv.IMREAD_GRAYSCALE) # Read image in gray scale
24 img_col = cv.cvtColor(cv.imread(path + "/" + img_name), cv.COLOR_BGR2RGB) # Read image in gray scale
25 img.blur = cv.GaussianBlur(img.copy(), ksize=(0, 0), sigmaX=1.5) # Gaussian filtering
26 mayor_axis = max(img.blur.shape) # The largest axis
27 # Normalize size
28 digit_scaled = cv.resize(img.blur, (0, 0), fx=32 / mayor_axis,
29                         fy=32 / mayor_axis, interpolation=cv.INTER_CUBIC)
30 # Build an image of 32 x 32 pixels with padding
31 if digit_scaled.shape[0] > digit_scaled.shape[1]:
32     digit_scaled = np.pad(digit_scaled, ((0, 0), ((32 - digit_scaled.shape[1]) // 2,
33                                         (32 - digit_scaled.shape[1]) // 2)), 'constant')
34 else:
35     digit_scaled = np.pad(digit_scaled, (((32 - digit_scaled.shape[0]) // 2,
36                                         (32 - digit_scaled.shape[0]) // 2), (0, 0)), 'constant')
37
38 img_bin = cv.threshold(digit_scaled, 0, 255, cv.THRESH_BINARY | cv.THRESH_OTSU)[1] # Otsu binarization
39 # -- SIFT DESCRIPTOR --
40 _, features = descriptor.compute(img_bin, key_points) # Computes SIFT descriptor
41 X.append(features.flatten()) # Add the features vector of the actual training sample
42 y.append(img_name) # Add the class of the actual training sample
43 # -- Plots results --
44 plt.imshow(img, cmap='gray'), plt.show()
45 plt.imshow(img_col), plt.show()
46 plt.imshow(img.blur, cmap='gray'), plt.show()
47 plt.imshow(digit_scaled, cmap='gray'), plt.show()
48 plt.imshow(img_bin, cmap='gray'), plt.show()
49
50 # -- Plots SIFT features by sample --
51 plt.scatter(range(len(X[0])), X[0], s=8, c='b', marker='s', label='Muestra de número 5')
52 plt.grid(visible=True), plt.legend(), plt.show()
```

Código A.2: Código para realizar la extracción de características de los vectores de entrenamiento y para entrenar el clasificador.

```

1 from sklearn.decomposition import KernelPCA
2 from sklearn.naive_bayes import GaussianNB
3
4 kpcaModel = KernelPCA(n_components=16) # KPCA for dimensionality reduction
5 gnbClassifier = GaussianNB() # Gaussian naive Bayes classifier
6
7 X = np.array(X) # Convert training features vector to numpy array
8 y = np.array(y) # Convert training samples labels to numpy array
9
10 # ----- DIMENSIONALITY REDUCTION BY KERNEL PCA ----- #
11 # Fits the model and apply transformation to the features vector
12 X = kpcaModel.fit_transform(X, y)
13 # ----- FITS THE CLASSIFIER -----#
14 gnbClassifier.fit(X, y)

```

Código A.3: Código para realizar la extracción de características de los vectores de prueba y para realizar la clasificación.

```

1 X = np.array(X) # Convert test sample features vector to numpy array
2 # ----- DIMENSIONALITY REDUCTION BY KERNEL PCA ----- #
3 X = kpcaModel.transform(X)
4 # ----- CLASSIFY -----#
5 y_hat = gnbClassifier.predict(X)
6

```

Código A.4: Código para generar la matriz de confusión del clasificador bayesiano normal.

```

1 from sklearn.metrics import confusion_matrix, ConfusionMatrixDisplay
2
3 # ----- CLASSIFICATION ACCURACY -----
4 cm = confusion_matrix(y_hat, y_test, labels=gnbClassifier.classes_)
5 disp = ConfusionMatrixDisplay(confusion_matrix=cm, display_labels=gnbClassifier.classes_)
6 disp.plot()
7 plt.show()

```

Bibliografía

Brüel & Kjær (2016). *Instruction Manual, Hand-held Analyzer Types 2250, 2250-L and 2270*. Brüel & Kjær Sound & Vibration Measurement A/S, Nærum, Denmark.

Brüel & Kjær (2021). What is a Sound Level Meter? <https://www.bksv.com/en/knowledge/blog/sound/what-is-a-sound-level-meter>. En línea: consultada en marzo del 2022.

Committee on conformity assessment (2017). General requirements for the competence of testing and calibration laboratories. Standard ISO/IEC 17025, International Standard Organization, Geneva, Switzerland.

Dobrow, R. P. (2016). *Introduction to Stochastic Processes* With R. John Wiley & Sons, Inc., Hoboken, New Jersey, 1 edición.

Fletcher, H. y Munson, W. A. (1933). Loudness, Its Definition, Measurement and Calculation. *The Journal of the Acoustical Society of America*, 5(2):82–108.

Gubner, J. A. (2006). *Probability and Random Processes for Electrical and Computer Engineers*. Cambridge University Press, New York, 1 edición.

IEC technical committee 29: Electroacoustics (2013a). Electroacoustics – sound level meters - part 1: Specifications. Standard IEC 61672-1, International Electrotechnical Commission, Geneva, Switzerland.

IEC technical committee 29: Electroacoustics (2013b). Electroacoustics – sound level meters - part 2: Pattern evaluation tests. Standard IEC 61672-2, International Electrotechnical Commission, Geneva, Switzerland.

IEC technical committee 29: Electroacoustics (2013c). Electroacoustics – sound level meters - part 3: Periodic tests. Standard IEC 61672-3, International Electrotechnical Commission, Geneva, Switzerland.

IEC technical committee 29: Electroacoustics (2017). Electroacoustics – sound calibrators. Standard IEC 60942, International Electrotechnical Commission, Geneva, Switzerland.

ISO Technical Advisory Group 4 (2008). *Uncertainty of measurement. Part 3: Guide to the expression of uncertainty in measurement (GUM:1995)*. Standard ISO/IEC 98-3, International Organization for Standardization, Geneva, Switzerland.

Keysight Technologies (2015). *Keysight Trueform Series Waveform Generator Operation and Service Guide*. Keysight Technologies, Inc., Loveland, CO 80537 USA, 3 edición.

Keysight Technologies (2022). IO Libraries Suite Downloads. <https://www.keysight.com/zz/en/lib/software-detail/computer-software/io-libraries-suite-downloads-2175637.html>. En línea: consultada en marzo del 2022.

Lowe, D. G. (2004). Distinctive image features from scale-invariant keypoints. *International Journal of Computer Vision*, 60(2):91–110.

MHJ-Software GmbH & Co. KG (2020). Book Grafcet-Workbook. <https://www.mhj-wiki.de/en/grafcet-workbook/introduction/>. En línea: consultada en abril del 2022.

Otsu, N. (1979). A Tlreshold Selection Method from Gray-Level Histograms. *IEEE Trans Syst Man Cybern*, SMC-9(1):62–66.

PyVISA (2022). PyVISA: Control your instruments with Python. <https://pyvisa.readthedocs.io/en/latest/index.html>. En línea: consultada en marzo del 2022.

Richard, S. (2011). *Algorithms and Applications: Computer vision*. Springer, London, 2 edición.

Schölkopf, B., Smola, A., y Müller, K. R. (1997). *Kernel principal component analysis*, volumen 1327. Springer, Alemania.

Scikit-learn developers (2022). 1.9. Naive Bayes. https://scikit-learn.org/stable/modules/naive_bayes.html#gaussian-naive-bayes. En línea: consultada en marzo del 2022.